



机器学习实验三：K-means 聚类

姓名：冯怡然

学号：2411434

班级：人工智能特色班

日期：2026 年 6 月 2 日

南开大学 · 机器学习实验

1 实验目的

1. 理解聚类任务与监督分类任务的差异，掌握无监督学习的基本思想。
2. 理解 K-means 算法中“样本分配”和“中心更新”两个核心步骤。
3. 使用 MATLAB 实现 K-means 算法，并对二维数据进行聚类与可视化。
4. 观察随机初始化对聚类结果的影响，并分析 K-means 对簇形状和簇规模的限制。

2 实验内容

本实验使用二维平面上的随机样本进行聚类。程序首先在区域 $[0, 10] \times [0, 10]$ 内均匀生成样本，再删除白色间隔中的样本点。聚类算法只能使用样本坐标矩阵 $\mathbf{X}$ ，不能使用数据生成阶段的标签 $\mathbf{Y}$ 。

1. 基础任务：对九宫格形式的九个区域进行聚类，设置 $K = 9$ 。
2. 按照实验要求随机生成初始类中心，不能人为指定中心位置。
3. 使用不同颜色和形状绘制聚类结果，并使用实心方块标记聚类中心。
4. 报告十次随机初始化的运行结果，不只选择效果最好的一次。
5. 附加任务：对簇大小明显不均衡的数据进行聚类，报告现象并分析原因。

3 实验原理

3.1 聚类任务

聚类是一类无监督学习任务。与监督分类不同，聚类算法没有可供直接学习的真实标签。算法只能根据样本之间的相似度或距离，将彼此接近的样本划分到同一类别。本实验中的每一个样本均可表示为二维向量

$$x_i = (x_{i1}, x_{i2})^\top.$$

3.2 K-means 的优化目标

设需要将 n 个样本划分为 K 类，第 k 类的中心为 μ_k ，样本 x_i 的预测类别为 c_i 。K-means 的目标是最小化类内平方距离之和：

$$J = \sum_{i=1}^n \|x_i - \mu_{c_i}\|_2^2.$$

目标函数越小，说明样本到所属中心的总距离越短，类内样本越紧凑。

3.3 迭代计算过程

K-means 通过以下步骤反复更新聚类结果：

1. 从样本中随机选择 K 个点作为初始类中心。

2. 对每个样本，计算它到全部类中心的平方欧氏距离：

$$d_{ik} = \|x_i - \mu_k\|_2^2.$$

3. 将样本划分到距离最近的类中心：

$$c_i = \arg \min_k d_{ik}.$$

4. 对每个类别，计算该类别内样本坐标的均值，作为新的类中心：

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i.$$

5. 重复执行样本分配和中心更新，直到类别不再变化或中心移动距离足够小。

比较距离时，程序直接使用平方欧氏距离而没有计算平方根。这不会改变最近中心的判断，同时可以减少不必要的计算。

4 实验过程与代码实现

4.1 数据生成

基础任务中，程序保留九个小大小接近的小方块区域。附加任务中，左下角为一个 6×6 的大区域，其余区域大小约为 3×3 。在进入 K-means 算法前，程序执行 `clear Y`，确保聚类过程不使用真实标签。

4.2 核心代码

```
1 K = 9; % 附加题中修改为 K = 6
2 Ym = zeros(n,1);
3 meanpoint = X(randperm(n,K),:); % 随机选择初始中心
4
5 maxIter = 100;
6 tol = 1e-6;
7
8 for iter = 1:maxIter
9     distance = zeros(n,K);
10    for k = 1:K
11        difference = X - meanpoint(k,:);
12        distance(:,k) = sum(difference.^2,2);
13    end
14
15    [~,newYm] = min(distance,[],2); % 分配到最近中心
16
17    newMeanpoint = meanpoint;
18    for k = 1:K
19        if any(newYm == k)
20            newMeanpoint(k,:) = mean(X(newYm == k,:),1);
21        else
22            newMeanpoint(k,:) = X(randi(n),:);
```

```

23     end
24 end
25
26 if isequal(newYm,Ym) || ...
27     max(sqrt(sum((newMeanpoint-meanpoint).^2,2))) < tol
28     Ym = newYm;
29     meanpoint = newMeanpoint;
30     break;
31 end
32
33 Ym = newYm;
34 meanpoint = newMeanpoint;
35 end

```

Listing 1: K-means 核心实现

如果某次迭代中出现空类别，程序会随机选择一个样本作为新的中心。这可以避免对空矩阵求均值后产生无效数值，使算法能够继续迭代。

5 实验结果

5.1 基础任务结果

基础任务的输入数据如图 1 所示。九个区域的大小接近，区域之间存在明显间隔。




图 1: 基础任务：九宫格形式的输入数据

图 2 展示了一次典型运行结果。不同颜色表示不同的预测类别，品红色实心方块表示聚类中心。理想情况下，每个小方块区域内分布一个中心。




图 2: 基础任务：一次 K-means 聚类结果

5.2 十组随机初始化结果

按照实验要求，图 3 报告了十次独立运行结果。每次运行均重新生成随机初始中心，不对结果进行人为筛选。




图 3: 基础任务：十次随机初始化的聚类结果

5.3 附加任务结果

附加任务的数据生成区域如图 4 左侧所示。图中左下角区域的面积明显大于其他区域。右侧为一次标准 K-means 的聚类输出。




图 4: 附加任务：数据区域与聚类结果对比

为了观察随机初始化的影响，图 5 给出了附加任务的十次运行结果。




图 5: 附加任务：十次随机初始化的聚类结果

6 分析与讨论

6.1 基础任务为何通常表现较好

基础任务中的九个区域面积相近、形状规则，并且相互分离。每个区域对应一个中心时，可以得到较小的类内平方距离之和。因此，在大多数随机初始化情况下，中心会逐渐移动到九个小方块附近，聚类结果与肉眼观察较为一致。

6.2 随机初始化的影响

K-means 的初始中心由随机样本决定，因此不同运行之间可能存在差异。算法优化的是目标函数 J ，但该优化过程可能收敛到局部最优解。初始中心分布较均匀时，聚类结果通常较好；如果多个初始中心集中在同一区域，最终结果可能出现某个区域被拆分、相邻区域被合并等现象。因此，实验要求报告十组结果，而不是只展示效果最好的一次，能够更客观地体现算法稳定性。

6.3 附加任务为何难以恢复六个连通区域

附加任务展示了 K-means 的重要局限。人的直观判断依据是白色间隔：只要两个区域不连通，就倾向于将它们视为不同类别。然而，标准 K-means 不会直接识别白色间隔，也不判断区域是否连通。它只关心所有样本到各自中心的平方距离总和。

左下角大区域包含更多样本，覆盖范围也更广。将多个中心分配给该区域，往往能够显著降低目标函数。与此同时，部分较小且相邻的区域可能共享同一个中心。因此，附加任务中常见的现象是大区域被拆分，而两个小区域被合并。该现象不是程序错误，而是目标函数与人的“按连通区域分类”目标不同所导致的。

7 实验总结

本实验完成了 K-means 聚类算法的 MATLAB 实现，并在二维数据上验证了算法的基本过程。通过距离计算、类别分配、中心更新和收敛判断，程序可以在无标签条件下完成聚类。基础任务表明，当各类别规模接近且分离明显时，K-means 通常能够获得较好的结果。十次随机实验说明，算法对初始中心具有一定敏感性。

附加任务进一步说明，K-means 的类别划分依据是类内平方距离，而不是几何连通性。当不同簇的面积和样本数量差异较大时，标准 K-means 可能拆分大区域并合并小区域。因此，在实际应用中需要根据数据分布特征选择合适的聚类方法，不能仅依据类别数量机械地使用 K-means。