



机器学习期末大作业报告

任务三：超导材料临界温度预测

姓名：冯怡然

学号：411434

班级：人工智能特色班

日期：2026 年 6 月

南开大学 机器学习

目录

1	实验目的	2
2	数据说明	2
3	评价指标	2
4	模型原理	3
4.1	回归树与集成学习	3
4.2	ExtraTreesRegressor	3
4.3	LightGBM	3
4.4	模型融合	4
5	实验过程与调参分析	4
5.1	Baseline 与初始模型	4
5.2	ExtraTrees 参数调整	4
5.3	CatBoost 尝试	4
5.4	高温样本加权与分区选择	5
5.5	化学特征工程 v1	5
5.6	化学特征工程 v2	5
5.7	LightGBM 调参	6
5.8	实验结果总表	7
6	最终模型与提交方式	8
7	残差分析	8
7.1	真实值与预测值	8
7.2	残差随温度变化	9
7.3	分温区误差	10
8	实验总结	10

1 实验目的

本实验选择期末大作业任务三：根据超导材料的组成与统计特征预测临界温度 `critical_temp`。该任务属于典型的表格数据回归问题，目标不是单纯追求复杂模型，而是在固定训练数据下通过模型选择、特征工程、调参与残差分析得到一个可解释且效果稳定的回归模型。

本实验的具体目标如下：

1. 建立满足作业接口要求的回归模型，并使用 RMSE、MAE 和 R^2 评价模型效果；
2. 比较 ExtraTrees、HistGradientBoosting、LightGBM、CatBoost、高温样本加权和分区选择等尝试，分析哪些方法有效、哪些方法效果有限；
3. 使用 `unique_m_train.csv` 中的元素组成信息构造化学特征，验证化学先验对材料性质预测的帮助；
4. 特别关注高临界温度材料的误差表现，并通过残差图和分温区指标说明模型在哪些样本上预测较好或较差；
5. 最终得到最佳提交模型：`model_feature_engineered_v2_tuned.joblib`。

2 数据说明

`ml_train.csv` 共包含 17010 条训练样本。每条样本包含 81 个输入特征和目标变量 `critical_temp`。这些输入特征由材料元素属性派生得到，例如原子质量、电负性、热导率和价电子等属性的均值、加权均值、几何均值、熵、范围和标准差等。

`unique_m_train.csv` 与 `ml_train.csv` 逐行对应，包含材料表达式 `material` 以及 H、He、Li、...、Rn 等元素含量列。该文件本身不直接给出新的物理测量量，但提供了材料的元素组成，因此可以进一步构造化学组成特征。例如 `YBa2Cu3O7` 可反映 Y、Ba、Cu、O 的组成比例，而这类信息对识别铜氧化物高温超导体非常重要。

实验采用固定随机种子 `random_state=42`，按 8:2 划分训练子集和验证集：

$$N_{\text{train}} = 13608, \quad N_{\text{valid}} = 3402.$$

所有模型比较均在该划分下进行，避免不同划分导致的结果不可比。

3 评价指标

设真实临界温度为 y_i ，预测值为 $\hat{y}_i$ ，样本数为 N 。本实验主要使用 RMSE、MAE 和 R^2 三个指标。

均方根误差 RMSE 定义为

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}.$$

RMSE 对较大的误差更敏感，因此适合作为主指标，用于检查模型是否在部分材料上出现严重偏差。

平均绝对误差 MAE 定义为

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|.$$

MAE 更直观地表示平均预测偏差，且不如 RMSE 那样强烈放大极端误差。

决定系数 R^2 定义为

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2},$$

其中 $\bar{y}$ 为真实值均值。 R^2 越接近 1，说明模型对目标变量变化的解释能力越强。

4 模型原理

4.1 回归树与集成学习

回归树将特征空间递归划分为若干叶子区域 R_m ，并在每个叶子中输出该区域训练样本目标值的均值：

$$\hat{y}(x) = \sum_{m=1}^M c_m I(x \in R_m), \quad c_m = \frac{1}{|R_m|} \sum_{x_i \in R_m} y_i.$$

单棵树方差较大，因此本实验主要使用树模型集成方法，通过组合多棵树降低预测不稳定性。

4.2 ExtraTreesRegressor

ExtraTrees 通过训练多棵随机化回归树并取平均得到最终预测：

$$\hat{f}_{ET}(x) = \frac{1}{T} \sum_{t=1}^T h_t(x).$$

与普通随机森林相比，ExtraTrees 在节点分裂时不仅随机选择部分特征，还随机生成候选切分阈值，因此不同树之间差异更大。对多棵树取平均后，可以降低方差并提升稳定性。该方法不要求特征标准化，适合本任务中的数值表格特征。

4.3 LightGBM

LightGBM 属于梯度提升树模型。它采用加法模型：

$$F_M(x) = \sum_{m=1}^M \eta f_m(x),$$

其中 f_m 为第 m 棵回归树， η 为学习率。在第 m 轮训练中，模型拟合损失函数的负梯度方向：

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}}.$$

当损失函数为平方误差

$$L(y, F) = \frac{1}{2}(y - F)^2$$

时，负梯度即为当前残差：

$$r_{im} = y_i - F_{m-1}(x_i).$$

因此，LightGBM 可以理解为后续树不断修正前面模型尚未解释的残差。

LightGBM 论文提出了 GOSS 与 EFB 等优化思想 [1]。其中 GOSS 保留梯度绝对值较大的样本，并从小梯度样本中采样一部分，以降低计算量并尽量保留困难样本信息。虽然本任务不是超大规模数据，但 LightGBM 的梯度提升结构和叶子优先生长策略仍适合中等规模表格回归问题。

4.4 模型融合

ExtraTrees 与 LightGBM 的误差来源不同: ExtraTrees 依靠大量随机树降低方差, LightGBM 则通过逐轮拟合残差降低偏差。因此本实验使用验证集搜索线性融合权重:

$$\hat{y} = w\hat{y}_{ET} + (1 - w)\hat{y}_{LGBM}, \quad 0 \leq w \leq 1.$$

最终调参模型中, 最优权重为

$$w_{ET} = 0.30, \quad w_{LGBM} = 0.70.$$

这说明在加入更细的化学特征后, LightGBM 更能利用新增特征中的非线性关系, ExtraTrees 则提供稳定补充。

5 实验过程与调参分析

5.1 Baseline 与初始模型

作业 baseline 使用 HistGradientBoostingRegressor, 验证结果为

$$\text{RMSE} = 10.2201, \quad \text{MAE} = 6.2628, \quad R^2 = 0.9111.$$

首先尝试 ExtraTrees, 是因为它适合表格数据、对特征尺度不敏感, 且通常具有较强鲁棒性。ExtraTrees 单模型验证 RMSE 为 9.6467, 已明显优于 baseline。随后加入 LightGBM, 并在验证集上搜索 ExtraTrees 与 LightGBM 的融合权重, 得到原始特征融合模型 RMSE 为 9.4521。

5.2 ExtraTrees 参数调整

实验尝试调整 ExtraTrees 的 max_features 和树数量。结果如表 1 所示。

表 1: ExtraTrees 参数调整结果

设置	ExtraTrees RMSE	融合 RMSE
默认设置	9.6467	9.5434
max_features=0.6	9.6530	9.5498
max_features=0.8, n_estimators=1000	9.6498	9.5465
max_features=0.9	9.6515	9.5488
max_features=1.0	9.6553	9.5515

可以看到, 继续增加树数量或扩大分裂时可用特征比例没有进一步提升, 说明单纯调 ExtraTrees 的参数并没有对结果有很大影响。

5.3 CatBoost 尝试

为检验是否有比 LightGBM 更适合的提升树模型, 实验尝试 CatBoost。结果如表 2。

表 2: CatBoost 对比实验

模型	RMSE	MAE	R^2
ExtraTrees	9.6467	5.1086	0.9190
CatBoost	10.3831	6.4875	0.9061
ExtraTrees + CatBoost	9.4925	5.2800	0.9215
ExtraTrees + LightGBM	9.4521	5.1990	0.9222

CatBoost 融合后有一定提升,但仍未超过 ExtraTrees + LightGBM,因此最终不采用 CatBoost。

5.4 高温样本加权与分区选择

由于作业要求特别关注高临界温度材料,本实验将 `critical_temp >= 77K` 的样本视为高温样本,并尝试提高这类样本的训练权重。高温加权后,高温区误差有所改善,但整体 RMSE 上升。例如在原始特征模型中,高温样本 RMSE 从 11.6352 降至 11.1885,但整体 RMSE 从 9.4521 升至 9.6335。

随后尝试两类分区策略。第一类是手工阈值切换,即正常区域使用正常模型,高温预测区域使用高温模型。第二类是学习一个硬选择器,判断每个样本应采用正常增强模型还是高温加权增强模型。硬选择器在高温样本上确实更好,高温 RMSE 从正常增强模型的 11.0480 降至 10.3045,但整体 RMSE 为 9.1921,仍不如正常增强模型。这说明分区思想能改善高温材料,但选择器会将部分正常样本错分给高温模型,导致整体误差增加。

因此,高温加权和分区选择被保留为实验分析内容,但不作为最终提交模型。

5.5 化学特征工程 v1

仅使用 `ml_train.csv` 的 81 个统计特征时,不同材料族的元素组成信息被压缩为总体统计量,可能丢失关键化学结构。例如 YBCO 典型组成为 `YBa2Cu3O7-delta`, BSCCO 典型组成为 `Bi2Sr2CaCu2O8+delta`, 铁基超导体常见 `LaFeAsO`、`BaFe2As2` 等族 `[?, ?, ?]`。这些材料族信息与高温超导性质密切相关。

因此,利用 `unique_m_train.csv` 构造第一版化学特征,包括:

- 关键元素含量与占比,例如 Cu、O、Ba、Y、Bi、Sr、Ca、Fe、As 等;
- 关键比例特征,例如 Cu/O、Ba/Cu、Y/Cu、Bi/Sr、Fe/As 等;
- 材料族标记,例如 `is_cuprate`、`is_ybco_like`、`is_bi_based_cuprate`、`is_iron_based`;
- 组成复杂度,例如非零元素数、最大元素占比、最小非零占比、组成熵;
- 稀土元素数量、总含量与占比。

加入 v1 化学特征后,输入维度从 81 扩展到 171,融合模型 RMSE 从 9.4521 降至 9.0342,是早期实验中最明显的提升。

5.6 化学特征工程 v2

在 v1 的基础上,继续从元素组成中派生更细的化学特征。新增特征包括:

- 周期表属性统计：原子序数、原子质量、电负性、元素周期的加权均值、标准差和范围；
- 元素类别统计：过渡金属、稀土、碱土金属、重金属、非金属、卤素等类别的数量、含量和比例；
- 组成均匀性：Herfindahl 指数和组成均匀度；
- 更多关键比例：Sr/Cu、La/Cu、Hg/Cu、Tl/Cu、O/Ba、O/Bi、O/Sr 等；
- 典型材料族距离：与 YBCO、Bi2212、MgB2、FeAs 等典型化学计量比的距离。

例如，若材料中第 k 个元素含量为 a_k ，其原子比例为

$$p_k = \frac{a_k}{\sum_j a_j}.$$

组成熵定义为

$$H = - \sum_k p_k \log p_k,$$

Herfindahl 指数定义为

$$D = \sum_k p_k^2.$$

对于典型化学式距离，以 YBCO 为例，将目标比例记为 q_k ，则距离可写为

$$d_{\text{YBCO}} = \sqrt{\sum_k (p_k - q_k)^2}.$$

这些特征帮助模型更直接地识别材料族与元素配比。

v2 特征将输入维度扩展至 234，默认参数下融合模型 RMSE 进一步降至 8.9771。

5.7 LightGBM 调参

v2 特征加入后，LightGBM 单模型表现明显增强，因此最后集中调节 LightGBM 参数。调参主要考察：

`num_leaves`, `min_child_samples`, `learning_rate`, `n_estimators`, `colsample_bytree`, `reg_lambda`.

搜索结果显示，较大的叶子数、更小的叶子最小样本数和较低学习率更适合当前特征集。最终采用：

`num_leaves = 63`, `min_child_samples = 10`, `learning_rate = 0.02`, `n_estimators = 1200`,

`colsample_bytree = 0.8`, `reg_alpha = 0.05`, `reg_lambda = 0.05`.

最终模型的融合权重为 ExtraTrees 0.30、LightGBM 0.70，验证集 RMSE 降至 8.9479。

5.8 实验结果总表

表 3: 主要实验结果对比

模型或实验阶段	RMSE	MAE	R^2
Baseline HGB	10.2201	6.2628	0.9111
原始特征 ExtraTrees	9.6467	5.1086	0.9190
原始特征 ExtraTrees+LightGBM	9.4521	5.1990	0.9222
ExtraTrees+CatBoost	9.4925	5.2800	0.9215
高温加权增强模型	9.1783	4.9669	0.9266
学习式硬选择器	9.1921	4.9713	0.9264
化学特征 v1	9.0342	4.9628	0.9289
化学特征 v2	8.9771	4.9863	0.9298
化学特征 v2 + LightGBM 调参	8.9479	4.9680	0.9303




图 1: 主要实验阶段 RMSE 对比

从表 3 可以看出, 单纯换模型、调 ExtraTrees 或引入 CatBoost 的收益有限; 高温加权和分区选择可以改善高温样本, 但牺牲整体 RMSE。真正持续有效的改进来自化学特征工程和 LightGBM 参数调整。最终模型在 RMSE 和 R^2 上均为最优, 因此作为最终提交模型。

6 最终模型与提交方式

最终提交模型：

`model_feature_engineered_v2_tuned.joblib`.

该模型使用 `ml_train.csv` 的原始统计特征和 `unique_m_train.csv` 派生的 v2 化学组成特征，内部由 ExtraTrees 与 LightGBM 融合得到。最终验证集结果为：

$$\text{RMSE} = 8.9479, \quad \text{MAE} = 4.9680, \quad R^2 = 0.9303.$$

若评测方提供与测试集逐行对应的元素组成文件，可使用如下命令运行：

```
1 python test_feature_engineered.py --test_data data/ml_test.csv --unique_data data/unique_m_test.csv --model_path model_feature_engineered_v2_tuned.joblib
```

本地实验没有额外 test 集，因此报告中的所有结果均来自固定 8:2 验证集。如果要复现验证的结果，可以执行以下命令。

```
1 python validate_feature_engineered.py --train_data data/ml_train.csv --unique_data data/unique_m_train.csv
```

7 残差分析

7.1 真实值与预测值

图 2 保留了旧化学特征 v1 模型的一张真实值-预测值图，作为对比。图 3 为最终 tuned 模型结果。整体上，大部分样本分布在理想直线附近，说明模型能较好捕捉临界温度变化趋势；但高温区样本仍存在低估现象。




图 2: 旧化学特征 v1 模型：真实值与预测值对比




图 3: 最终模型：真实值与预测值对比

7.2 残差随温度变化

定义残差为

$$e_i = \hat{y}_i - y_i.$$

图 4 显示，在低温和中温区域，残差大多围绕 0 分布；而当真实临界温度超过 77K 后，残差整体偏负，说明模型对高温超导材料仍有低估倾向。这一现象也解释了为什么高温样本加权可以改善高温区误差，但会牺牲整体 RMSE。




图 4: 最终模型：残差随真实临界温度变化

7.3 分温区误差

表 4: 最终模型在不同温度区间的误差

温度区间	样本数	RMSE	MAE	平均残差
$< 10K$	1251	4.9925	2.0179	1.2765
$10-30K$	794	9.2260	5.2335	2.4237
$30-77K$	748	11.7287	7.8397	0.7501
$\geq 77K$	609	10.7761	7.1546	-5.2501




图 5: 最终模型：不同温度区间绝对误差箱线图

表 4 表明，模型在低温样本上预测最好，MAE 仅为 2.0179K；在 30–77K 和高温区间误差较大。高温区平均残差为 -5.2501K，说明最终模型虽然优于旧增强模型，但仍倾向于低估高温材料。这可能与高温样本数量相对较少、材料族分布复杂以及高温超导机理难以仅由组成统计特征完全表达有关。

8 实验总结

本实验最终选择 `model_feature_engineered_v2_tuned.joblib` 作为唯一提交模型。实验过程表明，模型性能提升主要来自两方面：第一，从 `unique_m_train.csv` 中提取元素组成信息，构造材料族、元素比例、组成复杂度和周期表属性统计等化学特征；第二，在新增特征基础上重新调整 LightGBM 参数，使其更充分利用非线性组成关系。

与 baseline 相比，最终模型 RMSE 从 10.2201 降至 8.9479；与原始特征 ExtraTrees+LightGBM 相比，RMSE 从 9.4521 降至 8.9479。HGB、CatBoost、ExtraTrees 单独调参、高温加权和学习式硬选择器均提供了有价值的对照，但没有在整体 RMSE 上超过最终模型。其中，高温加权和硬选择

器说明：若单独关注高温材料，模型可以牺牲部分普通样本性能来改善高温误差；但在综合指标下，最终 tuned 化学特征模型最稳定。

残差分析显示，最终模型对低温材料预测较好，对高温材料仍存在低估倾向。这说明在超导材料临界温度预测中，仅依靠元素组成和统计属性仍难以完全刻画高温超导机理。后续若继续优化，引入晶体结构、压力、掺杂状态或实验条件等更丰富的材料信息可能会进一步提高模型性能。

本次实验通过调参也体会到了机器学习的基本实验方法，看着结果一点点变好的兴奋，也让我对这个学科有了更大的探索欲。

参考文献

- [1] Ke, G. et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS 2017. https://papers.nips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html