

自动化与智能科学概论

Introduction to Automation and Intelligence Science

刘景泰 主编

2024 年 6 月

目录 (CONTENTS)

自动化与智能科学概论	1
目录 (CONTENTS)	2
第 5 章 深度学习	4
5.1 从机器学习到深度学习	4
5.1.1 机器学习的发展历程	4
1. 第一阶段是传统机器学习的发展阶段	4
2. 第二阶段是深度学习的发展阶段	5
3. 第三个阶段是大规模预训练模型的发展阶段	5
5.1.2 深度学习的发展脉络	6
5.2 机器学习的问题与方法	7
5.2.1 机器学习问题	7
1. 统计分类	9
2. 回归分析	9
3. 聚类分析	12
4. 降维	14
5.2.2 机器学习流程	15
5.3 深度学习的基本方法	16
5.3.1 深度学习的典型模型	16
1. 卷积神经网络 (Convolutional Neural Network, CNN)	16
2. 循环神经网络 (Recurrent Neural Network, RNN)	17
3. 长短期记忆模型 (Long Short-Term Memory, LSTM)	17
5.3.2 特征学习	18
5.3.3 深度学习的三个步骤	19
1. 网络结构设计	19
2. 学习目标定义	20
3. 模型训练	20
5.4 深度学习的主要应用	20
5.4.1 深度学习在计算机视觉中的应用	20
1. 场景识别	21
2. 目标检测	21
3. 艺术品风格迁移	22
5.4.2 深度学习在自然语言处理中的应用	22
1. 智能问答系统	22
2. 知识图谱	22
3. 评论观点抽取	23
4. 机器翻译	23
5.4.3 深度学习在多模态任务中的应用	24
5.4.4 深度学习在大规模预训练模型上的应用	25
1. 大语言模型	25
2. 视觉大模型	25
5.5 思考	25
5.6 习题	25

《自动化与智能科学概论》教材初稿

第 5 章 深度学习

深度学习是机器学习的一个重要分支，它通过构建和训练多层神经网络模型，使计算机能够从大量数据中学习复杂的模式和规律。深度学习在图像识别、语音识别和自然语言处理等领域取得了显著成果，助力了人脸识别、图像识别和自然语言处理等技术的迅猛发展。

强化学习也是一种机器学习方法，它通过让智能体与环境互动，学习如何在不同情境下采取最佳行动以最大化累计奖励。强化学习在自动驾驶、游戏 AI 和机器人控制等领域展现了强大的潜力。例如，强化学习算法在围棋和其他复杂游戏中已经超越了人类顶尖选手，并且在机器人控制领域实现了自主学习复杂任务的能力。

深度学习和强化学习是机器学习技术中的左膀右臂，在近 20 年人工智能的高速发展中起到了关键的作用。这两种技术的进步推动了人工智能的发展，使得计算机系统在处理复杂任务和适应新环境方面表现出更高的智能和灵活性。

5.1 从机器学习到深度学习

在本书第一章人工智能的发展历程中，曾经提到人工智能研究的波浪式前进中，机器学习起到了至关重要的作用。机器学习是一种让机器通过数据学习和改进的方法，它使得机器能够根据过去的经验不断优化自己的性能。深度学习作为机器学习的一个分支，通过构建多层次的神经网络模型，使得机器可以从大量数据中提取抽象的特征和模式，从而实现诸如图像识别、自然语言处理等复杂任务。特别是深度学习也是人工智能研究进入第三个高潮的最重要推手。人工智能、机器学习和深度学习的包含关系如下图所示：




图 5-1 人工智能、机器学习和深度学习的关系

5.1.1 机器学习的发展历程

机器学习的发展分为三个阶段，涵盖传统机器学习、深度学习和大规模预训练模型。

1. 第一阶段是传统机器学习的发展阶段

这个阶段主要是基于统计学和数学方法的传统机器学习算法，例如线性回归、支持向量机、决策树、朴素贝叶斯等。早在 20 世纪五六十年代，就已经出现了感知机、逻辑回归和 K-近邻算法等，直到 1980 年

在美国卡内基梅隆大学举行了第一届机器学习研讨会，才标志着机器学习研究作为一个独立方向在全世界范围内的兴起，之后传统机器学习快速发展了 20 多年。

线性回归是一种用于预测连续数值输出的回归算法，它基于对输入特征和输出之间的线性关系进行建模，通过最小化预测值和真实值之间的误差，得到最佳的模型参数。支持向量机是一种二分类的有监督学习算法，在数据集中找到一个最优决策边界，以尽可能最大化两个不同类别之间的间隔，可以高效地处理高维数据，并且具有较强的泛化能力。决策树是一种基于树状结构的分类和回归算法，通过对特征值的逐步划分，构建一个树形的决策流程，易于理解和解释，并且可以处理数值型和离散型数据。朴素贝叶斯是一种基于贝叶斯定理的分类算法。它假设所有特征之间相互独立，通过计算后验概率得到最佳分类结果，计算简单，效果良好。这些传统机器学习算法在数据处理、模式识别、分类、预测等方面都得到了广泛的应用，常用于房价预测、文本分类、股票趋势分析、金融风险评估等任务。

然而，当面对复杂数据和高维特征空间时，传统机器学习方法也展现出一定的局限性。首先面临**维度灾难**：随着特征维度的增加，传统机器学习方法的性能可能迅速下降，这被称为维度灾难。在高维特征空间中，数据变得稀疏，将高维空间的分类结果投影在低维空间中，容易使分类器学习过多的样本数据的异常特征（即噪声），出现过拟合问题，在新数据上的泛化能力不佳。其次**特征工程困难**：在高维特征空间中，如何选择合适的特征并进行特征工程变得更加困难。传统方法需要大量的人工专业知识来进行特征选择和提取，耗时更多，且难以保证最佳性能。此外，高维特征空间中可能存在大量的特征交互关系，利用传统方法难以捕捉，从而限制了模型的性能。

2. 第二阶段是深度学习的发展阶段

深度学习的概念由 Hinton 于 2006 年在《Science》上发表的论文《Deep Learning》中提出，是一种基于深度神经网络的机器学习方法，通过多层次的神经网络模型学习数据的特征和模式。作为新一代机器学习方法，深度学习依托其多层神经网络结构和大规模数据训练的能力，能够自动地从原始数据中学习到高层次的抽象特征，从而在计算机视觉、自然语言处理和语音识别等领域取得了突破，可以说深度学习使得机器学习大放异彩。

卷积神经网络是深度学习最具代表性的方法之一，在图像分类、目标检测和图像生成等等计算机视觉任务上取得了巨大成功；与此同时，循环神经网络作为另一种代表性深度学习方法，因其出色的序列建模能力，在自然语言处理、语言识别、时间序列预测等任务上大放异彩。

深度学习在自然语言处理、图像识别、语音识别等领域取得了重大突破和成功，并得到了广泛应用，例如智能语音助手 Siri、谷歌翻译等。2016 年，谷歌的围棋人工智能 AlphaGo 在比赛中战胜围棋冠军李世石，最终总比分为 4:1。这一事件对于人工智能领域的发展具有重要意义，因为围棋的复杂性和不确定性远超出国际象棋等传统游戏，AlphaGo 的胜利显示了深度学习和强化学习等技术在处理复杂决策问题方面的潜力。这些重要事件，从特定领域的竞技，到自然语言处理，再到复杂决策，凸显了人工智能的不断进步，展示了人工智能在模拟智能能力方面的成功尝试。

3. 第三个阶段是大规模预训练模型的发展阶段

以卷积神经网络、循环神经网络为代表的深度学习模型需要在大量的标注数据上进行训练，对数据品质的依赖性高，且容易出现过拟合问题。由此诞生了预训练模型这一范式。早在 2003 年，Bengio 等人提

出的神经网络语言模型（Neural Network Language Models, NNLM）就已经通过在大量语料上的训练，用词的分布式表示实现对自然语言序列的建模。

预训练模型是指在大规模数据上预先训练好的神经网络模型，然后在大规模未标记数据上进行自监督学习或多任务学习得到（也有部分计算机视觉领域的预训练模型为有监督学习）。对于特定任务，只需要在少量标注样本上进行微调或迁移学习，就可以达到与从头开始训练相当甚至更好的效果，大大减少了训练时间和样本需求。

随着数据和模型规模的大幅增加，大规模预训练模型（以下简称“大模型”）应运而生。大模型的参数通常在十亿以上，模型大小可以达到数百 GB 甚至更大，具有强大的表达能力和学习能力。大模型在自然语言处理领域展现了先进的能力，如问答、机器翻译、摘要提取、代码生成、写作润色等，大模型在计算机视觉领域同样得到了广泛的应用，未来大模型将在产品交互、企业生态、商业模式、个人创作等方面带来深刻的变革。

5.1.2 深度学习的发展脉络

深度学习被学界熟悉并广泛应用之前，绝大多数机器学习和信号处理技术都利用浅层神经网络结构，这些结构一般包含最多一到两层的非线性特征变换。浅层结构包括高斯混合模型（Gaussian mixture model, GMM）、线性或非线性动力系统、条件随机场（Conditional random field, CRF）、最大熵模型（Maximum entropy models, MaxEnt）、支持向量机（Support vector machine, SVM）、逻辑回归（Logistic Regression, LR）、核回归等方法。浅层结构在解决很多简单的、或者限制较多的问题上可以取得良好的效果，但是由于其建模和表示能力有限，在遇到自然语言、视觉图像等数据更复杂的情境时就会遇到各种困难。

作为解决上述困难的有效方法，深度学习起源于对人工神经网络的研究。前馈神经网络或多层感知机^[3]被认为是最早的深度学习（Deep Neural Network, DNN）。具有里程碑意义的反向传播算法（Back-Propagation, BP）流行于 20 世纪 80 年代，是广为人知的一种有效学习网络参数的算法。更高的算力和更好的学习算法也促使了 DNN 的成功。在训练过程中深而宽网络的使用不仅显著提高了 DNN 的建模能力，而且创造出了许多接近的最优配置。2003 年，Yann LeCun 提出的随机梯度下降算法^[4]在大多数训练集较大且冗余的情况下是最有效的算法。但是，在优化目标为非凸函数的深度神经网络中，来自局部最优化或其他最优化问题的挑战普遍存在，当使用批量梯度下降或随机梯度下降的反向传播算法时，目标函数经常会陷入局部最优的情况。随着网络层数的加深，局部最优的情况也就会变得越来越严重，这些挑战通常是学习中面临的主要困难。

2006 年，加拿大多伦多大学 Hinton 提出了一种高效的无监督学习算法叫作深度置信网络^[5]（Deep Belief Network, DBN），其由一组受限玻尔兹曼机堆叠而成，经验性地缓解了与深度模型相关的最优化难题。多层感知机或深度神经网络通过无监督的深度置信网络来进行预训练，然后通过反向传播微调来优化。实验证明使用配置好的深度置信网络来初始化多层感知机的权重取得了比随机初始化的方法更好的结果。除了具有好的初始点，DBN 还有一些颇具吸引力的优点，首先它的学习算法可以有效使用未标注的数据，其次它可以看作是一个概率生成模型，最后过拟合和欠拟合问题都可以通过预训练方式解决。

对于 DNN 学习的高度非凸优化问题，由于优化是从初始模型开始的，所以更好的参数初始化技术将会打造出更好的模型。一种与 DBN 性能相当且有效的初始化方法是对 DNN 进行逐层地预训练，通过将每

两层视为一个除噪自编码器，该除噪自编码器通过将输入节点的随机子集设置为零而进行正则化。另一种方法是使用压缩自编码器，它通过使输入变量具有更好的鲁棒性来达到同样的目的。除了无监督预训练外，有监督的预训练也被证明是很有效的，并且在标记的训练数据充足的情况下比无监督的预训练技术表现得更好。

有研究人员还分析了深度学习在语音和图像中捕获了哪些信息，他们发现，DNN 的隐藏激活向量保留了与多个尺度上的特征向量相似的结构。我们有理由认为，深层网络的强大之处在于它们拥有在提取合适特征的同时做判别的能力。

2009 年，斯坦福大学的李飞飞教授创建了包含超过 1400 万张标注图像的大型数据集 ImageNet^[6]，并在 2010 年启动了 ImageNet 大规模视觉识别挑战赛（ILSVRC）。创立 ImageNet 数据集和挑战赛的目的是评估大型数据集上的图像分类架构，它带来了许多新颖的、强大的、有趣的视觉架构。

2012 年，Hinton 团队在该挑战赛上使用了一个名为 AlexNet 的卷积神经网络^[7]，一举夺得冠军，将错误率从 26%降低到 15%。AlexNet 网络的成功证明了深度卷积神经网络可以很好地处理视觉识别任务，也引发了卷积神经网络在图像识别领域的革命。

此后几年，VGGNet^[8]、GoogLeNet^[9]等卷积架构的网络相继出现，他们的架构不断变大并且也取得了更好的效果，但网络深度的增加也给训练带来了困难。为此，2015 年，何恺明提出了 ResNet^[10]，通过引入残差连接解决了深层网络的训练问题，并且进一步将错误率降低到 3.6%。随后深层次的网络架构井喷式出现并在 ImageNet 图像挑战赛中不断刷新记录，同时也在图像分割、目标检测、人脸识别等图像相关任务上取得了显著的效果。

因在深度神经网络概念和工程上的突破，Yoshua Bengio、Geoffrey Hinton 和 Yann LeCun 三位学者获得了 2018 年图灵奖。

5.2 机器学习的问题与方法

5.2.1 机器学习问题

研究机器学习，首先要对机器学习问题进行定义。如下图所示，我们希望对不同的图像内容识别出其中物体的类别，例如“轮船”、“汽车”、“花朵”。该问题可以转化为一个机器学习 $y=f(x)$ 。其中 x 表示输入的图像特征， f 为预测函数代表机器学习方法， y 为预测函数的输出。采用训练集中的数据对机器学习模型进行优化，期望预测函数能够应用到新的样本中并获得准确的结果。




图 5-2 机器学习问题

机器学习的目的是研究计算机怎样模拟或实现人类的学习行为，以获取新的知识或技能，重新组织已

有的知识结构使之不断改善自身的性能。机器学习方法是人工智能的核心，可以应用到人工智能的各个领域。




图 5-3 机器学习的分类

常见的机器学习方法包括监督学习、无监督学习、半监督学习和强化学习等。

监督学习（Supervised Learning）^[13]：是从标记的训练数据来推断一个功能的机器学习任务。训练数据包括一套训练示例。在监督学习中，每个实例都是由一个输入对象（通常为矢量）和一个期望的输出值（也称为监督信号）组成。监督学习算法是分析该训练数据，并产生一个推断的功能，其可以用于映射出新的实例。目前，监督学习被广泛应用到分类、回归、排序、匹配等多种任务中。

无监督学习（Unsupervised Learning）^[14]：无监督学习的问题是，在未加标签的数据中，试图找到隐藏的结构。因为提供给学习者的实例是未标记的，因此没有错误或报酬信号来评估潜在的解决方案。无监督学习可以缓解人工标注的时间和人工成本。聚类是一种常见的无监督学习算法。

半监督学习（Semi-supervised Learning）：这是一种结合了监督学习和无监督学习的技术。同时使用“少量标记数据”和“大量未标记数据”，缓解人工标注成本的同时，少量标记数据也可以指导学习。半监督学习往往采用一些假设，如平滑假设、聚类假设、流形假设。

强化学习（Reinforced Learning）^[15]：令模型以“试错”的方式进行学习，当模型学习正确的时候给模型一个奖励。强化学习是智能系统从环境到行为映射的学习，学习目标是使奖励信号（强化信号）函数值最大。由于外部环境提供的信息很少，必须靠自身的经历进行学习。通过这种方式，模型在行动-评价的环境中获得知识，改进行动方案以适应环境。马尔可夫决策过程就是一种常见的强化学习方法。

机器学习问题可以根据数据的“有监督/无监督”以及输出数据是“连续/离散”进行分类，分为统计分类、回归分析、聚类分析、降维四类典型问题。有监督的学习方式要求训练集包括输入和输出，也可以说是特征和目标。其中训练集中的目标是人工标注的。区别于有监督的数据，当训练集没有人工标注结果时则是无监督的。

	有监督	无监督
离散	Classification 统计分类	Clustering 聚类分析
连续	Regression 回归分析	Dimensionality reduction 降维

图 5-4 机器学习问题

下面我们对分类、回归、聚类和降维四个典型的机器学习问题，分别介绍其相应的方法。

1. 统计分类

统计分类通过部分已知的离散的观测数据来分析事物的规律，从而对其它数据做出分类。我们以经典的统计分类问题“泰坦尼克号之灾”为例，使用机器学习创建一个模型，预测哪些乘客在泰坦尼克号沉船事故中幸存下来。在这个问题中，我们可以使用乘客数据（如姓名、年龄、性别、社会经济阶层等），建立一个预测模型来分析“什么样的人更有可能生存”。

名字	性别	年龄	同船亲属	船票	金额	舱位	登船港口
Braund	男	22	1	A/5 21171	7.2500	NaN	S
Cumings	女	38	1	PC 17599	71.2833	C85	C
Heikkinen	女	26	0	STON/O2. 3101282	7.9250	NaN	S
Futrelle	女	35	1	113803	53.1000	C123	S
Allen	男	35	0	373450	8.0500	NaN	S

➡ 是否存活?
0 or 1

输入：乘客信息（性别、年龄、客舱等级...）

输出

图 5-5 经典案例：泰坦尼克号之灾

采用统计分类方法可以对此类问题进行建模。通常情况下，数据集有 N 个训练对象 $x_1, \dots, x_n$ 。对于每个对象，提供了一个标签 t_n 描述对象 x_n 属于哪个类别， t_n 是离散的，通常取整数。每个对象都是一个 D 维的特征向量。对于测试集中给定的对象 x_{new} ，分类任务需要预测它的类别 t_{new} 。常用的分类方法有贝叶斯分类器、逻辑回归、K-近邻算法、支持向量机等。

2. 回归分析

回归分析是一种统计方法，它用于研究一个或多个自变量（independent variables）和因变量（dependent variable）之间的关系。回归分析同样是一种监督学习方法，但与分类问题不同的是，它的输出数据是连续的。一个经典的回归分析案例是房价预测问题。通过多项关于房屋信息的特征（如卧室数量、占地面积等）来预测每套房屋的最终价格。



图 5-6 经典案例：房价预测

回归分析是一种预测性的建模技术，通常用于预测分析、时间序列模型以及发现变量之间的因果关系，在许多领域都有着广泛的应用，包括经济学、营销学、社会学、医学、工程学等。常见的回归模型有线性回归、逻辑回归、多项式回归等。

1) 线性回归 (Linear Regression)

线性回归假设因变量与自变量之间呈线性相关，换句话说，因变量可以通过自变量的线性组合来解释。如果回归分析中只包含一个自变量和一个因变量，且二者的关系能够拟合为一条直线（见图 5-6），称为一元线性回归。如果包含两个以上的自变量，且因变量和自变量之间的关系是线性的，称为多元线性回归，拟合的是多维空间中的一个超平面。




图 5-7 一元线性回归示意图

2) 逻辑回归 (Logistic Regression)

逻辑回归是一种用于解决分类问题的统计学和机器学习方法, 尤其适用于二分类问题。尽管它的名字中包含“回归”, 但实际上它是一个分类算法, 用于预测二元分类标签。逻辑回归假设因变量(分类标签)与自变量之间存在线性关系, 并且利用逻辑函数(也称为 Sigmoid 函数)将线性组合映射到[0,1]之间的概率值。




图 5-8 逻辑回归示意图

如图 5-8 所示, 图中散点展示的是学习时长和对应的考试通过情况(只有“通过”和“不通过”两种), 蓝色曲线是通过逻辑回归方法拟合的学习时长和估计的考试通过率之间的关系。

3) 多项式回归 (Polynomial Regression)

许多情况下, 数据的分布难以拟合为线性模型, 常用的做法是多项式回归。多项式回归是一种在线性回归的基础上进行扩展的方法, 用于建模因变量和自变量之间的非线性关系。与简单的线性关系不同, 多项式回归允许自变量的多项式函数来拟合数据, 从而更灵活地捕捉数据之间的复杂关系。




图 5-9 多项式回归和线性回归对比

如图 5-9 所示, 图中的红色直线代表用线性回归拟合数据的结果, 蓝色曲线表示用二次多项式拟合数据的结果, 针对图中数据的分布, 多项式回归对数据的拟合能力更强。

在选择了合适的回归分析方法之后, 需要选择一组合适的参数, 使模型最好地拟合样本数据, 称为参数估计。常用的参数估计方法包括最小二乘法、最大似然法等。

最小二乘法通过最小化误差的平方和寻找数据的最佳函数匹配。利用最小二乘法可以简便地求得未知

的数据, 并使得这些求得的数据与实际数据之间误差的平方和为最小。

最大似然法采用最大似然估计预测结果。当从模型总体随机抽取 n 组样本观测值后, 最合理的参数估计量应该使得从模型中抽取该 n 组样本观测值的概率最大。

3. 聚类分析

“物以类聚, 人以群分”, 在自然科学和社会科学中, 存在着大量的分类问题。聚类分析又称群分析, 它是研究(样品或指标)分类问题的一种统计分析方法。将物理或抽象对象的集合分成由类似的对象组成的多个类的过程被称为聚类^[1]。由聚类所生成的簇是一组数据对象的集合, 这些对象与同一个簇中的对象彼此相似, 与其他簇中的对象相异。

如图 5-10 所示, 左侧一堆水果中包含苹果、香蕉、葡萄, 聚类方法利用不同水果的外观特征将同一类型的水果聚合到一簇中。




图 5-10 聚类分析

在商务上, 聚类能帮助市场分析人员从客户基本库中发现不同的客户群, 并且用购买模式来刻画不同的客户群的特征。在生物学上, 聚类能用于推导植物和动物的分类, 对基因进行分类, 获得对种群中固有结构的认识。聚类在地球观测数据库中相似地区的确定, 汽车保险单持有者的分组, 及根据房子的类型、价值和地理位置对一个城市中房屋的分组上也可以发挥作用。聚类也能用于对网页中的文档进行分类, 以发现信息。

聚类分析的目标是创建满足处于同一组内的对象相似、不同组内对象相异的对象分组。聚类分析起源于分类学, 但是聚类不等于分类。聚类与分类的不同在于, 聚类所要求划分的类是未知的。聚类分析内容非常丰富, 有系统聚类法、有序样品聚类法、动态聚类法、模糊聚类法、图论聚类法、聚类预报法等。在数据挖掘中, 聚类也是很重要的一个概念。传统的聚类分析计算方法主要有如下几种:

1) 划分方法 (partitioning methods)

给定一个有 N 个元组或者纪录的数据集, 分裂法将构造 K 个分组, 每一个分组就代表一个聚类, $K < N$ 。而且这 K 个分组满足下列条件: (1) 每一个分组至少包含一个数据纪录; (2) 每一个数据纪录属于且仅属于一个分组 (注意: 这个要求在某些模糊聚类算法中可以放宽); 对于给定的 K , 算法首先给出一个初始的分组方法, 以后通过反复迭代的方法改变分组, 使得每一次改进之后的分组方案都较前一次好, 而所谓好的标准就是: 同一分组中的记录越近越好, 而不同分组中的纪录越远越好。使用这个基本思想的算法有: K-MEANS 算法、K-MEDOIDS 算法、CLARANS 算法等。

大部分划分方法是基于距离的。给定要构建的分区数 k , 划分方法首先创建一个初始化划分。然后, 它采用一种迭代的重新定位技术, 通过把对象从一个组移动到另一个组来进行划分。一个好的划分的一般准

备是：同一个簇中的对象尽可能相互接近或相关，而不同的簇中的对象尽可能远离或不同。还有许多评判划分质量的其他准则。传统的划分方法可以扩展到子空间聚类，而不是搜索整个数据空间。当存在很多属性并且数据稀疏时，这是有用的。为了达到全局最优，基于划分的聚类可能需要穷举所有可能的划分，计算量极大。实际上，大多数应用都采用了流行的启发式方法，如 K-MEANS 算法、K-MEDOIDS 算法，渐近的提高聚类质量，逼近局部最优解。这些启发式聚类方法很适合发现中小规模的数据库中小规模的数据库中的球状簇。为了发现具有复杂形状的簇和对超大型数据集进行聚类，需要进一步扩展基于划分的方法。

2) 层次方法 (hierarchical methods)

这种方法对给定的数据集进行层次似的分解，直到某种条件满足为止。具体又可分为“自底向上”和“自顶向下”两种方案。例如在“自底向上”方案中，初始时每一个数据纪录都组成一个单独的组，在接下来的迭代中，它把那些相互邻近的组合成一个组，直到所有的记录组成一个分组或者某个条件满足为止。代表算法有：BIRCH 算法、CURE 算法、CHAMELEON 算法等；

层次聚类方法可以是基于距离的或基于密度或连通性的。层次聚类方法的一些扩展也考虑了子空间聚类。层次方法的缺陷在于，一旦一个步骤（合并或分裂）完成，它就不能被撤销。这个严格规定是有用的，因为不用担心不同选择的组合数目，它将产生较小的计算开销。然而这种技术不能更正错误的决定，因此，人们已经提出了一些提高层次聚类质量的方法。

3) 基于密度的方法 (density-based methods)

基于密度的方法与其它方法的一个根本区别是：它不是基于各种各样的距离的，而是基于密度的。这样就能克服基于距离的算法只能发现“类圆形”的聚类的缺点。这个方法的指导思想就是，只要一个区域中的点的密度大过某个阈值，就把它加到与之相近的聚类中去。代表算法有：DBSCAN 算法、OPTICS 算法、DENCLUE 算法等。

4) 基于网格的方法 (grid-based methods)

这种方法首先将数据空间划分成为有限个单元 (cell) 的网格结构，所有的处理都是以单个的单元为对象的。这么处理的一个突出的优点就是处理速度很快，通常这是与目标数据库中记录的个数无关的，它只与把数据空间分为多少个单元有关。代表算法有：STING 算法、CLIQUE 算法、WAVE-CLUSTER 算法等。

很多空间数据挖掘问题，使用网格通常都是一种有效的方法。因此，基于网格的方法可以和其他聚类方法集成。

5) 基于模型的方法 (model-based methods)

基于模型的方法给每一个聚类假定一个模型，然后去寻找能够很好的满足这个模型的数据集。这样一个模型可能是数据点在空间中的密度分布函数或者其它。它的一个潜在的假定就是：目标数据集是由一系列的概率分布所决定的。通常有两种尝试方向：统计的方案和神经网络的方案。

此外，聚类方法还有传递闭包法、布尔矩阵法、直接聚类法、相关性分析聚类、基于统计的聚类方法等。

传统的聚类已经比较成功的解决了低维数据的聚类问题。但是由于实际应用中数据的复杂性，在处理许多问题时，现有的算法经常失效，特别是对于高维数据和大型数据的情况。因为传统聚类方法在高维数据集上进行聚类时，主要遇到两个问题。其一是高维数据集中存在大量无关的属性使得在所有维中存在簇

的可能性几乎为零；其二是高维空间中数据较低维空间中数据分布要稀疏，其中数据间距离几乎相等是普遍现象，而传统聚类方法是基于距离进行聚类的，因此在高维空间中无法基于距离来构建簇。

高维聚类分析已成为聚类分析的一个重要研究方向。同时高维数据聚类也是聚类技术的难点。随着技术的进步使得数据收集变得越来越容易，导致数据库规模越来越大、复杂性越来越高，如各种类型的贸易交易数据、Web 文档、基因表达数据等，它们的维度（属性）通常可以达到成百上千维，甚至更高。但是，受“维度效应”的影响，许多在低维数据空间表现良好的聚类方法运用在高维空间上往往无法获得好的聚类效果。高维数据聚类分析是聚类分析中一个非常活跃的领域，同时它也是一个具有挑战性的工作。高维数据聚类分析在市场分析、信息安全、金融、娱乐、反恐等方面都有很广泛的应用。

4. 降维

在机器学习领域中，高维度的特征由于维度灾难的影响，往往会导致过拟合。此外，由于特征维度间的相关性，高维特征中往往有较多冗余信息，会引入不必要的计算。因此降低特征矩阵维度也是必不可少的。降维是一种提取有效信息的方法，它在某些限定条件下降低变量个数，得到一组“不相关”主变量。具体地，降维将数据的特征维度从高维转换到低维，降低了计算复杂度、减少冗余信息所造成的识别误差、进而可以提高识别的精度^[12]。

数据降维算法是机器学习算法中的大家族，与分类、回归、聚类等算法不同，它的目标是将向量投影到低维空间，可以进行可视化，提升分类、聚类算法的精度，避免维度灾难问题。抽象来看，数据降维就是寻找一个映射函数，将高维向量映射成低维向量。数据降维方法可分为线性降维和非线性降维两大类，具体分类如图 5-11 所示：




图 5-11 数据降维方法分类

主成分分析法是一种常用的线性降维技术。从空间角度来说，主成分分析法的目标在于找到一个投影

矩阵，将数据从高维空间投影到低维子空间中，同时保留尽可能多的信息，或者说让信息损失最小。样本的方差越大表示样本的多样性越好，主成分分析法将数据投影到方差最大的几个相互正交的方向上，以期待保留最多的样本信息。具体而言，主成分分析法首先对特征矩阵进行中心化，即对矩阵按列求均值得到行向量，然后用特征矩阵减去行向量得到矩阵 X 。而后，求矩阵 X 的协方差矩阵，并对协方差矩阵进行特征分解，得到特征值和其对应的特征向量。对特征值按照从大到小的顺序排序，假设取前 k 个特征值，取这 k 个特征值对应的特征向量作为一组基向量。最后，用矩阵 X 和基向量相乘，就可以把矩阵 X 变换到维度更低的子空间，得到新的矩阵 Y ，它就是降维后的矩阵。

非线性降维方法是解决线性降维方法（如主成分分析法），但无法处理非线性数据问题的关键方法。非线性降维方法通过非线性变换将高维数据映射到低维空间，保留数据的局部和全局结构。非线性降维的常用方法有 t 分布随机近邻嵌入（t-SNE）和局部线性嵌入（Locally Linear Embedding, LLE）。 t 分布随机近邻嵌入（t-SNE）通过将高维数据映射到低维空间，保持数据样本之间的相似度。t-SNE 利用 t 分布来衡量数据样本之间的相似性，使得映射后的数据样本可以保留原始数据中的局部结构。t-SNE 在数据可视化和聚类分析中有着广泛的应用，特别适用于高维数据的可视化展示。LLE 通过局部线性近似来映射高维数据到低维空间，每一个数据点都可以由其近邻点的线性加权组合构造得到。LLE 首先寻找每个样本点的 k 个近邻点（ k 是一个预先给定的值），然后通过每个样本点的近邻点计算出该样本点的局部重建权值矩阵。最终，由该样本点的局部重建权值矩阵和其近邻点计算出该样本点的输出值定义一个误差函数，通过线性组合得到映射后的低维表示。LLE 在保持数据的全局和局部结构上具有很好的性能，特别适用于流形结构数据的降维。

线性降维方法计算简单、可解释性强、对数据结构的保持较好，适用于处理大规模数据，例如图像压缩和特征选择。而非线性降维方法可以捕捉数据中的非线性关系，对复杂数据具有较好的表现，它适用于数据可视化和聚类分析，特别适用于处理流形结构数据。在不同应用场景下需要根据数据的特点选择合适的方法。

5.2.2 机器学习流程

一个完整的机器学习流程包含数据处理、分析方法和计算、结果的评估和利用等多个步骤。如图 5-12 所示，机器学习流程包含模型训练和模型测试两部分。




图 5-12 机器学习流程

在模型训练中, 首先对训练集数据提取特征。机器学习往往需要处理不同模态的输入数据, 对于图像数据需要提取图像特征, 常见的图像特征有原始像素 (Raw pixels)、直方图 (Histograms)、全局特征信息 (GIST descriptors)、尺度不变特征变换 (SIFT) 等。对于文本类输入, 常见的提取文本特征方法有词袋模型 (BoW)、TF-IDF (Term Frequency-Inverse Document Frequency)、词嵌入 (Word Embeddings)、N-gram 模型等。

在特征提取后, 使用训练数据集来训练模型。在训练过程中, 模型会尝试找到最优的参数值, 使得模型在训练数据集上的预测结果与训练集标签之间的差距最小。在测试过程中, 将测试集数据的特征输入到训练后的模型中预测结果。通过模型测试, 我们可以了解模型是否过拟合或者欠拟合, 以及模型在未知数据上的性能如何。

5.3 深度学习的基本方法

深度学习的核心思想是通过构建多层神经网络模型来模仿人脑神经元之间的连接, 以解决各种复杂的任务。深度学习模型的多层神经网络结构使其能够从原始数据中提取更加抽象的特征表示, 从而在计算机视觉、语音识别、自然语言处理等领域取得了一系列突破性成果。

5.3.1 深度学习的典型模型

1. 卷积神经网络 (Convolutional Neural Network, CNN)


卷积神经网络是一种在计算机视觉领域取得巨大成功的深度学习架构^[7], CNN 通过卷积层、池化层和全连接层实现对图像的特征提取和模式识别。

卷积层作为 CNN 的核心, 将一组卷积核与特定的局部区域进行运算, 从而实现特征的提取。该操作能够有效捕捉图像中边缘、纹理等特征, 通过组合多个卷积核提取出的不同特征, 可以形成卷积特征图。

为了减少模型的计算复杂度和存储消耗, CNN 引入了池化层, 在减小卷积特征图尺寸的同时保留关键信息, 进而帮助提高模型的计算效率和泛化能力。常见的池化操作包括最大池化和平均池化。

在卷积层和池化层之上, 通常会添加全连接层将提取到的特征映射到输出空间, 处理分类、回归等任务。

CNN 的主要优势体现在三个方面: (a) 通过局部连接和权值共享机制, 有效减少了模型的参数数量, 提高了模型的泛化能力。其中, 局部连接机制是指将卷积核与不同的局部区域进行运算; 权值共享机制是指同一个卷积核使用相同的权重在不同的局部区域进行运算。(b) 由于卷积核的权值共享特性, CNN 具有平移不变性, 使其能够在图像的不同位置检测相同模式的特征。(c) 通过逐层堆叠, CNN 能够从底层的边缘、纹理等低级特征逐渐提取更抽象的高级特征, 实现了多层次的抽象和表征。这些优势使得 CNN 在图像分类、目标检测、人脸识别等任务中展现出强大的性能, 成为深度学习领域的重要支柱。

图 5-13 卷积神经网络 CNN^[18]

2. 循环神经网络 (Recurrent Neural Network, RNN)

循环神经网络是一种主要用于处理文本、语音、时间序列等序列数据的深度学习方^[16]。在处理序列数据时，该网络能够有效捕捉序列中的时间依赖关系和上下文信息。因此，RNN 被广泛应用于语言建模、机器翻译、股票价格预测、天气预测等任务，并取得了重大突破。

RNN 的核心思想是通过引入循环结构，将网络中某时刻的输出作为下一时刻的输入。具体来说，假设在 $t-1$ 时刻的隐藏状态为 h_{t-1} ，在 t 时刻的输入为 x_t ，则 t 时刻的隐藏状态可以通过公式 5.1 计算得到：

$$h_t = \sigma(W_x \cdot x_t + W_h \cdot h_{t-1} + b) \quad (5.1)$$

其中， W_x 和 W_h 是可学习的权重参数， b 是偏置项， $\sigma(\cdot)$ 代表激活函数，通常为 Sigmoid、Tanh 等。这里，隐藏状态可以看作是网络在某时刻的“记忆”，通过在不同时刻间传递隐藏状态，RNN 可以将历史信息融合到后续的计算中。这种记忆能力使得 RNN 能够处理各种序列数据中的时间相关性，如自然语言中的序列结构、音频信号中的语调变化等。

尽管 RNN 在处理序列数据上具有很多优势，但也存在两方面的不足：(a) RNN 容易面临梯度消失和梯度爆炸问题，限制了其在长序列上的训练效果。(b) 由于循环结构的限制，RNN 很难并行处理数据，导致训练速度较慢。

3. 长短期记忆模型 (Long Short-Term Memory, LSTM)

长短期记忆模型^[17]是一种特殊的循环神经网络变体，主要用于解决传统 RNN 中的梯度消失和梯度爆炸问题，使得模型可以更好地捕捉长期依赖关系。LSTM 在序列建模、语言生成、机器翻译等领域表现出色，其核心在于引入了门控机制，使得模型能够选择性地记忆和遗忘信息。具体地说，每个 LSTM 单元由输入门 (Input Gate)、遗忘门 (Forget Gate) 和输出门 (Output Gate) 三个关键部分组成，具体计算过程如下：

$$i_t = \sigma(W_{xi} \cdot x_t + W_{hi} \cdot h_{t-1} + b_i) \quad (5.2)$$

$$f_t = \sigma(W_{xf} \cdot x_t + W_{hf} \cdot h_{t-1} + b_f) \quad (5.3)$$

$$o_t = \sigma(W_{xo} \cdot x_t + W_{ho} \cdot h_{t-1} + b_o) \quad (5.4)$$

$$\tilde{c}_t = \tanh(W_{xc} \cdot x_t + W_{hc} \cdot h_{t-1} + b_c) \quad (5.5)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad (5.6)$$

$$h_t = o_t \odot \tanh(c_t) \quad (5.7)$$

其中， x_t 是第 t 时刻的输入， h_{t-1} 是第 $t-1$ 时刻的隐藏状态， $\sigma(\cdot)$ 和 $\tanh(\cdot)$ 分别代表 Sigmoid 和 Tanh 激活函数， $\odot$ 表示按位相乘。 i_t ， f_t 和 o_t 分别代表输入门、遗忘门和输出门。

尽管 LSTM 在处理序列的长期依赖关系方面具有优势，但在一些复杂任务中，仍然可能受到过拟合、难以并行处理数据导致训练速度较慢等问题的困扰。此外，与 RNN 模型相比，LSTM 的参数较多，通常需要更多的计算资源和数据来训练。

5.3.2 特征学习

特征学习是机器学习中的一个关键环节，其旨在将原始数据转化并映射到一个更有区分度的、抽象性的特征空间，以便于机器学习算法能够更好地理解和处理数据。通常情况下，原始数据是高维、复杂且冗余的，而特征学习的过程能够自动地从数据中发现有价值的信息，提取出更有区分度的特征，从而提升模型的性能和泛化能力。

在传统的机器学习方法中，通常需要手动设计特征，即利用专家的领域知识和经验进行特征的选择、构造和提取。例如，在垃圾邮件分类任务中，传统机器学习方法需要手工构建词频、特殊关键词、邮件长度、链接数量等特征，并基于这些特征将邮件文本转化为特征向量，然后使用朴素贝叶斯、支持向量机等算法进行垃圾邮件和非垃圾邮件的分类。

虽然手工构建特征可以将领域专家的知识和洞察力应用于特征的设计过程，确保提取的特征与任务相关，有助于提高模型的性能，但是手工构建特征仍存在如下不足：

- 人类倾向于选择容易理解和解释的特征，而忽略了一些对模型性能有益的隐含特征，并且难以捕捉数据中复杂的模式和关系，使得模型性能受限。
- 手工构建特征需要耗费大量时间和人力。对于大规模数据集或复杂任务，特征的设计和提取会变得异常繁琐。
- 手工构建的特征难以适应不同的数据分布或任务。当任务变化或数据分布不稳定时，手工构建的特征可能无法提供足够的灵活性与泛化性。

为了解决上述问题，深度学习方法利用多层神经网络结构和梯度下降方法来实现特征的自动学习，而不需要人为干预。例如，在上述垃圾邮件分类任务中，深度学习模型可以通过端到端的方式从原始文本中学习出高层次的特征表示，如语义信息、上下文关系等，从而更准确地实现邮件分类。总的来说，深度学习模型在特征抽取方面优势如下：

- 多层抽象：通过堆叠多个隐藏层实现逐层的特征提取，从简单到复杂地捕捉数据的抽象特征，其中低层次的特征可以捕获数据的原始信息，而高层次的特征则能够捕获数据中的更抽象、更复杂的模式。
- 端到端学习：采用端到端学习，通过构造损失函数来度量模型的预测输出与实际标签之间的误差，并基于损失函数的梯度逐层反向更新各层的权重。在这个过程中，模型可以自动挖掘数据的非线性关系和隐含信息，并自适应地从数据中学习特征表示而无需人工干预，显著降低了模型开发和应用过程中的人工成本。
- 泛化能力强：利用大规模数据进行训练，能够确保模型能够在充分学习不同情况下的数据模式，而不仅仅局限于特定的示例，提高模型的泛化能力。

5.3.3 深度学习的三个步骤

深度学习包括网络结构设计、学习目标定义和模型训练三个步骤。本节将围绕这三个步骤展开介绍。

1. 网络结构设计

人工神经元是多层神经网络最基础的组成单元，最早于 1943 年由 McCulloch 和 Pitts 提出。人工神经元模拟了大脑神经元的工作机制，通过适当的权重和激活函数，人工神经元可以有效学习到输入信号间的模式和关联。具体地说，如公式 5.8 所示，人工神经元接收多个输入信号 $\{x_1, x_2, \dots, x_N\}$ ，按照不同的权重 $\{w_1, w_2, \dots, w_N\}$ 对不同的输入信号进行加权求和，并引入偏置项 b 对加权求和的结果进行调节。随后，加权求和的结果会通过激活函数 $\sigma(\cdot)$ 进行转换，引入非线性特性，常见的激活函数包括 Sigmoid、ReLU、Tanh 等。激活函数的输出即为神经元的输出，其可以传递给下一层的神经元或作为模型的输出。

$$y = \sigma \left(\sum_{i=1}^N w_i x_i + b \right) \quad (5.8)$$

为解决复杂的应用问题，通常需要将多个神经元排列起来作为一层，然后逐层叠加，构建多层神经网络。如图 5-1 所示，多层神经网络包括一个输入层、一个或多个隐藏层、以及一个输出层。其中：

输入层是神经网络的第一层，用于接收原始数据特征。这里，每个输入神经元代表数据的一个特征，例如在处理图像时，每个输入神经元可以对应图像的一个像素。

隐藏层是输入层和输出层之间的一层或多层神经结构，其作用是在数据的输入和输出之间进行特征变换和抽象。每个隐藏层都有一定数量的神经元，每个神经元将输入信号加权后通过激活函数进行转换。

输出层是神经网络的最后一层，产生最终的预测结果或输出。输出层的神经元数量取决于问题的类型，例如，分类问题可能有与类别数量相等的输出神经元，回归问题可能只有一个输出神经元。




图 5-14 多层神经网络的结构示意图

通过堆叠多个隐藏层，可以构成超深网络，例如计算机视觉领域常用的 ResNet^[10]网络具有 152 层的深度。随着网络深度的增加，网络可以提取更复杂的抽象特征和模式，以便更好地适应复杂的数据，这有助于模型在更高层次上实现数据表示和分析。

2. 学习目标定义

在深度学习中，需要定义学习目标（即损失函数）来度量模型的预测输出与实际标签之间的差异，从而指导模型调整权重和参数以最小化这种差距。具体地说，在优化过程中，损失函数的梯度信息可以告诉模型应该在哪个方向上调整参数，以使预测结果逐渐逼近真实标签。这个过程是迭代的，直到模型达到一定的收敛条件或训练迭代次数。

根据任务的不同，损失函数可以有所不同。例如，均方误差（Mean Squared Error, MSE）是一种适用于回归问题的损失函数，通过计算预测值与真实值之间的平方差的平均值，以量化预测误差的平均程度；交叉熵（Cross-Entropy）是一种广泛应用于分类问题的损失函数，通过计算每个真实标签在预测分布中的对数概率的累加值，来量化预测与输出之间的差异。定义合适的学习目标，可以使模型更好地适应训练数据，提高在新数据上的泛化能力。

3. 模型训练

基于设计好的网络结构与学习目标，需要通过模型训练来找到一组最优的网络参数。考虑到深度学习模型的参数空间具有连续、非线性、维度巨大、以及存在多个局部最优解等特点，训练过程通常使用梯度下降法，根据反向传播算法计算梯度并更新参数。

其中，梯度下降法（Gradient Descent Method）首先随机初始化一组网络参数 θ^0 ，随后计算该参数下模型在训练样本集合上的损失 $\mathcal{L}(\theta^0)$ 以及参数对该损失的梯度 $\nabla\mathcal{L}(\theta^0)$ ，并利用梯度对模型参数进行更新：

$$\theta^1 = \theta^0 - \eta \nabla\mathcal{L}(\theta^0), \quad (5.9)$$

其中， θ^1 代表第一次更新后的参数， η 为学习率（Learning Rate）。随后，模型训练过程不断迭代执行上述步骤，直到找到一组最优的模型参数 θ^F 。

梯度下降法又包括批量梯度下降（Batch Gradient Descent, BGD）、随机梯度下降（Stochastic Gradient Descent, SGD）、以及小批量梯度下降（Mini-Batch Gradient Descent, MBGD）的三种形式。批量梯度下降法在每次迭代时需要利用全部训练样本计算损失和梯度，能够更准确地向全局最优点的方向优化，但是随着训练样本数量的增加，该方法的训练速度会非常慢；随机梯度下降法在每次迭代时仅利用一个样本计算损失和梯度，使得参数更新速度和模型收敛快，但容易陷入局部最优，导致模型性能下降；为了能够综合利用批量梯度下降和随机梯度下降的优势，小批量梯度下降法每次迭代时随机选取M个训练样本计算模型损失和梯度。

在梯度下降法中，如何高效地计算每个参数的梯度是一个重要的问题。常用的梯度计算方法为反向传播算法，该方法的数学理论基础为导数的链式法则。具体来说，模型第一层参数的梯度可以由第一层特征表示的梯度计算得到，而第一层特征表示的梯度又可以通过第二层特征表示的梯度计算得到。以此类推，可以发现每层网络的梯度均由其下一层网络的梯度加权得到。

5.4 深度学习的主要应用

5.4.1 深度学习在计算机视觉中的应用

在传统计算机视觉任务中，特征选择和提取往往依赖手动操作，主要基于图像进行浅层次的特征处理，

如边缘检测、角点检测、直线检测等。然而，这些方法在面对复杂场景和大量数据时往往力不从心。

深度学习技术通过构建多层神经网络模型，可以自动学习和提取高层次的语义特征，实现更加高效、准确的图像处理任务。卷积神经网络（CNN）是一种深度学习模型，被广泛应用于计算机视觉领域，如图像分类、目标检测和语义分割等。

1. 场景识别

通过对网络进行训练，它可以自动学习图像中的特征，并在给定一张图像时，识别出图像所属的场景类型，如建筑物、自然风景、人物等。场景识别在许多领域中都有重要的应用，如智能监控系统、自动驾驶汽车和图像搜索引擎等。



图 5-15 场景识别^[19]

2. 目标检测

卷积神经网络可以用于目标检测，即在图像中定位和标记出物体的位置。通过在网络中添加额外的层和技巧，可以使网络能够同时输出物体的类别和位置信息。目标检测在计算机视觉领域具有重要的实际应用，如人脸识别、车辆检测和物体跟踪等。




图 5-16 目标检测^[20]

3. 艺术品风格迁移

卷积神经网络还可以用于将一幅图像的风格应用到另一幅图像上，从而实现艺术品风格迁移。该应用利用了卷积神经网络中的特征提取能力，可以将一幅图像的风格特征与另一幅图像的内容特征进行合成，生成具有原始图像内容但具有新风格的图像。这种应用在艺术创作和图像处理中具有很大的潜力。




图 5-17 艺术品风格迁移^[21]

5.4.2 深度学习在自然语言处理中的应用

自然语言处理从计算语言学发展而来，是一门工程学科，致力于使计算机对人类自然语言进行理解、解释和生成。如今，深度学习已经在自然语言处理任务中得到广泛应用，包括智能问答系统、知识图谱、评论观点抽取、机器翻译等。

1. 智能问答系统

智能问答系统通过理解用户提出的问题，并从已知的知识库或互联网上的信息中提取正确的回答。这些系统利用自然语言处理和机器学习技术对问题进行语义理解、信息检索和答案生成。智能问答系统在助手应用程序、虚拟助手和在线知识库中被广泛使用。在搜索引擎中，问答系统能够直接回答用户的问题，提供更精确的搜索结果。在智能助理和虚拟机器人中，问答系统能够与用户进行对话，并提供个性化的服务和建议。在教育和培训领域，问答系统能够帮助学生解答问题，提供学习资源和指导。

2. 知识图谱

知识图谱是一个结构化的知识数据库，它将实体、属性和关系组织在一起，形成一个知识网络。知识图谱的发展可以追溯到上世纪 60 年代，但直到近年来，随着大数据和人工智能的快速发展，知识图谱才得到了广泛的关注和应用。自然语言处理和深度学习技术可以用于实体识别和关系抽取，从文本中识别出具体的实体，例如人物、地点或组织；并提取出实体之间的关系，将它们组织成一个图谱。深度学习技术可以用于知识图谱的构建、推理和补全，通过学习大量的数据来自动地构建知识图谱的结构，通过推理来发现实体之间的隐藏关系和属性，或通过学习已有的知识图谱来预测新的实体和关系。知识图谱被广泛应用于搜索引擎、智能助手、推荐系统等领域，以帮助用户更好地获取和理解信息。代表应用为谷歌知识图谱。

3. 评论观点抽取

指从文本数据中提取出评论者的观点或意见，例如影评、购物评价、餐厅评价等。传统的方法通常需要手动编写规则来进行抽取，但这种方法往往不够灵活，难以适应不同类型的评论和不同的语言。而深度学习可以通过训练模型来自动学习抽取规则，从而更好地适应不同的情况。

结合深度学习和自然语言处理技术，可以构建评论观点抽取系统，通过训练模型，从大量的评论文本中学习观点的模式和规律，并且可以自动地从新的评论文本中提取出观点。在评论观点抽取中，常用的深度学习算法包括文本分类、情感分析和实体识别等。文本分类是将评论分为不同的类别，例如正面评价和负面评价。情感分析是判断评论中的情感倾向，例如评论是积极的还是消极的。实体识别是识别评论中提到的具体实体，例如产品名称、品牌等。




图 5-18 评论观点抽取^[22]

在实际应用中，深度学习在商品评论抽取方面已经取得了许多成功的案例。例如，一些电商平台可以通过深度学习算法自动抽取商品评论中的关键信息，帮助用户更好地了解产品的优点和缺点。另外，一些社交媒体分析工具也可以利用机器学习来抽取用户对商品的评价和意见，帮助企业了解用户需求和市场趋势。

4. 机器翻译

机器翻译是指通过计算机自动将一种语言的文本转换成另一种语言的文本。传统的机器翻译方法主要依赖规则进行翻译，但这种方法往往需要人工编写大量的规则，不够灵活。相比之下，深度学习方法则通过训练模型进行翻译。这些模型可以通过大量的双语平行语料进行训练，学习源语言和目标语言之间的对应关系。深度学习方法能够适应不同的语境和语法结构，具有更高的翻译质量和效率。




图 5-19 机器翻译^[23]

常用方法包括统计机器翻译 (SMT) 和神经机器翻译 (NMT)。统计机器翻译方法基于统计模型, 通过计算翻译假设的概率来选择最佳的翻译结果。神经机器翻译方法则利用深度神经网络进行翻译, 通过编码-解码结构来实现翻译过程。与 SMT 相比, NMT 在翻译质量上通常表现更好。由于神经网络可以更好地捕捉句子的上下文信息, NMT 系统能够处理更复杂的语言结构和长距离依赖关系。此外, NMT 还具有端到端的优势, 可以减少翻译过程中的错误传播。

深度学习在机器翻译方面的应用还包括语言模型的使用, 用于解决词义消歧和上下文问题。此外, 还有一些技术被用于改进机器翻译的性能, 如迁移学习、序列到序列模型等。

总而言之, 用深度学习算法进行机器翻译, 可以提高翻译准确性和流畅度, 使得机器翻译在实际应用中更加可行和实用。

5.4.3 深度学习在多模态任务中的应用

多模态深度学习, 旨在训练深度学习模型来处理和发现不同模态的数据之间的关系, 通常包括图像、音频、文本等。其中, 将图像信息与文本信息结合, 是多模态深度学习最常见的研究方向之一。

人类可以将图像中的视觉信息自动建立关系, 进而感知图像的高层语义信息, 但是计算机只能提取图像的特征信息, 无法向人类大脑一样生成高层语义信息, 这就是“语义鸿沟问题”。

借助深度学习算法, 可将图像转化为相应的文字描述, 这是一种结合计算机视觉和自然语言处理的应用。该任务一般分为两个部分: 图像编码和文本生成。一种常见的方法是首先使用卷积神经网络 (CNN) 提取图像的特征, 然后使用循环神经网络 (RNN) 来逐步生成描述图像的文字。




牙膏盒组成的坦克



一个戴眼镜的猫正在学习



一本关于中医的书籍



一本关于爱情的西方名著

图 5-20 用文字表达图像^[24]

图像描述技术在很多领域都有应用, 比如自动图像标注、图像搜索和辅助视觉障碍人士等。它可以帮助计算机理解图像的内容, 并将其转化为易于理解的文字描述, 从而提供更好的用户体验和辅助功能。

5.4.4 深度学习在大规模预训练模型上的应用

当前的主流大规模预训练模型集中在语言大模型和视觉大模型两类。

1. 大语言模型

代表性的模型包括 GPT-4、PaLM、LlaMA、ChatGLM、通义千问等。这些模型基于庞大的文本数据集训练而成，能够理解和生成人类语言。

大语言模型广泛应用于自然语言处理任务如机器翻译、文本摘要、对话系统等，并深度融入金融、法律、教育、医疗等领域，有效降低知识获取成本，提升工作效率。例如，借助其强大的生成能力，用户可轻松生成博客文章、文献摘要、问卷调查、社交媒体帖子等多样化文本内容。此外，大模型还能生成 Java、Python、C# 等编程语言的代码，助力调试现有代码和生成注释文档，显著提升开发效率。各行业也可利用特定行业数据和知识库对通用领域大模型进行定制化训练和优化，构建具有高度领域专业性和实用性的垂直领域大模型。

2. 视觉大模型

随着 Transformer 架构在自然语言处理领域的成功，许多研究者开始将此架构应用于视觉领域。通过图像数据的预训练，这些模型获得了对图像的理解和生成能力。

代表性成果有，Vision-Transformer 使用 Transformer 架构代替传统的 CNN 架构，在图像分类领域取得了优异的效果；MAE 提出的自监督训练方法为大规模图像数据的预训练奠定了基础；CLIP 模型通过联合文本和图像特征的训练，促进了多模态大模型的发展；此外，结合扩散模型的 Stable Diffusion 模型根据输入的文字描述生成高质量图像，用户还可个性化定制图片风格，极大地丰富了创作方式。

除语言和视觉大模型外，多模态融合是大模型未来发展的重要趋势。这种融合不仅可以处理单一数据类型的任务，还能联系和整合不同的数据类型（文字、图像、语音和视频），为解决真实场景下的复杂问题提供支持，进一步推动通用人工智能技术的落地。

5.5 思考

【思考 5.1】深度神经网络和一般神经网络的最重要区别在哪里？

【思考 5.2】相较于传统的特征学习方法，深度学习和大规模预训练模型为什么能更好地理解数据？

【思考 5.3】比较深度学习模型与传统机器学习模型在处理高维数据时的优缺点。

【思考 5.4】常见的机器学习方法有哪些？试分析每种方法的特点。

【思考 5.5】预训练模型如何提升深度学习模型的性能？请结合具体案例说明预训练模型在实际应用中的优势。

【思考 5.6】对比分析批量梯度下降（BGD）、随机梯度下降（SGD）、和小批量梯度下降（MBGD）的优缺点。

5.6 习题

【作业 5.1】分析深度神经网络的几种典型网络结构。

【作业 5.2】一般神经网络适用于简单的分类、回归等任务，如房价预测、简单的图像分类等。而深度神经网络广泛应用于图像识别、语音识别、自然语言处理、自动驾驶、医学图像分析等复杂领域。观察生活中有哪些实际问题可以用深度学习技术来解决，并简述你的方案。

【作业 5.3】深度学习技术在自然语言处理（NLP）中的应用有哪些？请结合具体案例进行分析。

参考文献

- [1] RUSSELL S J, NORVIG P. Artificial Intelligence: A Modern Approach (Fourth Edition) [M]. Hoboken, New Jersey: Prentice Hall, 2019.
- [2] MCCARTHY J, MINSKY M L, ROCHESTER N, et al. A Proposal for The Dartmouth Summer Research Project on Artificial Intelligence, August 31, 1955[J]. AI Magazine, 2006, 27(4): 12-12.
- [3] ROSENBLATT F. The Perceptron: A Probabilistic Model for Information Storage and Organization in The Brain[J]. Psychological Review, 1958, 65(6): 386.
- [4] BOTTOU L, CUN Y. Large Scale Online Learning[J]. Advances in Neural Information Processing Systems, 2003, 16.
- [5] HINTON G E, OSINDERO S, TEH Y W. A Fast Learning Algorithm for Deep Belief Nets[J]. Neural Computation, 2006, 18(7): 1527-1554.
- [6] DENG J, DONG W, SOCHER R, et al. ImageNet: A Large-Scale Hierarchical Image Database[C]//2009 IEEE Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2009: 248-255.
- [7] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet Classification with Deep Convolutional Neural Networks[J]. Advances in Neural Information Processing Systems, 2012, 25.
- [8] SIMONYAN K, ZISSERMAN A. Very Deep Convolutional Networks for Large-Scale Image Recognition[C]//3rd International Conference on Learning Representations. 2015.
- [9] SZEGEDY C, LIU W, JIA Y, et al. Going Deeper with Convolutions[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 1-9.
- [10] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [11] JAIN A K, MURTY M N, FLYNN P J. Data Clustering: A Review[J]. ACM Computing Surveys (CSUR), 1999, 31(3): 264-323.
- [12] KEOGH E, CHAKRABARTI K, PAZZANI M, et al. Dimensionality Reduction for Fast Similarity Search in Large Time Series Databases[J]. Knowledge and Information Systems, 2001, 3: 263-286.
- [13] KOTSIANTIS S B, ZAHARAKIS I, PINTELAS P. Supervised Machine Learning: A Review of Classification Techniques[J]. Emerging Artificial Intelligence Applications in Computer Engineering, 2007, 160(1): 3-24.
- [14] TYAGI K, RANE C, SRIRAM R, et al. Unsupervised Learning[M]//Artificial Intelligence and Machine Learning for Edge Computing. Academic Press, 2022: 33-52.
- [15] GAO Y, CHEN S F, LU X. Research on Reinforcement Learning Technology: A Review[J]. Acta Automatica Sinica, 2004, 30(1): 86-100.
- [16] MITTAL S, LAMB A, GOYAL A, et al. Learning to Combine Top-Down and Bottom-Up Signals in Recurrent Neural Networks with Attention Over Modules[C]//International Conference on Machine

Learning. PMLR, 2020: 6972-6986.

- [17] HOCHREITER S, SCHMIDHUBER J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [18] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-Based Learning Applied to Document Recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [19] ZHOU B, LAPEDRIZA A, KHOSLA A, et al. Places: A 10 Million Image Database for Scene Recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(6): 1452-1464.
- [20] POTDAR K, PAI C D, AKOLKAR S. A Convolutional Neural Network Based Live Object Recognition System As Blind Aid[J]. Arxiv Preprint Arxiv:1811.10399, 2018.
- [21] WANG X, OXHOLM G, ZHANG D, et al. Multimodal Transfer: A Hierarchical Deep Convolutional Neural Network for Fast Artistic Style Transfer[C]//Proceedings of The IEEE Conference on Computer Vision and Pattern Recognition. 2017: 5239-5247.
- [22] 储哲, 王璐, 润宇等. 情感分析技术在美团的探索与应用[EB/OL]. 美团技术团队, [2021-12-09]. <https://tech.meituan.com/2021/12/09/meituan-aspect-based-sentiment-analysis-daodian.html>
- [23] SUTSKEVER I, VINYALS O, LE Q V. Sequence to Sequence Learning with Neural Networks[J]. Advances in Neural Information Processing Systems, 2014, 27.
- [24] SHAN B, YIN W, SUN Y, et al. Ernie-Vil 2.0: Multi-View Contrastive Learning for Image-Text Pre-Training[J]. Arxiv Preprint Arxiv:2209.15270, 2022.