

自动化与智能科学概论

Introduction to Automation and Intelligence Science

刘景泰 主编

2024 年 6 月

目录 (CONTENTS)

自动化与智能科学概论	1
目录 (CONTENTS)	2
第 8 章 大数据智能	3
8.1 大数据的概念与意义	3
8.1.1 何为大数据	3
8.1.2 大数据的特征	4
8.1.3 大数据思维	5
8.1.4 大数据的意义	6
8.2 大数据的来源与获取途径	7
8.2.1 按产生数据的主体划分	7
8.2.2 按数据来源的行业划分	7
8.2.3 按数据存储的形式划分	8
8.2.4 常见的大数据获取途径	9
8.3 大数据挖掘与分析	9
8.3.1 大数据智能的技术支撑	10
1. 存储技术	10
2. 计算技术	11
3. 智能技术	11
8.3.2 大数据预处理技术	11
8.3.3 大数据统计与分析技术	12
1. 基本的统计与分析-R 语言工具	12
2. 以 Python 为例的大数据统计与分析	12
8.3.4 大数据挖掘技术	13
8.4 大数据应用及其对社会的影响	16
8.4.1 大数据的呈现形式	16
1. 数据存储形式和相关技术	16
2. 数据可视化	16
8.4.2 大数据应用场景	18
8.4.3 大数据的风险及对策	20
1. 数据泄露风险	20
2. 隐私侵犯风险	20
3. 算法偏见	20
4. 安全漏洞与数据篡改	20
5. 国际合作应对	21
8.5 实践	21
8.6 思考	21
8.7 习题	22
参考文献	22

第 8 章 大数据智能

大数据一般指体量庞大、类型多样的数据集合。在信息化与数字化快速发展的当代，大数据不仅是数据的简单堆积，而是一个庞大的信息资源库，它已经成为人工智能的一类重要载体，内含无限潜力和可能性。

国务院 2017 年 7 月出台的《新一代人工智能发展规划》在建立新一代人工智能基础理论体系中明确提出：“大数据智能理论重点突破无监督学习、综合深度推理等难点问题，建立数据驱动、以自然语言理解为核心的认知计算模型，形成从大数据到知识、从知识到决策的能力”，并针对大数据智能理论具体部署“研究数据驱动与知识引导相结合的人工智能新方法、以自然语言理解和图像图形为核心的认知计算理论和方法、综合深度推理与创意人工智能理论与方法、非完全信息下智能决策基础理论与框架、数据驱动的通用人工智能数学模型与理论等。”

通过本章的学习，帮助大家掌握大数据的基本概念，了解相关技术，从而为未来开展大数据智能理论研究、掌握大数据系统并构建大数据平台奠定基础，更好地把握信息时代的机遇，迎接未来的挑战。

8.1 大数据的概念与意义

8.1.1 何为大数据

大数据指的是体量巨大、类型丰富并且需要快速处理的数据集合，包括结构化、半结构化和非结构化数据。在数字化时代，数据来源已从书籍、唱片、绘画等传统形式扩展到互联网、传感器设备、社交媒体和移动通信等现代技术。这种变化彻底改变了数据的生成、存储和分析方式。

信息论是大数据的科学基础，它探讨信息的本质和传输规律。大数据可以通过分析与处理减少不确定性：系统的熵（不确定性和混乱程度的度量，熵值的增加，表示系统的不确定性和混乱程度增加，反之则为减少）与收集到的信息量成反比，即信息越多，系统的熵值越低，不确定性越小。

表 8.1 回顾了大数据发展中的关键历史事件，并简述这些事件对大数据领域及其在社会中应用的深远意义。

表 8.1 大数据发展历程与关键里程碑

年份	关键里程碑事件	意义
1990 年代	互联网普及和信息技术的发展使得大规模数据产生和存储成为可能，大数据的概念首次被提出 ^[1] 。	标志着数据处理和分析的新时代开始，为后续大数据技术的发展奠定了基础。
2004 年	Google 发表关于分布式文件系统 GFS、大数据分布式计算框架 MapReduce 和数据库系统 BigTable 的三篇论文。	这些技术的发表，为处理大规模数据集提供了创新的方法和工具，极大推动了大数据技术的发展。
2011 年	麦肯锡研究院发布报告《Big data: The next frontier for innovation, competition, and productivity》 ^[2] ，明确定义了“大数据”。	报告强调了大数据对创新、竞争和生产力提升的重要性，将大数据的重要性推向了公众视野。

2012 年	美国政府推出《大数据研究和发展倡议》，将大数据比喻为“未来的新石油”。	倡议内容包括政策框架、数据开放和共享、隐私保护、人才培养和技术发展等方面。
2016 年	中国的“十三五”规划纲要将大数据发展纳入国家战略。通过建设强大的大数据基础设施和提升数据处理和分析能力，大数据将成为重要战略资源。	确立了大数据在国家发展中的核心地位，为经济社会发展提供支撑，有助于促进企业管理优化、推动创新和产业升级，并提供科学依据支持政府决策和改善公共服务。
2017 年	国务院 2017 年 7 月出台的《新一代人工智能发展规划》，把大数据作为新一代人工智能的核心要素之一。	指出大数据智能理论的发展方向，重点突破无监督学习、综合深度推理等难点问题，建立数据驱动、以自然语言理解为核心的认知计算模型，形成从大数据到知识、从知识到决策的能力。
2018 年	欧盟推出通用数据保护条例（GDPR），加强了对个人数据隐私的保护。	强化了数据隐私保护规范，对全球数据管理和数据驱动的业务模式产生深远影响。
2019 年	5G 技术正式商用，为大规模数据传输和实时处理提供了更高的带宽和速度。	使得数据应用更为广泛和高效，促进了大数据和人工智能技术的融合和应用。
2020 年	新冠疫情爆发，各国政府和组织通过大数据分析和人工智能技术来应对疫情。	凸显了大数据和人工智能在应急管理和公共卫生危机管理方面的关键作用。

现如今，大数据技术已广泛应用于日常生活和各行各业，从数据分析到决策支持，它正在重新定义我们的工作和生活方式，成为现代社会不可或缺的部分。

8.1.2 大数据的特征

2001 年，IBM 的研究员 Doug Laney 首次明确提出大数据具有“3V 特征”：

体量大（Volume）：大数据最明显的特征是数据量庞大，通常指的是海量的数据集，无法用传统的数据处理工具来处理。这些数据来自多个来源，如社交媒体、传感器、日志文件等。

种类多（Variety）：数据来源广泛，维度多样，类型复杂，包括结构化、半结构化和非结构化数据，对数据整合和处理技术提出了更高要求。如文本、图片、音频、视频等。多样化的数据类型带来了处理和分析上的复杂性。

速度快（Velocity）：大数据的生成速度非常快，数据实时或接近实时地生成，需要快速的处理和分析。这包括例如社交媒体上的实时动态、金融市场数据流等。

基于 Laney 的理论，IBM 和麦肯锡等机构进一步扩展了大数据特征，引入了第四和第五特征：

真实性（Veracity）：真实性是指数据的质量和可靠性。在大数据环境中，数据可能来自不同的来源，数据本身可能不完整、错误或含有噪音，因此对数据的可信度进行验证变得尤为重要。

价值（Value）：大数据的最终目标是从庞大的数据集中提取有价值的信息。这涉及到通过分析挖掘来发现潜在的商业价值、趋势、模式等，以指导决策和提升效率。

图 8-1 直观展示了大数据的 5V 特征（Volume, Variety, Velocity, Veracity, Value）。这五个 V 是理解和应对大数据的关键特征，有助于识别在处理大数据时可能遇到的挑战和要求。




图 8-1 大数据 5V 特征示意图

8.1.3 大数据思维

大数据思维（Big Data Thinking）是指在面对庞大、多维、高速和复杂的数据集时，采用一种全新的思维方式来处理和分析数据，目的是从中获取新的理解和意想不到的价值。这种思维方式超越了传统的因果分析方法，转而依赖数据驱动的探索，即使在缺乏明确假设的情况下，也能通过数据揭示答案，如图 8-2 所示。



图 8-2 从接受因果关系转到接受强相关性

大数据常见的分析方法包括关联分析（Association Analysis）和发现型分析（Exploratory Analysis）。这些方法强调从数据中挖掘出深入的信息和意义，以指导决策和行动。

- 1) 关联分析：此方法不限于寻找显而易见的关联，而是深挖数据中隐藏的、非直观的联系。例如，通过挖掘顾客的购买数据可以发现某些产品之间的共同购买模式，从而帮助商家优化库存和营销

策略。

- 2) 发现型分析: 数据科学家利用算法探索未知的数据模式或趋势, 这些发现可以引导新的研究方向或产品开发。

典型应用场景

- 1) 市场营销: 通过购物车分析, 帮助企业从顾客浏览历史、购买记录等数据中发现哪些商品经常同时被购买, 促进有效的交叉销售和定价策略优化。
- 2) 医疗健康: 通过关联分析, 辅助医生从大量病历数据中揭示疾病间的潜在联系, 提升早期检测、诊断和治疗的精准度。
- 3) 金融行业: 银行和金融机构利用大数据分析贷款申请人的交易历史、支付行为和社交活动来评估其信用风险, 预测还款能力。
- 4) 城市规划: 城市规划者通过分析交通流量数据、居民活动模式和社区服务使用情况, 优化公共交通系统设计和城市设施布局。

尽管大数据思维为各行各业带来了前所未有的机遇, 但它也面临着数据隐私、数据安全和伦理问题等挑战:

- 1) 隐私保护: 随着越来越多的个人数据被用于分析, 如何保护用户隐私成为一个紧迫的问题。
- 2) 数据质量: 确保数据的真实性和准确性是分析可靠性的关键, 需要持续关注数据质量的提升。
- 3) 算法偏见: 机器学习模型可能会因为训练数据的偏见而产生有偏的结果, 如何消除这些偏见是一个重要的研究领域。

总之, 大数据思维要求我们用全新的视角看待数据的潜力和价值, 通过先进的分析技术不断探索数据的深层含义, 同时关注分析过程中的伦理和法律问题。这种思维方式不仅可以帮助我们解决当前的问题, 还能预见并应对未来的挑战, 从而推动社会和科技的持续进步。

8.1.4 大数据的意义

大数据的核心意义在于其通过挖掘和分析海量数据集来获取有价值的信息, “用数据说话, 使数据发声”, 已成为人类认知世界的一种全新方法。这不仅能帮助我们更好地理解 and 应对现实世界的挑战, 而且实现了更高效、智能和可持续的生产与生活方式。大数据可支持决策制定、业务优化、市场推广、产品创新等关键活动。

具体价值体现在:

- 1) 洞察消费者行为: 大数据可以揭示消费者的偏好、行为趋势和购买模式, 为企业提供了了解市场需求、推动产品创新并优化市场策略的关键洞见。
- 2) 提升运营效率: 通过监测和分析企业运营的各个环节, 大数据帮助企业发现并解决瓶颈问题, 优化流程, 提高效率, 降低成本。
- 3) 预测趋势和风险: 依托历史数据和预测模型, 大数据能够帮助企业在面临不确定性和变化时预测市场趋势和潜在风险, 使决策更加科学和准确。
- 4) 个性化服务: 大数据使企业能够根据用户的个人兴趣、需求和行为提供定制化的服务, 改善用户体验, 提高客户满意度和忠诚度。

- 5) 支持科学研究和技术创新：为科学家和研究人员提供了分析和挖掘新规律、新关联的强大工具，推动了科学进步和技术革新。
- 6) 促进社会发展和政策制定：政府和公共机构利用大数据进行社会调查和分析，制定科学合理的政策和规划，优化城市管理和公共服务，促进社会的可持续发展。

尽管大数据带来了巨大的机遇，也存在一些不可忽视的挑战，特别是在个人隐私和数据安全方面。有效的数据管理和严格的保护机制是确保大数据可持续发展的关键。

8.2 大数据的来源与获取途径

信息时代，随着互联网基础设施建设日益完善、移动互联网持续发展、网络应用爆发增长、物联网技术日益成熟，全球数据量正以不容忽视的爆发式姿态迅猛增长。根据不同的标准，我们可以将大数据的来源按照以下角度进行分析：

8.2.1 按产生数据的主体划分

目前大数据的来源日益多样化，表 8.2 是按照产生数据的主体划分。

表 8.2 数据产生主体划分的不同类型的大数据来源

数据产生主体	数据类型	具体例子
互联网用户	社交媒体数据、交易数据、浏览数据等	据 2023 年二季度数据，中国移动互联网用户已超过 12 亿，年增长率为 2.8% 。 来自于用户在社交平台上的互动，如聊天记录、评论、点赞、分享等； 电商平台购物记录，包括购买频率、购买类别等； 搜索查询、网页浏览、广告点击等。
企业和机构	运营数据、财务数据、客户服务数据等	企业的 CRM 系统、ERP 系统以及电子商务平台等，都记录了详细的业务交易和操作数据，这些数据是优化业务流程、提高运营效率、制定战略决策的重要基础。 运营数据包括产品销售量、服务调用次数等；财务数据包括收入、支出、利润等；客户服务数据包括通过客户服务渠道收集的客户反馈和服务请求数据。
机器与设备	传感器数据、监控数据、设备状态数据	随着物联网技术的成熟和应用的扩展，越来越多的机器和设备被用来收集和传输数据。这些数据不仅支持设备的自主运作，还为城市规划、安全监控、环境监测等提供了实时数据支持。 智能温控系统的温度数据；城市监控摄像头录像； 智能电表的电力使用数据；智能车的行驶数据等。

8.2.2 按数据来源的行业划分

随着信息化的快速发展，计算机早已广泛进入各行各业，现在每一个行业都在每时每刻产生大量新的数据信息。按照产业划分来源可以更好地指导数据的具体应用方向和个性化需求设置。表 8.3 具体展示了

不同行业产生的大数据类型和具体示例。

表 8.3 各个行业在大数据生成方面的角色和特点

行业分类	数据类型	具体示例
互联网公司	用户行为数据、交易数据、社交数据等	百度公司数据总量达到 EB 级别，每日搜索多达 70 亿次以上；阿里巴巴公司数据总量超过了百 PB 级别，拥有 90%以上的电商数据；腾讯 2023 年微信用户量达到 14 亿，拥有社交数据、游戏数据、交通数据、舆论数据、支付平台数据等涉及各项生活领域的数据集，这些也是场景化非常高的数据。
电信与电力	运营数据、用户数据等	电信行业的用户通信数据；国家电网的供电使用和缴费情况数据总量达到了数十 PB 以上。
石化与金融	交易数据、监控数据、保险数据等	石化工业产生和保存的数据量，包括仓储、炼化设备、反应堆的日常追踪等，达到了百 PB 级别；金融、保险系统产生的数据每年以数十 PB 的规模增长。
交通行业	物流数据、运输数据等	航班和列车的运行数据，物流公司的货运记录形成的视频、文本类数据均在百 PB 级。
制造业	生产数据、设备监控数据等	现代机械设备产生的数据；工人作业活动产生的追踪数据，包括从采购、生产、物流再到销售的内部流程以及外部产业讯息等。
公共安全与医疗	健康数据、监控数据等	公共安全领域的监控视频数据；整个医疗卫生行业包含就诊病例、医学图像、用药进药等环节每年均达到数百 PB 规模数据。
政务领域	行政数据、地理信息数据等	政府掌握着气象、地质、教育、人力资源管理等全社会最大、最核心的数据，气象局保存的数据将近 10PB,每年约增数百 TB；各种城市规划地图和地理位置信息每年约增长数十 PB。
其他传统行业	消费数据、物流数据、科研实验数据等	餐饮行业的订单数据；快递物流行业的配送数据；院校研究所的科研实验数据；这些数据量剧增，但也处于积累期，多则达到 PB 级别，少则数十数百 TB。

8.2.3 按数据存储的形式划分

大数据不仅仅是体量巨大，其丰富的数据类型也是促成其规模庞大的另一重要原因。按照数据存储的具体形式，我们可以将现有大数据分为结构化数据、半结构化数据和非结构化数据^[3]，如表 8.4 所示。

表 8.4 大数据的存储形式、常见例子和处理工具

数据类型	定义与特征	常见例子	处理工具
结构化数据	数据在固定字段内严格组织，易于存储和查询，通	客户数据库、库存记录、金融交易等	数据库管理系统（如 MySQL, Oracle）

	常存储在关系数据库中。		
半结构化数据	不符合严格的数据库结构, 但具有可识别的模式和标记, 灵活性较高。	网页的 HTML 代码, JSON 格式的数据交换文件、XML 文档、电子邮件等	XML 解析器、JSON 解析器
非结构化数据	没有预定义的数据模型, 也无法轻易地适应传统数据库的行和列的结构。	社交媒体帖子、视频、音频文件、PDF 文件、卫星图像等	使用人工智能技术, 如大模型、自然语言处理、图像和视频分析工具等

根据现有的数据来看, 现在已经产生的大数据中仅有 20% 左右属于结构化的数据, 80% 的数据属于广泛存在于社交网络、物联网、电子商务等领域的半结构化和非结构化数据。

8.2.4 常见的大数据获取途径

随着大数据需求的增长, 特别是各类智能系统不断拓展应用导致可以提供的数据类型空前增加, 获取大数据的途径也变得多样化。为了清晰地展示大数据的不同获取途径, 整理了表格 8.5。

表 8.5 大数据获取途径

获取途径	描述	适用情况	常用工具
系统日志采集	收集系统软硬件运行和变化的日志信息, 用于分析系统问题。	需要监控和分析系统性能及安全事件。	Logstash、Filebeat、Fluentd、Logagent、rsyslog 等常见的日志采集工具
互联网数据采集	通过爬虫程序或 API 获取网页的 HTML、文本、图片等数据。	需要分析网页内容或用户行为, 适用于市场分析、竞争情报等。	Web 数据提取器, 数据抓取工具, API 调用工具
APP 移动端数据采集	通过 API 接口获取 APP 相关信息, 如应用详情、评分、下载量等。	针对移动应用市场的分析, 包括用户行为分析、应用性能监控等。	通过 API 接口获得应用详情、评分、下载量、版本信息以及其他数据。
与数据服务机构合作	与专门的数据服务机构合作, 获取特定的、难以直接获取的数据。	数据获取难度大或数据量巨大, 需要高保密性和准确性的场合。	专业数据服务平台、寻求许可和合作协议

8.3 大数据挖掘与分析

大数据的真正价值就像海洋上的冰山, 我们只能看到冰山上很小的一部分。为了最终挖掘出隐藏在表面下的价值, 大量的数据需要进行剥离、清洗、整理、归类、建模和分析等操作, 以建立数据分析的维度, 并对不同维度的数据进行分析与展示。其基本流程如图 8-3 所示。



图 8-3 大数据处理的基本流程

但是挖掘大数据的价值并非易事，传统的数据处理和分析方法无法适应大数据的数据量大、流速快、多样性等特点，需要不断更新迭代技术和工具。本节将详细介绍大数据挖掘与分析的具体处理方法，包括预处理、统计分析，以及数据挖掘技术，其主要处理方法如图 8-4 所示。




图 8-4 大数据的处理方法

8.3.1 大数据智能的技术支撑

在开始大数据挖掘与分析技术之前，先介绍一下支撑大数据挖掘与分析的三项关键技术：

1. 存储技术

大数据的存储需求导致了传统数据库技术的演进，如分布式文件系统和 NoSQL 数据库的使用，以应对大规模数据的存储和快速访问需求。

大数据的处理需要能够高效存储和管理大规模的数据。传统的关系型数据库在处理大数据时存在容量和性能上的限制，因此，各种新型的存储技术应运而生。例如，分布式文件系统（如 Hadoop HDFS），列式存储数据库（如 Apache Cassandra），NoSQL（Not only SQL）数据库以及分布式键值存储（Distributed Key-Value Store）等先进技术。

值得一提的是，数据库作为最常见的数据存储和管理工具，其发展经历了从关系的、结构良好的

（relational, well-structured）到非关系、无模式的（non-relational, schema-less）的技术转变^[4]。这些存储技术的发展和运用，使得大规模数据的存储、管理和访问更加高效和可靠，为大数据的分析和应用提供了坚实的基础。同时，随着技术的不断进步，存储技术也在不断发展和创新，以满足不断增长的数据需求，让大数据处理具有高容量性、高可扩展性和高可靠性。

2. 计算技术

大数据处理需要高性能的并行计算和分布式计算技术来快速分析和处理庞大的数据集。

并行和分布式计算：传统的串行计算方式无法满足需求，并行计算和分布式计算由此成为大数据处理的主要技术。例如，分布式计算框架（如 Apache Hadoop 和 Apache Spark）能够将任务切分成多个子任务，并在集群的多台服务器上并行执行，从而提供高效、可扩展的数据处理能力。

实时处理技术：大数据的不断增长，对实时处理能力的需求也越来越高。实时处理技术可以快速地处理即时产生的大数据，并实时生成分析结果。例如，流式计算引擎（如 Apache Kafka 和 Apache Flink）可以实时接收、处理和存储连续产生的数据流，实时分析和可视化数据，及时发现数据的变化和异常^[5]。

3. 智能技术

大数据的核心价值在于从数据中提炼“智慧”，而机器学习、大模型等智能技术则不断提升大数据的处理与理解能力，使得数据的潜在价值得以深度挖掘。智能技术的应用使大数据分析不仅可以揭示深层次的洞察与趋势，还能够为各行业的决策提供数据支持，从而更全面地释放数据价值。这些技术的发展推动了数据分析的精准度和广度，让数据驱动决策成为现实，为大数据在各领域的广泛应用打开了更为广阔的前景。

8.3.2 大数据预处理技术

在现实世界中，我们经常面对着不完整、不一致的数据，这些数据被称为“脏”数据，无法直接进行有效的数据挖掘。或者即使进行了数据挖掘，得到的结果也并不令人满意。为了高效地进行数据挖掘，数据预处理技术就此产生。大数据预处理技术是在开始主要处理之前对数据进行的一系列操作，包括数据清理、数据集成、数据变换和数据规约等，见表 8.6。

表 8.6 大数据预处理技术

序号	预处理技术	技术内容	作用	实例
1	数据清理	去除噪声数据、修正错误值、删除重复记录	提高数据的准确性和完整性，确保分析结果的可靠性	例如，在用户注册数据中删除重复的用户记录，修正不可能的出生日期（如未来日期）。
2	数据集成	合并来自不同数据源的数据，解决数据冲突	创建一个统一的数据视图，便于进行全面的数据分析	将 CRM 系统中的客户数据与交易系统上的交易记录合并，以获得完整的客户活动视图。
3	数据变换	标准化、归一化、对数变换、离散化等	将数据转换为适合分析的格式，调整数据尺度，简化模型建立过程	对收入数据进行对数变换，以处理极端值并改善其在统计模型中的表现。

4	数据规约	对大量数据集合进行筛选、清洗、转化和重组等操作	降低数据的复杂性，包括维度降低、数据压缩、数值简化等，减少数据量，提高数据处理效率，同时尽可能保留重要信息	在分析顾客满意度时，仅选择与研究问题最相关的特征（如顾客反馈和产品评分）。
5	特征提取	从数据中抽取新的特征集，通常通过数学变换实现，如主成分分析（PCA）	减少数据集中的冗余信息，提取关键信息用于建模	使用 PCA 处理高维数据，减少特征数量同时保持数据的大部分变异信息。
6	特征选择	从众多特征中选择最相关的特征，剔除无关特征	提高模型的性能，减少过拟合，加快学习速度	通过自动化特征选择技术，识别出对房价预测最有影响的变量，如位置、大小和房龄。
7	数据降维	将高维数据转化为低维表示的过程，减少随机变量的数量，如通过特征提取或特征选择实现	简化模型，减少计算量，同时降低噪声和提高模型的解释能力	对遥感影像数据进行降维，以提高在地形分类任务中的处理速度和分类精度。
8	数据集平衡	在分类不平衡的数据集中，通过技术手段调整类别样本的数量，如过采样或欠采样	提高分类模型的性能，特别是在预测较少出现的类别时能够提高准确性	使用 SMOTE 算法对医疗数据中的少数类病例进行过采样，改善模型对罕见疾病的预测能力。

8.3.3 大数据统计与分析技术

大数据技术的核心在于通过一系列方法和工具，从海量、复杂、无序的数据中自动提取出有价值的信息和潜在模式。这一过程涉及对数据进行深入的统计和分析，以帮助更好地理解数据、组织数据并预测未来趋势。大数据统计与分析技术，是指利用高级分析方法对大规模且多样化的数据集进行系统处理和分析的过程，通常在分布式数据库或计算集群等系统中进行海量数据的分类、汇总与分析，以满足广泛的分析需求。

1. 基本的统计与分析-R 语言工具

R 语言是大数据分析中的重要工具之一，作为一款开源数据处理、统计计算和制图软件，R 具有高度灵活性，提供了丰富的统计工具及数学计算、统计计算的函数。用户可以基于 R 语言定制新的统计和分析方法，其扩展包（如 SparkR 和 H2O）能够与 Apache Spark 和 Hadoop 集成，用于大数据处理，成为全球专业数据分析的标准工具。由于数据量庞大，统计分析过程往往对系统资源特别是 I/O 有较大需求。

2. 以 Python 为例的大数据统计与分析

Python 因其丰富的数据可视化、统计描述和深度学习工具库而在大数据分析中广泛使用。

Python 中多种可视化库（如 Matplotlib、seaborn、Plotly 等）可以用线图、散点图、柱状图和饼图展示数据的分布和趋势；pandas 库的 describe() 函数能计算数据基本统计量，而 scipy 库则提供了概率分布、置信区间和假设检验功能（如 ttest_ind 和 chisquare）。statsmodels 库支持线性回归、逻辑回归和多元回归等多种回归分析，Prophet 库则适用于时间序列分析，NetworkX 库支持网络分析。Python 还通过深度学习库（如 TensorFlow、PyTorch）处理图像数据，支持卷积神经网络（CNN）进行图像分类。通过结合 Apache Spark

等分布式计算框架, Python 能够高效处理超大规模数据集, 为大数据技术的发展提供了有力支持。

8.3.4 大数据挖掘技术

大数据挖掘源自数据挖掘技术, 是从大规模数据集中发现有用信息和知识的过程, 涉及应用统计学、机器学习、人工智能等多个领域的方法。数据挖掘技术帮助揭示数据中隐藏的模式、关联和趋势, 支持决策制定和策略发展。主要任务和应用包括分类、聚类、关联规则挖掘、连接分析和序列挖掘等。

核心技术及应用:

1) 分类技术

描述: 分类是将数据样本划分为预定义类别或标签的任务。使用的方法包括决策树、朴素贝叶斯、支持向量机、随机森林等。

应用: 广泛应用于信用评分、客户细分、图像识别和垃圾邮件检测等领域。

2) 聚类技术

描述: 聚类旨在将具有相似特征的数据样本聚集在一起, 常见方法有 K 均值、K 最近邻、层次聚类和 DBSCAN 等。

应用: 用于市场细分、社交网络分析、基因数据分析和图像分割等任务。

3) 关联规则挖掘

描述: 探索数据项之间的关联和频繁模式, 主要方法包括 Apriori 算法和频繁模式增长算法。

应用: 适用于零售购物车分析、推荐系统、生物信息学等领域。

4) 序列挖掘

描述: 从时间序列数据中识别频繁出现的模式和趋势, 重要技术包括广义序列模式和前缀树算法。

应用: 用于股票市场分析、顾客购物行为分析、天气预测等。

5) 链接分析

描述: 分析和解释数据中的链接关系, 主要算法有页面排名和超链接分析法。

应用: 在网页排名、社交网络影响力分析和反欺诈领域中有广泛应用。

大数据挖掘技术涉及到的算法众多, 如属于分类算法的决策树 (Decision Tree)、支持向量机 (SVM)、朴素贝叶斯分类 (Naive Bayes) 和 K 近邻算法 (K-Nearest Neighbors, KNN) 等; 属于聚类算法的 K 均值聚类 (K-Means Clustering)、层次聚类 (Hierarchical Clustering) 和密度聚类 (DBSCAN) 等; 属于关联规则算法的 Apriori 算法和 FP-Growth 算法等; 属于回归分析的线性回归 (Linear Regression) 和逻辑回归 (Logistic Regression) 等; 属于降维算法的主成分分析 (PCA)、线性判别分析 (LDA) 和 t-SNE (t-Distributed Stochastic Neighbor Embedding) 等; 属于神经网络与深度学习的卷积神经网络 (CNN)、循环神经网络 (RNN) 和深度信念网络 (DBN) 等; 属于集成学习算法的随机森林 (Random Forest)、梯度提升树 (Gradient Boosting Trees) 和 XGBoost 等; 属于时间序列分析的自回归积分滑动平均模型 (ARIMA) 和长短期记忆网络 (LSTM) 等。这些算法在不同场景和需求下被灵活应用, 以应对大数据挖掘的多样性和复杂性。若干典型算法举例:

1) 决策树算法

决策树算法 (decision tree) ^[6] 是一类常见的机器学习方法, 同时也是一种典型的分类方法。决策树是通过一系列规则对数据进行分类的过程, 从而形成树状分类模型。

基本原理：以根结点开始，使用归纳算法基于最优属性值逐层划分数据，直到达到预设条件或完全分类。

决策树算法伪代码如下：

输入： 训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$;
 属性集 $A = \{a_1, a_2, \dots, a_d\}$ 。
过程： 函数 $\text{TreeGenerate}(D, A)$

- 1: 生成结点 node ;
 // 递归返回，当前结点包含的样本全属于同一类别，无需划分
- 2: **if** D 中样本全属于同一类别 C **then**
- 3: 将 node 标记为 C 类叶结点; **return**
- 4: **end if**
 // 递归返回，当前属性集为空，或是所有样本在所有属性上取值相同
- 5: **if** $A = \emptyset$ OR D 中样本在 A 上取值相同 **then**
- 6: 将 node 标记为叶结点，其类别标记为 D 中样本数最多的类; **return**
- 7: **end if**
- 8: 从 A 中选择最优划分属性 a_* ;
- 9: **for** a_* 的每一个值 a_*^v **do**
- 10: 为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;
 // 递归返回，当前结点包含的样本集合为空，不能划分
- 11: **if** D_v 为空 **then**
- 12: 将分支结点标记为叶结点，其类别标记为 D 中样本最多的类; **return**
- 13: **else**
 // 从 A 中去掉 a_*
- 14: 以 $\text{TreeGenerate}(D_v, A \setminus \{a_*\})$ 为分支结点
- 15: **end if**
- 16: **end for**

输出： 以 node 为根结点的一棵决策树

算法流程：包括结点生成、最优属性选择、分支处理，直到所有数据被合理分类或达到树的最大深度限制。其中关键步骤：1) 选择最优属性：这通常涉及到计算各属性的信息增益，选择最佳属性来分割数据集。2) 递归构建树：对于选择的属性，为每个唯一值创建一个分支，递归地应用算法在这些分支上构建子树。3) 处理空分支：如果任何属性值对应的子集为空（即没有数据点），则创建一个叶节点，使用数据集中最常见的类别标记此节点。

决策树学习算法是一种广泛使用的分类技术，通过从训练数据中自动学习决策规则来构建树形结构模型。通过这种方法，决策树能够将复杂的数据集分解成更简单的子集，最终形成一个易于解释的分类模型。

2) K 均值算法

K 均值算法^[7]是原型聚类（prototype-based clustering）的一种，在现实聚类任务中比较常用。

基本原理：给定样本集 $D = \{x_1, x_2, \dots, x_m\}$ ，K 均值（k-means）算法针对聚类所得簇划分 $C = \{C_1, C_2, \dots, C_k\}$ 最小化平方误差：

$$E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|_2^2 \quad (8.1)$$

其中 $\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$ 是簇 C_i 的均值向量。直观来看, 式 (8.1) 在一定程度上刻画了簇内样本围绕均值向量的紧密程度, E 值越小则簇内样本相似度越高。K 均值算法采用了贪心策略, 通过迭代优化来近似求解式 (8.1)。

K 均值算法伪代码如下:

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;

聚类簇数 k 。

过程:

1: 从 D 中随机选择 k 个样本作为初始均值向量 $\{\mu_1, \mu_2, \dots, \mu_k\}$

2: **repeat**

3: 令 $C_i = \emptyset$ ($1 \leq i \leq k$)

4: **for** $j = 1, 2, \dots, m$ **do**

5: 计算样本 x_j 与各均值向量 μ_i ($1 \leq i \leq k$) 的距离: $d_{ji} = \|x_j - \mu_i\|_2$;

6: 根据距离最近的均值向量确定 x_j 的簇标记: $\lambda_j = \arg \min_{i \in \{1, 2, \dots, k\}} d_{ji}$;

7: 将样本 x_j 划入相应的簇: $C_{\lambda_j} = C_{\lambda_j} \cup \{x_j\}$;

8: **end for**

9: **for** $i = 1, 2, \dots, k$ **do**

10: 计算新均值向量: $\mu'_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$;

11: **if** $\mu'_i \neq \mu_i$ **then**

12: 将当前均值向量 μ_i 更新为 μ'_i

13: **else**

14: 保持当前均值向量不变

15: **end if**

16: **end for**

17: **until** 当前均值向量均未更新

输出: 簇划分 $C = \{C_1, C_2, \dots, C_k\}$

算法流程: 其中第 1 行对均值向量进行初始化, 在第 4-8 行与第 9-16 行依次对当前簇划分及均值向量迭代更新, 若迭代更新后聚类结果保持不变, 则在第 18 行将当前簇划分结果返回。

3) Apriori 算法

Apriori 算法^[8]是第一个关联规则挖掘算法, 由 IBM 的研究员于 1993 年提出。

Apriori 算法的工作原理:

Apriori 算法中的每个关键步骤都旨在识别项集及其所有可能的超集, 寻找最常见的项集以创建关联规则。

步骤 1: 生成频繁项集

该算法首先识别数据集中的唯一项 (有时称为 1 项集) 并计算其频率。然后, 将那些出现概率超过指定阈值的项组合成候选项集, 并筛选出不常见的项集, 以降低后续步骤中的计算成本。此过程称为频繁项集挖掘, 即仅查找具备有意义频率的项集。

步骤 2: 扩展并修剪项集

该算法利用 Apriori 特性, 进一步组合频繁项集, 形成更大的项集。针对概率较低的大项集的组合会进行修剪。这样可以进一步减少了搜索空间, 并提高了计算效率。

步骤 3：重复步骤 1 和 2

该算法重复步骤 1 和 2，直至完成生成所有符合定义阈值概率的频繁项集。每次迭代都会生成更复杂、更全面的项集关联。

Apriori 算法创建项集后，可以进一步分析其关联规则的强度和关系。

Apriori 算法已经被广泛地应用于商业、网络安全等领域，算法简单明了，易于实现。

大数据挖掘技术为企业和组织提供了深入理解庞大和复杂数据集的能力，帮助他们在竞争激烈的市场环境中做出更快、更准确的决策。随着技术的不断进步，大数据挖掘的应用领域将进一步扩大，其影响力也将持续增强。

8.4 大数据应用及其对社会的影响

本节将介绍大数据的可视化呈现形式，讨论大数据如何重塑行业格局和社会经济结构，提供决策支持，完善政策制定。

8.4.1 大数据的呈现形式

数据呈现形式，一般是指数据以何种形式存在于这个世界上，或者以何种方式被人们所感知，具体涉及数据存储、数据可视化等。大数据的有效呈现不仅涉及技术的选择和应用，还包括如何通过这些技术使数据更易于理解和分析。

1. 数据存储形式和相关技术

分布式系统：如 Hadoop 和 Spark 等提供了一个可扩展、可靠且容错的数据存储和处理框架。这些系统通过将数据分布在多个服务器上，不仅优化了存储效率，也加快了数据处理速度。

NoSQL 数据库：如 MongoDB、Cassandra 和 HBase 等，这些数据库支持大量非结构化数据的存储，适用于需要灵活性和水平扩展能力的应用场景。

云数据库：如 Amazon Web Services、Google Cloud 和 Microsoft Azure 提供的数据库服务，这方面国内华为云、阿里云也有非常好的替代数据库服务，允许用户在云端存储和管理数据，提供高可用性、灵活的扩展性及成本效益。

2010 年后，随着移动通信技术的突破，流处理框架和云原生数据存储的应用开始广泛普及，这些技术支持对海量非结构化数据的高效处理。

2. 数据可视化

数据可视化是将复杂数据转换为易于理解的视觉格式，使信息一目了然，支持快速决策。数据的可视化方式需要由数据本身的形式以及人们的目标来决定。

最简便的方式是文字描述，但其展现的信息量有限，而图表则更为形象和具体：

- 1) 基础图表：直方图、折线图、饼状图等，适用于展示数据的绝对大小、变化趋势或比例分布。
- 2) 高级图表：箱线图展示数据分布的统计特性；热力图揭示数据项间的相关性。
- 3) 地理数据可视化：结合实际地图，用颜色等视觉元素表示数据分布或属性，如人口迁移、疫情分布等。

可视化的应用实例：

- 1) 实时大屏展示：在公共场合或决策中心使用大型显示屏实时展示关键业务指标和趋势，如交通流量监控中心或网络安全运营中心。
- 2) 动态仪表板：在企业管理中，使用仪表板工具，展示销售数据、库存水平、市场分析等，帮助管理者做出快速决策。
- 3) 增强现实（AR）和虚拟现实（VR）：在复杂数据环境下，如通过 VR 来模拟天气系统或通过 AR 来辅助地理位置数据分析，提供更直观的数据感知方式。

大数据可视化呈现可以极大地帮助分析和理解复杂数据集。以下是一个使用热力图来分析和呈现一个城市的交通流量数据的具体例子。

第一步数据收集，交通流量数据通过在主要路口安装的交通摄像头和传感器收集得到。这些设备每 15 分钟记录一次数据，包括车辆数量、车速等信息；第二步数据处理，收集到的数据进行清洗和预处理，以消除错误读数和填补数据缺失，数据被整理成一个时间序列格式，每个时间点记录每个路段的车流量；第三步用热力图来可视化呈现。

使用热力图来展示数据，每个路段的位置对应地图上的一个点，而颜色的深浅表示车流量的大小：

- 1) 时间维度：横轴表示一天中的时间，从凌晨到晚上。
- 2) 空间维度：纵轴表示城市的不同路段。
- 3) 颜色渐变：代表从低流量到高流量。

图 8-5 是一个热力图，显示了一个城市 10 条主要路段在一天 24 小时内的交通流量数据。这个图表使用了颜色渐变（从黄色到红色），颜色越深表示交通流量越大，从而直观地展示了各时间段各路段的拥堵情况。




图 8-5 城市交通热力图

通过这样的热力图，城市交通管理者可以轻松识别出交通高峰时段和拥堵路段，从而采取适当的交通管理措施，如调整信号灯控制、增加公共交通服务等，以优化交通流并提高道路使用效率。这只是大数据可视化在实际城市管理中应用的一个例子，类似方法还可以广泛应用于其他领域，如环境监测、资源分配、

公共安全等。

关于大数据的终极呈现形式，不可能简单给出结论。目前大数据应用在不断扩大和深化，未来会产生更多、更复杂的数据模式，驱使着芯片、服务器、超级计算机等载体的更新迭代，同时会推动数据可视化技术不断创新。

8.4.2 大数据应用场景

大数据涵盖了人类社会生产生活的方方面面，而对大数据的有效应用是实现数据价值的关键，同时也体现了对社会的巨大影响。目前大数据应用已经融入到各个行业中。如图 8-5 所示，金融、零售、医疗、教育、农业、环境、智慧城市是大数据应用的七大主要行业。




图 8-5 大数据主要应用于七大行业.

具体而言，在零售行业，通过大数据技术精确分析消费者行为和市场动态，实现个性化营销和优化定价策略，增强客户忠诚度和市场竞争力。在金融领域，利用大数据进行资产管理、风险评估和量化投资，提高交易效率和风险控制，确保投资回报和资本安全。在医疗行业，通过大数据提高医疗诊断的准确性，加速新药开发，优化保险产品，从而提高整体医疗服务的效率和质量。在教育领域，应用大数据优化教学资源配置，实现教学个性化，提升教育质量和效率。在农业领域，通过大数据技术进行精准种植，病虫害预测和防治，提高农业生产效率和作物品质。在环境保护行业，使用大数据进行环境监测和管理，确保环境保护措施的实时性和有效性。在智慧城市领域，通过整合大数据技术优化城市管理，实现资源优化分配，提高居民生活质量和城市可持续发展。

为了更好凝练和展示每个行业的大数据应用场景，包括技术的实际应用、相关案例、挑战以及预期的效益，整理表 8.7。

表 8.7 典型大数据应用场景

行业	应用目的	具体应用	常用技术/工具
----	------	------	---------

教材初稿，严禁复制和传播！

零售	通过分析消费者行为数据，优化营销策略，提升客户满意度和商业效率。	精准营销：分析消费者行为识别潜在的消费者需求，以定制个性化营销信息，提高转化率。 客户情绪分析：利用自然语言处理技术分析客户反馈，识别客户的情绪和态度，帮助零售商改进产品和服务。 价格优化：分析市场数据，包括竞争对手价格、产品需求和库存情况，动态调整价格以最大化利润。	数据分析平台、CRM 系统、自然语言处理、机器学习模型
金融	提高交易效率，降低风险，增强客户服务和合规性管理。	资产管理：监控和调度资产如飞机和船舶的租赁，监控资产的性能和维护需求，确保资产的最优使用和投资回报。 量化投资：通过算法交易，分析历史数据和市场趋势，构建投资模型，自动执行交易策略。 风险评估：评估贷款申请人的信用风险，量化贷款和投资的风险，并评估预测市场变动对投资组合的影响。	大数据分析工具、风险管理软件、量化分析工具
医疗	提高医疗服务的效率和质量，支持临床决策，加速药物和治疗方法的研发。	医学诊断和治疗：利用患者的历史健康记录和实时健康监控数据，辅助诊断和治疗决策。 药物研发：在药物研发阶段，通过分析临床试验数据和患者反馈，优化药物配方和治疗方案。 医疗保险：分析大量的保险申请和索赔数据，优化保险产品的设计，减少欺诈行为。 智能医疗：建立医疗数据库和云系统，辅助专家学者远程问诊，以实现重大疾病预防等目标。	健康信息系统、临床决策支持系统、生物统计软件
教育	优化教育资源分配，个性化学习经验，提高教学质量和效率。	学校管理：通过分析学生的出勤率、成绩和行为模式，学校管理层可以优化课程安排和教学资源分配。 教学策略制定：教师可以利用学生的学习成绩和在线学习行为，调整教学方法和内容，以满足学生的具体需求。 个性化学习：通过分析学生的学习习惯和成绩，提供个性化的学习资源和建议。	学习管理系统、数据分析平台、自适应学习技术
农业	优化农作物生产、病虫害管理和农业供应链。	精准农业：分析气候数据、土壤条件和作物生长数据，决定灌溉和施肥的最优时间。 生长分析：利用卫星图像和传感器数据监测作物生长状态，预测产量，快速响应可能的疾病或营养不足问题。 病害防治：通过分析气象数据和历史病虫害发生记录，预测病虫害发生概率和扩散趋势，及时部署防治措施，自动通知农户。	地理信息系统、遥感技术、智能分析软件
环境	通过大数据技术提高环境监测和管理的精确性和效率。	环境数据收集：集成多源环境监测数据，实时追踪空气质量、水质和土壤状况。 空气质量检测：分析预测空气污染趋势，制定防治措施，预测未来的污染事件。 环境治理保护：分析污染源数据和环境质量指标，优化资源	物联网传感技术、环境监控系统、数据可视化工具

		分配和环境治理策略。	
智慧城市	通过整合各种城市运营数据，提高城市管理效率，改善居民生活。	政府调控：分析宏观经济数据和城市发展数据，制定经济政策和优化资源配置。 资源规划：利用城市数据进行空间规划，优化交通和公共设施布局。 智慧交通：实时监控交通状况，优化信号控制和路线规划，减少交通拥堵。 安防预警：整合视频监控和应急响应系统，提高城市安全和应急效率。	物联网、大数据分析平台、智慧交通系统、安防系统

8.4.3 大数据的风险及对策

大数据，虽为技术创新带来诸多益处，但也伴随着重大挑战，特别是在隐私保护、数据安全和社会伦理方面。

1. 数据泄露风险

实例：2018 年社交媒体巨头 Facebook 与 Cambridge Analytica 的数据共享丑闻中暴露了大数据平台在隐私保护方面也会出现的重大漏洞，Facebook 透露了数百万用户的个人数据，未经同意就用于政治广告，引发全球对数据隐私的关注。

解决方向：部署端到端加密技术，确保数据在传输和存储过程中的安全。

2. 隐私侵犯风险

实例：一些手机 APP 软件会在后台收集通讯录、浏览记录、语音通话、文字消息、地理位置以及行踪等，凭借这些信息通过人工智能算法推断出用户的喜好，从而进行商品推荐；但是这些数据如果被未经授权的第三方获取，可能被用于不当目的。

解决方向：实施严格的数据访问权限管理和用户同意管理系统，强化用户对自己数据的控制权。

3. 算法偏见

实例：2016 年报道指出，用于预测未来犯罪可能性的算法，在评估中对少数族裔存在偏见，导致不公平的执法结果。

解决方向：使用更多元化的训练数据集，引入算法审计流程，确保算法的公平性和透明度。

4. 安全漏洞与数据篡改

案例：Equifax 数据泄露事件。2017 年，美国信用评分机构 Equifax 遭受了重大的数据泄露，影响了近 1.5 亿消费者。黑客利用一个已知的安全漏洞在几个月内访问了消费者的个人数据，包括社会安全号码、出生日期、家庭地址，甚至有些情况下的驾驶执照号码。此次数据泄露不仅对受影响消费者的财务和隐私安全造成了巨大风险，还对 Equifax 的商业信誉造成了严重打击，引发了全球范围内对企业数据保护措施的新评估。

解决措施：Equifax 在确认数据泄露后，立即启动应急响应计划，关闭了受影响的应用，并通知了所有可能受影响的消费者。公司增强了网络安全措施，包括加强内部网络的监控和加密，以防止未来的数

据泄露。Equifax 承诺提高对消费者数据处理的透明度，增加消费者对自己数据管理的控制权。与监管机构合作，遵守数据保护法规，确保合规性，并通过第三方安全审计来恢复公众的信任。

5. 国际合作应对

这些案例突显了大数据时代企业面临的安全挑战和潜在的数据保护问题，同时随着大数据应用跨国界扩展，国际合作在制定数据治理标准和监管措施方面变得尤为重要。

- 1) 国际标准：通过国际组织如联合国、国际电信联盟等推动全球数据保护标准的统一，以应对跨境数据流动的监管挑战。这包括制定共享的数据安全规范和隐私保护措施，确保各国在数据治理上能够达成共识。
- 2) 技术创新与伦理：鼓励跨国技术交流和协作，共同研发更安全、更透明的数据处理技术，提升全球范围内的数据处理能力和伦理意识。同时强化数据伦理教育和隐私意识教育，培养公众和组织对数据处理风险的认识，增强个人和组织的隐私保护意识。
- 3) 法律与技术并进：政府应制定或更新数据保护法规，确保数据处理的合法性和安全性，加强对数据使用者的监督和问责。数据使用者在必要场合采取高级数据加密、访问控制和身份验证技术，同时公开数据处理的目的是和方式，增加数据处理的透明度，保护数据免受未经授权的访问和篡改。

通过这些措施，我们可以更好地利用大数据的优势，同时降低其潜在的风险，推动构建一个更安全、更公正的数字社会。

8.5 实践

【实践 8.1】 现如今已发展出许多数据挖掘工具，如 R 语言，SPSS（Statistical Package for the Social Sciences）软件，Apache Spark 等。请从中选择一个，尝试下载安装或者部署环境；

【实践 8.2】 尝试使用数据收集技术，如 Python 爬虫，Hadoop 的 Chukwa 等；

【实践 8.3】 尝试对数据进行预处理，熟悉相关 API 操作流程，如 Pandas，Scikit-learn 等工具包，并实现相关预处理操作，如数据清洗，标准化，数据去噪等；

【实践 8.4】 尝试对处理后的数据进行挖掘和分析，如回归，聚类，相关性分析等；如果是文本，可以对数据进行自然语言分析等。

以下推荐若干数据挖掘实战网站，可以从中选择合适的项目进行练习：

1) kaggle: <https://www.kaggle.com/>

2) 阿里云天池: <https://tianchi.aliyun.com/>

8.6 思考

【思考 8.1】 数据伦理和隐私：大数据应用在收集和分析个人数据时，如何平衡商业利益和个人隐私权？请讨论可能的策略和技术解决方案。

【思考 8.2】 数据质量的影响：数据质量问题（如不准确、不完整或过时的数据）如何影响大数据分析的结果？应如何确保其数据分析的准确性和可靠性？

【思考 8.3】 数据治理：企业如何建立有效的数据治理框架来管理其大数据资产？请讨论数据治理中的关键组成部分。

【思考 8.4】 行业特定的大数据应用：选择一个行业（如医疗、金融或教育），探讨大数据如何在该行业中创造价值，并讨论可能面临的独特挑战。

【思考 8.5】 大数据与人工智能：大数据如何加速人工智能的发展？这种交叉应用对未来的技术革新有何意义？

【思考 8.6】 技术发展的双刃剑：大数据技术的发展带来了哪些潜在的社会挑战和风险？如何利用政策和技术创新来缓解这些问题？

【思考 8.7】 随着互联网和信息技术的快速发展，大数据的职业方向及职业前景备受关注，请思考如何胜任下面这些研究和开发类岗位：1) ETL (Extract-Transform-Load) 研发岗位，ETL 指的是将原始数据经过提取 (extract)、转换 (transform)、加载 (load) 到目标存储数据仓库的过程。2) 大数据平台开发岗位，在 ETL 处理后，数据需要在大数据平台如 Hadoop 上进行进一步的处理和存储，以支持大规模数据的处理需求。3) 数据仓库研究岗位，需要根据业务需求和技术趋势，设计和规划信息系统的整体架构 (包括硬件、软件、网络和数据等)。4) 信息架构开发岗位，是指对某一特定内容的信息进行统筹、规划、设计等一系列处理过程的构思。5) OLAP (On-line Analytical Processing) 开发岗位，负责从各种数据源中建立模型，创建数据访问的用户界面，为用户提供多维查询功能。6) 可视化工具开发岗位，根据业务需求和用户反馈，设计和开发高效、易用的数据可视化工具，跨越多个资源和层次从而实现数据连接等。7) 数据科学研究岗位，运用统计学知识和数据分析方法，对数据进行深入挖掘和分析。8) 数据安全研究岗位，负责对组织内部的数据安全漏洞进行深入的分析和评估，识别潜在的安全风险，并及时采取措施进行修复。

8.7 习题

【作业 8.1】 概述大数据的含义，并简要分析大数据的形成原因 (可从经济、技术发展、人类活动等几个角度出发)。

【作业 8.2】 基于大数据 5V 特征 (Volume, Variety, Velocity, Veracity, Value)，对比大数据与小数据的差异，尝试挖掘出大数据更多的特征。

【作业 8.3】 聚类和分类均为常用的数据挖掘的方法，尝试总结和对比这两个方法 (如这两个方法的区别、适用场景等)。

【作业 8.4】 数据预处理是大数据分析和挖掘的重要步骤，如数据清理、数据集成、数据变换、数据规约等，尝试说明每一种的内容和达到的目的。

【作业 8.5】 调研中国大数据的现状，结合中国国情，尝试发掘中国大数据独有的特点。

参考文献

[1] Big data: The next Google[J]. Nature, 2008, 455, 8-9.

[2] MANYIKA J, CHUI M, BROWN B, et al. Big data: The next frontier for innovation, competition, and productivity[EB/OL]. McKinsey Global Institute, 2011

-
- [3] HOERL R.W, SNEE R.D, DE VEAUX R.D. Applying statistical thinking to 'Big Data' problems[J]. Wiley Interdisciplinary Reviews: Computational Statistics, 2014, 6(4), 222-232.
- [4] GEORGE G, HAAS M.R, PENTLAND A. Big data and management[J]. Academy of management Journal, 2014, 57(2), 321-326.
- [5] ANADIOTIS A.C, BALALAU O, CONCEICAO C, et al. Graph integration of structured, semistructured and unstructured data for data journalism[J]. Information Systems, 2022, 104, 101846.
- [6] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016, 73-74.
- [7] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016, 202-203.
- [8] AGRAWAL R, IMIELINSKI T, SWAMI A.N. Mining Association Rules between Sets of Items in Large Databases[J]. ACM SIGMOD Record, 1993, 22, 207-216.

《自动化与智能科学概论》教材初稿