

自动化与智能科学概论

Introduction to Automation and Intelligence Science

刘景泰 主编

2024 年 6 月

目录 (CONTENTS)

自动化与智能科学概论	1
目录 (CONTENTS)	2
第 10 章 机器人同步定位与建图	3
10.1 同步定位与建图 SLAM 的概述	3
10.1.1 机器人自主定位与 SLAM 定义	3
10.1.2 SLAM 的基本流程	6
10.1.3 典型的 SLAM 系统	7
10.1.4 SLAM 的应用	8
10.2 SLAM 的实现平台	9
10.2.1 SLAM 的传感设备	9
10.2.2 SLAM 系统的部署平台	10
10.3 SLAM 的地图形式	11
10.3.1 点云地图	11
10.3.2 特征地图	11
10.3.3 拓扑地图	12
10.3.4 栅格地图	12
10.3.5 语义地图	13
10.3.6 指纹地图	13
10.3.7 混合地图	13
10.4 SLAM 的基本方法	13
10.4.1 传统的 SLAM 方法	14
1. 传统 SLAM 的滤波框架	14
2. 传统 SLAM 的优化框架	17
10.4.2 基于深度学习的端到端 SLAM	21
1. 基本思路	21
2. 代表性方法	21
10.4.3 深度学习与传统方法的结合	22
1. 基本思路	22
2. 代表性方法	22
10.5 SLAM 的发展脉络与未来展望	23
10.5.1 SLAM 的发展脉络	23
1. 激光 SLAM	24
2. 视觉 SLAM	24
3. 多传感器融合 SLAM	25
4. 语义 SLAM	26
10.5.2 SLAM 的未来展望	27
10.6 思考	28
10.7 习题	28
参考文献	28

第 10 章 机器人同步定位与建图

当机器人开始执行任务时，首先需要明确自身所处的位置，实现精准的自主定位是其开展各项工作的先决条件。同步定位与建图（Simultaneous Localization and Mapping）简称 SLAM 技术就是研究如何让机器人在确定自身方位的同时构建环境地图。

随着计算机、传感系统和人工智能等技术的蓬勃发展，各种智能系统，如地面移动机器人、水下机器人及空中无人机等，已经逐渐融入人们的日常生活和生产活动中。这些自主无人系统的广泛应用，让自主导航技术的重要性愈发凸显，特别是在全球导航卫星系统（Global Navigation Satellite System, GNSS）无法覆盖的山区、丛林、地下、峡谷和室内环境中，SLAM 技术成为了实现自主导航的关键。

人类在陌生环境中常会依靠视觉观察具有明显特征的物体，通过估计与这些物体的相对空间关系确定自身位置，并利用物体之间的空间关系理解环境并规划路径，在按照该路线行进的同时，根据新观察到的信息不断估计自身相对位置，并逐步扩充和完善记忆的环境结构。类似地，家用扫地机器人通过激光雷达和摄像头收集周围环境数据，测量障碍物的距离和形状，并使用这些信息构建环境地图和规划移动路径，然后在移动过程中，持续地通过传感器数据进行定位并实时更新地图，以高效地完成清洁工作。

本章将探讨同步定位与建图的基本概念、实现平台、地图形式、基本方法以及技术难点，展示 SLAM 技术 1986 年之后的重大进步和技术变革。

10.1 同步定位与建图 SLAM 的概述

10.1.1 机器人自主定位与 SLAM 定义

在深入讨论 SLAM 之前，有必要先探究一下机器人自主定位的基本问题，机器人自主定位主要包括相对定位和绝对定位两种方式。

相对定位，又被称为位姿跟踪，在给定机器人初始位姿的条件下，采用相邻时刻的传感器信息估计位姿变换。相对定位一般存在误差累积，通常只适用于短时间或短距离定位。主要方法有：

- 1) 里程计法：利用机器人车轮上的光电编码器，通过航迹推测实现机器人位姿估计。
- 2) 惯性导航法：利用陀螺仪测得角速度和加速度计测得线加速度，通过积分得到机器人的姿态和位置。
- 3) 扫描匹配法：利用相邻两帧传感信息的匹配，估计机器人两帧之间的相对平移和旋转变换。例如，在图 10-1 中，(b) 和 (c) 分别表示机器人在两个不同位姿下获得的激光扫描数据，通过最小化两帧激光数据之间的匹配误差，估计出两帧之间的平移和旋转变换。




图 10-1 基于扫描匹配的相对定位

绝对定位，又称为全局定位，利用先验环境模型或全局定位传感器直接提供的位置数据计算机器人在全局坐标系中的位置，一般不存在误差累积，但可能会受到环境遮挡或信号干扰的限制。主要方法有：

1) 基于全球导航卫星系统定位：通过捕获跟踪卫星信号实现定位，适用于室外定位。

当前联合国卫星导航委员会 ICG 认定的全球卫星导航系统的四大核心供应商有：美国的 GPS、俄罗斯的 GLONASS、中国的北斗和欧盟的 Galileo。

美国：全球定位系统（GPS），共有 24 颗工作卫星，1978 年首次发射，1994 年建成。定位精度为 0.3–5.0 m。

俄罗斯：全球导航卫星系统（GLONASS），共有 24 颗工作卫星，1982 年首次发射，1995 年建成。定位精度为 2.8–7.4 m。

中国：北斗卫星导航系统（BDS），共有 30 颗工作卫星，2000 年首次发射，2020 年建成。北斗 2.0 版定位精度 1.2m，加密定位精度 0.1m。

欧盟：伽利略定位系统（GALILEO），共有 24 颗工作卫星，2011 年首次发射。2023 年，23 颗卫星在轨。2023 年 1 月公布的定位精度为 0.2m。

- 2) 基于信标定位: 观测人工或自然路标, 利用三边测量 (Trilateration) 或三角测量 (Triangulation) 原理进行定位。

如图 10-2 所示, 在三边测量定位方法中, 已知二维平面上三个路标位置 and 机器人到三个路标的观测距离, 并以此构建距离约束方程, 求解机器人的二维位置。例如, 在储油罐中作业的机器人通常装有超声测距传感器, 可利用三边测量原理进行定位。如图 10-3 所示, 机器人搭载超声发射单元, 储油罐罐壁安装多组位置已知的超声接收单元, 通过测量超声信号从发射单元到接收单元之间的传播时延计算机器人与接收单元之间的距离, 利用三边测量原理解算出机器人在全局坐标系中的位置。




图 10-2 三边定位原理




图 10-3 储罐机器人定位

如图 10-4 所示, 在三角测量定位方法中, 已知三个路标位置和机器人扫描路标得到的夹角, 利用三角函数原理构建位置约束方程, 可使用最小二乘法等方法求解机器人位置。

如图 10-5 所示, 自动导向车 (Automated Guided Vehicle, AGV) 安装的激光扫描器发出旋转的激光束由环境中设置的多组反光板反射回来, 回传旋转激光遇到反光板时的角度信息, 此时计算 AGV 在全局坐标系中的位置就采用的是三角测量原理。




图 10-4 三角定位原理



图 10-5 激光反光板定位

- 3) 基于地图匹配定位: 利用传感器信息与预先存储好的地图进行匹配, 计算出机器人在全局坐标系中的位姿。

如图 10-6 所示, 假设环境地图已知, 机器人利用车载的激光传感器扫描环境, 获得激光点云数据 (红色部分)。机器人将激光点云或点云特征与先验的环境地图进行匹配, 从而计算出自身在环境中的位置和姿态。




图 10-6 基于地图的匹配定位

相对定位与绝对定位的对比如表 10.1 所示。

表 10.1 相对定位与绝对定位对比

比较维度	相对定位	绝对定位
实时性	高，依赖传感器数据实时更新	中，依赖外部基准，更新频率受限制
误差特性	误差累积，时间越长误差越大	误差不累积，定位精度稳定
依赖性	低，不依赖外部基准	高，依赖外部基准（GNSS、已知地图）
实现难度	低，算法简单，计算量小	高，需额外硬件设备或预先构建地图
适用范围	短时间、短距离定位	大范围、长时间定位
环境限制	传感器噪声影响大，适用未知环境	需外部信号支持，不适用于无信号环境

在实际的机器人导航中，定位和建图通常交织在一起。理想情况下，若环境地图精确已知，但机器人位姿未知，则可利用上述方法计算机器人在地图中的位姿；反之，若机器人位姿已知但环境地图未知，则可将不同位姿上获得的传感器数据进行拼接或融合，实现增量式建图。然而，实际应用中，机器人位姿和环境地图常常都是未知的，这就引出了“先有鸡还是先有蛋”的问题。SLAM 技术的目标是将定位和建图问题综合考虑，同步在线地完成机器人状态估计与环境地图构建。

同步定位与建图（SLAM）定义：在没有环境先验信息的条件下，机器人在移动中感知周围环境，确定自身的运动状态（位置、姿态、速度等），同时根据这些信息增量式构建环境地图。

自 1986 年 Randall C. Smith 和 Peter Cheeseman 首次提出 SLAM 问题以来^[1]，SLAM 技术得到了飞速发展并取得了显著成果，许多实现方案已被应用于生产和日常生活中。

SLAM 的定位既涉及相对定位也涉及绝对定位。很多 SLAM 系统解决的是相对定位问题，通过传感器（如激光雷达、相机、IMU 等）实时获取环境信息和运动数据，以此估计机器人的相对位姿（位置和姿态的变化）。SLAM 系统依赖连续时刻的传感器数据进行位姿更新，因此存在误差累积的问题。同时，解决相对定位问题的 SLAM 系统中也包含一些绝对定位的成分，SLAM 在构建环境地图的过程中，通过识别和关联环境中的特征点，建立了机器人相对于地图的位姿关系，这相当于在构建一个绝对定位的基准。特别是通过回环检测（即机器人重新访问已知位置并识别出这一位置），SLAM 系统可以校正累积误差，从而实现全局一致的位姿和地图更新，这一过程类似于绝对定位。

此外，还有一些 SLAM 系统关注绝对定位问题。每一时刻都维护机器人相对于全局坐标系的位姿，并不断利用新的观测或回环信息优化和校正全局位姿，尽量消除定位误差的累积。

综上，SLAM 是一种综合了相对定位和绝对定位技术的复杂系统，旨在获取准确的运动状态并构建环境地图。

10.1.2 SLAM 的基本流程

如图 10-7 所示，典型的 SLAM 算法主要包括以下几个关键步骤：




图 10-7 SLAM 的基本流程

- 1) **特征提取**是指从传感器数据中提取出具有代表性和区分性的信息，如点特征和点云特征。在视觉系统中，特征提取通常通过分析图像中的颜色和纹理信息，计算像素点的梯度来识别梯度值高的特征点，并计算描述子向量以表征其独特性。激光和 RGB-D 视觉则利用点云（或经过降采样的点云）提取角点、面点、线段和平面等结构特征。
- 2) **数据关联**是指通过匹配连续两帧数据中的特征，建立它们之间的对应关系。这是实现帧间状态估计的基础。在视觉 SLAM 中，数据关联通常采用光流跟踪和描述子匹配方法，前者基于光度不变假设计算连续两帧图像之间的光流，完成特征点的匹配；后者通过比较不同帧之间特征描述子的相似性进行匹配。激光 SLAM 中，数据关联则主要依赖于点云的最近邻匹配，涉及到暴力搜索、体素搜索、kd 树搜索等搜索算法。
- 3) **状态估计**主要涉及机器人自身的位姿估计和环境地图的构建，常用的框架分为滤波和优化两类。滤波框架将机器人的位姿与地图中特征参数作为系统状态，传感器测量值作为系统观测，通过递推更新的方式估计机器人和环境地图的状态。优化框架将机器人位姿与地图中特征参数作为优化变量，利用传感器的测量数据建立约束关系，通过最小化损失函数估计优化变量。帧间状态估计利用帧间数据关联估计当前帧的机器人位姿以及特征参数，此过程在基于优化的 SLAM 方法中常被称为“前端”。
- 4) **回环检测**主要解决位姿估计随时间漂移的问题，由于连续两帧之间的位姿估计是增量式的，长时间运动后累积的误差会导致位姿估计与实际值出现较大偏差，此时通过回环检测建立当前观测与历史观测之间的关联关系校正位姿是必需的。回环检测类似于数据关联，但涉及到长时间运动和累积误差后的匹配，难度较大。在视觉 SLAM 中，回环检测常用词袋（Bag-of-Words, BoW）模型^[2]，而激光 SLAM 中，则可能依赖于描述子匹配和位置信息。
- 5) **回环校正**利用检测到的回环信息调整机器人轨迹和全局地图，以减小误差，得到全局一致的轨迹和地图。在滤波框架中，机器人利用回环误差计算新息（Innovation），更新系统状态，得到校正后的位姿和环境地图；而在优化框架中，则是利用回环信息构建回环约束，与其他约束一同进行非线性优化，进而得到全局一致的机器人轨迹和环境地图，这一过程对应优化框架的“后端”。

以上步骤共同构成了 SLAM 的主要流程，确保了机器人在未知环境中能够有效地进行自我定位和环境建图。

10.1.3 典型的 SLAM 系统

SLAM 系统可以根据使用的传感器类型大致分为激光 SLAM 和视觉 SLAM 两大类，这两类系统是目

前 SLAM 领域内最为关注的分支。

激光 SLAM: 早期 SLAM 系统主要基于 2D 激光雷达，例如 Gmapping^[3]和 Karto^[4]，这些系统通常用于室内小规模环境的地图构建。随着技术的发展，3D 激光雷达的使用日益普遍，激光 SLAM 扩展到了更大规模和更复杂的室外非结构化环境。LOAM^[5]算法为 3D 激光 SLAM 提供了重要的基础。

视觉 SLAM: 与激光雷达相比，得益于相机小巧、成本低廉和信息丰富的特点，视觉 SLAM 受到了广泛关注。ORB-SLAM2^[6]及其升级版 ORB-SLAM3^[7]是基于特征点方法的代表性算法，它们能在广阔的环境中实现实时定位和稀疏地图构建，是当前最经典的视觉 SLAM 算法。此外，直接法的算法如 DSO^[8]，在处理低纹理环境和快速运动的情况下展现了更高的鲁棒性。

多传感器融合 SLAM: 为了提高 SLAM 算法的性能，近年来出现了多种基于多传感器融合的方法，如基于滤波框架的 FAST-LIO2^[9]和 ROVIO^[10]以及基于优化框架的 LIO-SAM^[11]和 VINS^[12]等，它们结合了激光雷达或者相机和 IMU 的数据，提高了定位和地图构建的精度和稳定性。

深度学习在 SLAM 中的应用: 最近几年，深度学习技术也被引入到 SLAM 领域。例如，DeepVO^[13]和 LO-NET^[14]等算法采用端到端的方法，通过深度网络处理 SLAM 问题，展现了这一领域的新发展方向。

表 10-2 是一些代表性 SLAM 系统的总结，展示了 SLAM 技术在不同应用场景和不同技术路线上的多样化和专业化发展。

表 10-2 典型的 SLAM 系统

算法名称	传感器配置	状态估计方法
Gmapping (2007 年)	2D 激光雷达	滤波 (粒子滤波)
Karto (2010 年)	2D 激光雷达	优化
LOAM (2014 年)	3D 激光雷达	优化
FAST-LIO2 (2022 年)	3D 激光雷达+IMU	滤波 (IEKF)
LIO-SAM (2020 年)	3D 激光雷达+IMU	优化
ORB-SLAM 系列 (2015 年, 2017 年, 2021 年)	单目/双目+IMU	优化
DSO (2017 年)	单目/双目	优化
ROVIO (2017 年)	单目+IMU	滤波 (IEKF)
VINS 系列 (2018 年, 2019 年)	单目/双目+IMU	优化
DeepVO (2017 年)	单目	深度网络 (ConvNet+RNN)
LO-NET (2019 年)	3D 激光雷达	深度网络 (DCNN)

10.1.4 SLAM 的应用

随着机器人技术的发展，SLAM 已被广泛应用到众多领域中，并发挥出越来越显著的作用。

- 1) 生活服务：在家庭、商超、酒店等场景中，SLAM 技术得到了一定程度的应用。例如，迎宾机器人通过 SLAM 实现精准定位及路径规划，从而完成自主移动和人员引导，提升服务能力和用户体验；扫地机器人能够借助环境信息精确地规避障碍物，避免碰撞和意外，保证运行安全。

- 2) 安防巡检：在变电站、机场跑道、大型楼宇等场景中，机器人可以利用 SLAM 技术完成大规模环境下的自主导航，进而快速、准确地检查设施的运行状况，监测潜在的安全隐患，如电力设备故障、跑道损坏、楼宇设施异常等，从而弥补人工巡检存在的风险高、效率低、误报率高等不足。
- 3) 物流配送：在机场、港口、社区等物流运输应用中，SLAM 技术能够使快递车、无人机准确定位货物位置，进行智能分拣和装载，从而提高配送效率，减少人力成本。
- 4) 智慧交通：作为智慧交通的一个重要发展方向，自动驾驶受到了广泛关注，其利用 SLAM 提供定位、避障、地图构建等技术支持。现阶段，谷歌、滴滴、百度等自动驾驶技术研究公司均有无人车产品推出。然而，受限于城市道路场景的复杂性和不确定性，目前该项技术仍有很大的发展空间。
- 5) 特种作业：SLAM 技术不仅可以应用于矿山开采、地质勘察、气体泄漏检测等特殊服役任务，还可以应用于地震救援、深海勘测、太空探索等极端危险的场景中，从而完成人所难及和人所不及的任务。
- 6) 消费娱乐：现如今 SLAM 技术已经渗透到了生活的方方面面。例如，家居设计师可以利用增强现实（Augmented Reality, AR）技术将装修设计效果直观展示给消费者，其中的虚拟家具摆放就是依赖于 SLAM 技术进行定位和建模的。此外，近年来风靡的虚拟现实（Virtual Reality, VR）游戏等同样应用了 SLAM 技术。

10.2 SLAM 的实现平台

10.2.1 SLAM 的传感设备

SLAM 技术主要利用两大类传感设备：激光雷达和相机。激光雷达通过测量光波与物体反射的时间差获取环境信息，而相机则通过捕捉光线形成图像获取环境信息。

激光雷达：根据扫描方式的不同，激光雷达可分为机械式激光雷达、半固态激光雷达和全固态激光雷达，具体如表 10-3 所示。

表 10-3 激光雷达分类

激光雷达类型	具体分类		扫描方式
机械式激光雷达	单线激光雷达		发射器和接收器在电机的带动下进行360°旋转扫描
	多线激光雷达		
半固态激光雷达	转镜类	一维转镜	发射器和接收器固定不动，电机带动光学器件进行旋转，实现激光束的扫描
		二维转镜	
	MEMS 振镜类		
	棱镜类		
全固态激光雷达	OPA 固态激光雷达		不具备任何机械摆动结构，使用半导体技术实现光束的发射、扫描和接收
	Flash 固态激光雷达		

相机：按照结构组成的不同，相机大致可以分为七种，这些相机能够为 SLAM 系统提供丰富的视觉数

据，具体如表 10-4 所示。

表 10-4 相机分类

相机类型	主要结构	特点
单目相机 (Monocular)	单个摄像头	捕获二维图像，提供像素、纹理信息，无法直接获取深度信息
双目相机 (Stereo)	两个摄像头	捕获两个不同视角的二维图像，模拟人眼获取视差信息，推算出深度信息
深度相机 (RGB-D)	RGB 摄像头 +深度传感器	同时捕获彩色图像和深度图像，能够直接输出深度信息
全景相机 (Panoramic)	多镜头系统+图像传感器+ 同步控制系统	捕获完整的全景图像，提供全方位的视角覆盖
事件相机 (Event)	事件产生器+感光元件 +光学透镜系统	独立且异步地检测每个像素，在亮度变化发生时报告亮度变化，否则保持沉默，适用于高动态和高速度环境
光场相机 (Light Field)	微透镜阵列+图像传感器+ 光场计算引擎	不仅捕获传统的二维图像信息，还能捕获场景中的光线方向和强度信息
热成像相机 (Thermal Imaging)	红外传感器+信号处理器+ 光学透镜系统	捕获物体发出的热辐射或周围环境的能量分布，并将其转换为可见的热图像

除此之外，SLAM 技术还可以结合其他类型的传感器，如超声波传感器、射频识别 (Radio Frequency Identification, RFID)、Wifi 阵列等，以提升环境感知的准确性和鲁棒性。

10.2.2 SLAM 系统的部署平台

SLAM 系统可部署在多种移动平台上，具体取决于应用场景和执行任务的需求。常见的移动平台包括地面移动机器人、无人飞行器 (无人机)、无人驾驶汽车等，这些平台通常搭载激光雷达或相机等传感器，以实现在未知环境中的有效定位和导航。

随着技术的进步和应用范围的扩展，SLAM 系统的部署平台也在不断增加。在特殊领域如水下勘探、极地科考、灾难搜救中，SLAM 技术被应用于水下机器人、扑翼飞行器和各种特种机器人，以更好地完成高难度任务。此外，SLAM 技术还被集成到可穿戴设备、手持设备和 VR 眼镜中，用于实现测绘、AR 和 VR 技术。

图 10-8 展示了 SLAM 技术的各种应用平台，从传统的机器人到现代的智能设备，SLAM 的实用性和灵活性得到了广泛的证明。



(a) 地面机器人



(b) 无人飞行器




(c) 无人驾驶车^[15]




(d) 水下机器人^[16]



(e) 扑翼飞行器



(f) 特种机器人^[17]



(g) 可穿戴设备^[18]



(h) 手持设备



(i) VR 眼镜

图 10-8 SLAM 的应用平台

10.3 SLAM 的地图形式

10.3.1 点云地图

点云地图 (Point Cloud Map) 通常由多帧激光雷达或深度相机等传感器采集的数据构建而成，是一系列描述三维空间中物体位置信息的离散点。如图 10-9 所示，点云地图能够准确地描述环境中物体的形状及位置，但存储和计算代价高。




图 10-9 点云地图

10.3.2 特征地图

在构建特征地图 (Feature Map) 时，机器人利用激光雷达、相机等传感器提取环境中的特征，同时追踪这些特征的位置及机器人位姿，并生成由特征组成的环境地图。如图 10-10 所示，常见的三种特征包括点、线 (线段) 以及平面。另外，有些工作使用了面元 (Surfel) 和形状等作为特征，提升了鲁棒性，但这些特征的计算较为复杂。




图 10-10 特征地图

10.3.3 拓扑地图

拓扑地图 (Topological Map) 由节点和边组成, 节点表示环境中的重要区域 (例如路口), 边表示节点之间的连通关系, 如图 10-11 所示。拓扑地图不需要计算边的长度和形状, 只维护边的连通关系, 计算简单、存储量小且利于路径规划, 但对环境缺少精确的定量描述。




图 10-11 拓扑地图

10.3.4 栅格地图

栅格地图又称为占据栅格地图 (Occupancy Grid Map), 它使用由大小相等的栅格组成的网格表示地图, 栅格里存储的数值表示该栅格被占据的概率。对栅格地图进行可视化时, 一般选择不同的颜色表示地图的不同状态, 图 10-12 (a) 中立体栅格和图 10-12 (b) 中的黑色栅格代表障碍物, 白色栅格代表自由区域。栅格地图常用于导航规划, 其中三维栅格实现了对环境的有效描述, 不过存储空间开销较大; 而二维栅格占据的存储空间小, 但只能存储环境中一个切面的障碍信息。




图 10-12 栅格地图

10.3.5 语义地图

语义地图（Semantic Map）是用来描述环境语义信息的地图形式，它不仅包含了环境的几何信息，还包含了环境中物体、实例的语义信息（类别、形状等）。语义地图通常被可视化为如图 10-13 所示的形式，其中不同颜色代表着不同的语义类别，例如汽车、车道以及树木等。地图中的语义信息通常需要人工标注，或通过有监督学习进行自动标注。




图 10-13 语义地图

10.3.6 指纹地图

指纹地图（Fingerprint Map）是一种利用已知位置的无线接入点（Wireless Access Point, WAP）所发射信号的强度信息建立的地图，其中无线信号可以是 Wifi 信号或蓝牙信号等。使用指纹地图进行定位时，移动终端在定位点接收到信号强度及物理地址，并与指纹地图中存储的定位参考点进行匹配，进而估算出当前位置。

10.3.7 混合地图

地图的表现形式很大程度上取决于机器人的任务、传感器以及环境类型，有时候单一地图表达形式很难满足需求，通常会采用混合地图（Hybrid Map）的表达形式，例如特征地图与拓扑地图混合，混合后的地图不仅具有拓扑地图的高效性，还具有特征地图的精确性和一致性。

10.4 SLAM 的基本方法

SLAM 的基本方法可以分为三类：传统的 SLAM 方法、端到端的深度学习方法 and 前两类的结合。

传统的 SLAM 方法遵循问题建模—估计求解的思路，基于多视图几何、点云配准等原理，能取得较为准确的估计结果。目前，传统的 SLAM 方法在 SLAM 领域仍占主导地位，概括地说，一般包括特征提取、数据关联、帧间状态估计、回环检测和回环校正五个环节，具体的实现框架包括滤波框架和优化框架。基于滤波框架的 SLAM 方法实时性好、计算复杂度低，但精度略低；基于优化框架的 SLAM 方法具有更高的精度、更适用于大规模复杂环境，但相应的计算复杂度较高、实时性较差。SLAM 技术发展初期以滤波框架为主导，随着处理器算力的提升和 SLAM 系统灵活性需求的增高，目前优化框架成为了 SLAM 技术

的主导。

端到端的深度学习方法从输入的传感器数据直接输出机器人的运动轨迹与环境地图, 此类方法最近几年受关注度逐渐上升。对视觉传感器而言, 深度网络的输入一般为图像序列, 输出为机器人位姿和视觉深度地图 (即图像每个像素的深度); 对激光雷达而言, 网络的输入一般为点云帧序列, 输出为机器人的位姿以及环境的点云地图。基于深度学习的方法依赖于大样本离线训练, 目前的泛化能力较弱且准确性较低。

两者结合的 SLAM 方法通常使用深度神经网络实现传统 SLAM 方法中的某些环节, 例如特征提取和匹配、回环检测等, 以进一步提升 SLAM 系统的准确性和鲁棒性。

10.4.1 传统的 SLAM 方法

传统的 SLAM 方法一般先进行特征提取与匹配, 为后续的状态估计和回环检测提供约束。具体的状态估计包括滤波框架和优化框架两种实现形式。

1. 传统 SLAM 的滤波框架

滤波框架的核心问题是状态的递推估计, 其系统状态包括机器人的位姿与地图中特征 (如点、线、面等) 的参数, 地图中的特征一般称为路标 (Landmark), 系统的观测为传感器的测量值。

1) 滤波框架的主要思想

滤波框架一般包括预测与更新两步。如图 10-14 所示, 矩形表示机器人, 上方的圆形表示传感器, 星形表示路标, 初始时刻机器人通过传感器测量和特征提取获得路标的参数。机器人向前运动一步, 并利用里程计和运动模型预测自身位姿 (图 (b) 中虚线矩形)。之后机器人再一次测量到路标, 由于运动与测量噪声, 机器人发现此时系统状态与预测的并不一致, 则利用对路标的观测, 计算自身的位姿 (图 (d) 中实线矩形)。然后机器人将上述两个位姿估计结果进行融合, 得到更新后的更加准确的位姿估计 (图 (e) 中位于中间的实线矩形)。




图 10-14 滤波框架的主要思想

2) 基于滤波框架 SLAM 的代表性方法

SLAM 问题中常用的滤波器包括粒子滤波器 (Particle Filter, PF)、扩展卡尔曼滤波器 (Extended Kalman Filter, EKF) 和迭代扩展卡尔曼滤波器 (Iterative Extended Kalman Filter, IEKF), 下面将分别进行介绍。

(1) 粒子滤波器 PF

粒子滤波基于蒙特卡洛方法，用后验概率中随机抽取的粒子集合对目标概率密度函数进行近似，其最大特点是原理与实现都较为简单，能够处理非线性、非高斯系统的状态估计。粒子滤波一般包括初始化、预测、更新和重采样四个步骤。

粒子滤波定位的核心思想为：用很多个粒子代表机器人的位姿，每个粒子的权重表示该粒子对应位姿的可信度。在预测阶段，根据机器人的控制信息（速度、转角等）与运动模型，预测下个时刻的粒子分布；在更新阶段，根据机器人的观测值与预测的观测值的接近程度计算出每个粒子的新的权重。最后，在重采样阶段，根据粒子的权重重新采样粒子。随着 SLAM 的进行，粒子的平均位姿会逐渐接近真实的机器人位姿。

图 10-15 展示了粒子滤波定位过程。图（a）表示初始时刻，在没有任何先验信息的情况下，在环境的自由空间中按照均匀分布进行采样，得到的粒子集合代表机器人可能的位姿。图（b）表示由于环境结构的相似性，当前的传感器数据不足以区分出机器人处于位姿 1 还是位姿 2。图（c）表示在机器人行走一段距离后，由于采集到了更多的外部传感器数据，机器人对自身的位姿估计更加确信，绝大多数粒子都汇聚到了真实位姿附近，消除了图（b）中的歧义性。




图 10-15 粒子滤波定位示意图^[19]

Gmapping 是代表性的基于 RBPF (Rao-Blackwellized Particle Filters) 的 SLAM 算法，它使用的传感器为 2D 激光雷达。相对于传统的粒子滤波器而言，RBPF 将高维非线性系统的状态估计问题分解为多个低维子系统的估计问题，然后使用粒子滤波器进行估计。同时，Gmapping 对 RBPF 计算中的一些环节加以进一步优化，提高了分布采样的位姿质量，并降低了重采样次数，缓解了粒子耗散的问题。

(2) 卡尔曼滤波器、扩展卡尔曼滤波器 EKF 和迭代扩展卡尔曼滤波器 IEKF

卡尔曼滤波是一种利用线性系统状态方程，通过系统的观测数据，对系统状态进行最优估计的算法。由于观测数据中通常包含噪声，这个最优估计也可以看作是一个滤波的过程。与粒子滤波器处理非线性系统和非高斯分布的情况不同，卡尔曼滤波器主要针对线性高斯系统的状态进行估计。

SLAM 求解的一般是非线性系统的估计问题，针对线性问题的卡尔曼滤波器并不能直接适用，因此一般采用 EKF 或 IEKF 解决 SLAM 问题。EKF 的主要思想是对非线性系统的状态方程或者观测方程进行线性近似，之后根据卡尔曼滤波的原理进行求解。

针对线性、高斯系统，卡尔曼滤波一般用式 (10.1) 进行描述：

$$\begin{aligned}\mathbf{x}_{k+1} &= \mathbf{A}_k \mathbf{x}_k + \boldsymbol{\omega}_{k+1} \\ \mathbf{y}_k &= \mathbf{C}_{k+1} \mathbf{x}_{k+1} + \mathbf{v}_{k+1}\end{aligned}\quad (10.1)$$

其中 $\mathbf{A}_k$ 为状态转移矩阵， $\mathbf{C}_{k+1}$ 为观测矩阵； $\mathbf{x}_k$ 、 $\mathbf{x}_{k+1}$ 为系统在 k 时刻和 $k+1$ 时刻的状态， $\boldsymbol{\omega}_{k+1}$ 为状态模型的噪声； $\mathbf{y}_{k+1}$ 为系统在 $k+1$ 时刻的观测数据； $\mathbf{v}_{k+1}$ 为观测的噪声； $\boldsymbol{\omega}_{k+1}$ 和 $\mathbf{v}_{k+1}$ 均为零均值高斯白噪声，即 $\boldsymbol{\omega}_{k+1} \sim N(0, \mathbf{Q}_{k+1})$, $\mathbf{v}_{k+1} \sim N(0, \mathbf{R}_{k+1})$ ， $\mathbf{Q}_{k+1}$ ， $\mathbf{R}_{k+1}$ 是两个噪声服从的高斯分布的协方差矩阵。

针对 SLAM 问题而言，系统在各个时刻的状态为向量 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k, \dots$ ，通常包括机器人位姿和环境路标参数。一般用式 (10.2) 对系统进行描述：

$$\begin{aligned}\mathbf{x}_{k+1} &= f(\mathbf{x}_k, \mathbf{u}_{k+1}, \boldsymbol{\omega}_{k+1}) \\ \mathbf{y}_{k+1} &= g(\mathbf{x}_{k+1}, \mathbf{v}_{k+1})\end{aligned}\quad (10.2)$$

其中， $f(\cdot)$ 为系统状态方程，描述系统如何从状态 $\mathbf{x}_k$ 转移到状态 $\mathbf{x}_{k+1}$ ； $\mathbf{u}_{k+1}$ 为系统在 $k+1$ 时刻的输入； $g(\cdot)$ 为观测方程，描述系统如何在状态 $\mathbf{x}_{k+1}$ 得到观测结果 $\mathbf{y}_{k+1}$ 。

定义： $\hat{\mathbf{x}}_{k|k}$ 为 k 时刻对当前状态的估计； $\hat{\mathbf{x}}_{k+1|k}$ 为 k 时刻对 $k+1$ 时刻状态的预测； $\tilde{\mathbf{x}}_k = \mathbf{x}_k - \hat{\mathbf{x}}_{k|k}$ 为 k 时刻状态估计的偏差； $\tilde{\mathbf{x}}_{k+1} = \mathbf{x}_{k+1} - \hat{\mathbf{x}}_{k+1|k}$ 为 k 时刻状态预测的偏差； $\mathbf{P}_{k|k} = E(\tilde{\mathbf{x}}_k \tilde{\mathbf{x}}_k^T)$ 为 $\hat{\mathbf{x}}_{k|k}$ 的协方差矩阵； $\mathbf{P}_{k+1|k} = E(\tilde{\mathbf{x}}_{k+1} \tilde{\mathbf{x}}_{k+1}^T)$ 为 $\hat{\mathbf{x}}_{k+1|k}$ 的协方差矩阵。

在使用 EKF 求解 SLAM 的非线性问题时，一般对 (10.2) 中的运动方程 $f(\cdot)$ 和观测方程 $g(\cdot)$ 进行线性化近似：

$$\begin{aligned}f(\mathbf{x}_k, \mathbf{u}_{k+1}, \boldsymbol{\omega}_{k+1}) &\approx f(\hat{\mathbf{x}}_{k|k}, \mathbf{u}_{k+1}, 0) + \left. \frac{\partial f}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_{k|k}} \tilde{\mathbf{x}}_k + \frac{\partial f}{\partial \boldsymbol{\omega}_{k+1}} \boldsymbol{\omega}_{k+1} \\ g(\mathbf{x}_{k+1}, \mathbf{v}_{k+1}) &\approx g(\hat{\mathbf{x}}_{k+1|k}, 0) + \left. \frac{\partial g}{\partial \mathbf{x}_{k+1}} \right|_{\mathbf{x}_{k+1|k}} \tilde{\mathbf{x}}_{k+1} + \frac{\partial g}{\partial \mathbf{v}_{k+1}} \mathbf{v}_{k+1}\end{aligned}\quad (10.3)$$

经过线性化之后，系统可以近似为一个线性高斯系统，一般来说，SLAM 系统中输入 $\mathbf{u}_{k+1}$ 已知，通常为里程计等信息，此时式 (10.2) 可以写成类似式 (10.1) 的形式，其中：

$$\mathbf{A}_k = \left. \frac{\partial f}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_{k|k}}, \mathbf{C}_{k+1} = \left. \frac{\partial g}{\partial \mathbf{x}_{k+1}} \right|_{\mathbf{x}_{k+1|k}}\quad (10.4)$$

基于 EKF 的 SLAM 通常包括以下四个迭代步骤：

① 运动预测：通过里程计等信息预测出下一时刻机器人的状态。这里涉及到对状态值 $\hat{\mathbf{x}}_{k+1|k}$ 和它的方差 $\mathbf{P}_{k+1|k}$ 的计算，具体为：

$$\begin{aligned}\hat{\mathbf{x}}_{k+1|k} &= \mathbf{A}_k \hat{\mathbf{x}}_{k|k} \\ \mathbf{P}_{k+1|k} &= \mathbf{A}_k \mathbf{P}_{k|k} \mathbf{A}_k^T + \mathbf{Q}_{k+1}\end{aligned}\quad (10.5)$$

② 观测：通过传感器获取传感数据，并从中提取环境特征；

③ 数据关联：将新测量的特征与地图中的路标进行匹配，确定它们的对应关系；

④ 更新：通过关联上的特征的预测信息与观测信息计算出系统的新息，用于更新系统的状态。具体为：

首先，对下一时刻来自于路标的观测信息进行预测，即在 k 时刻预测 $k+1$ 时刻的观测 $\hat{\mathbf{y}}_{k+1|k}$ ：

$$\hat{\mathbf{y}}_{k+1|k} = \mathbf{C}_{k+1} \hat{\mathbf{x}}_{k+1|k} \quad (10.6)$$

之后在 $k+1$ 时刻获得传感器的观测数据 $\mathbf{y}_{k+1}$ ，计算新息 $\tilde{\mathbf{y}}_{k+1|k}$ ：

$$\tilde{\mathbf{y}}_{k+1|k} = \mathbf{y}_{k+1} - \hat{\mathbf{y}}_{k+1|k} \quad (10.7)$$

利用新息进行状态更新：

$$\hat{\mathbf{x}}_{k+1|k+1} = \hat{\mathbf{x}}_{k+1|k} + \mathbf{K}_{k+1} \tilde{\mathbf{y}}_{k+1|k} \quad (10.8)$$

其中，

$$\mathbf{K}_{k+1} = \mathbf{P}_{k+1|k} \mathbf{C}_{k+1}^T (\mathbf{C}_{k+1} \mathbf{P}_{k+1|k} \mathbf{C}_{k+1}^T + \mathbf{R}_{k+1})^{-1} \quad (10.9)$$

$\mathbf{K}_{k+1}$ 是在 $k+1$ 时刻的卡尔曼增益，更新后的系统状态协方差为：

$$\mathbf{P}_{k+1|k+1} = (\mathbf{I} - \mathbf{K}_{k+1} \mathbf{C}_{k+1}) \mathbf{P}_{k+1|k} \quad (10.10)$$

上述四个步骤迭代运行，即可完成 SLAM 的状态估计。

EKF 在 2D 激光雷达的 SLAM 方法中较为常用，而近年来，也开始应用于 3D 激光雷达与 IMU 的融合中，其中具有代表性的方法是 FAST-LIO2。FAST-LIO2 是一种计算效率较高、且鲁棒性较强的激光-惯导里程计，它利用 IEKF 将激光雷达与 IMU 数据进行融合，在机器人快速运动以及噪声或杂波环境中实现较为鲁棒的定位建图。为了降低在测量数据量过大的情况下滤波器的计算量，FAST-LIO2 提出了一个新的计算卡尔曼增益的方法，降低了计算复杂度。此外，基于 EKF 的 SLAM 算法还包括基于视觉-惯导的 ROVIO 等。

2. 传统 SLAM 的优化框架

相对于滤波框架而言，基于优化框架的 SLAM 类似于求解只有观测方程的状态估计问题。具体而言，根据传感器的测量数据，可以建立新的观测信息与地图之间的约束关系，构建损失函数，从而优化机器人

的位姿和地图信息。

1) 优化框架的主要思想

优化框架一般分为两个模块——前端和后端。在前端，通过对连续两帧数据中的特征进行匹配，建立特征之间的关联关系，同时也可以融合 IMU 信息，然后计算机器人的位姿变换，前端实际上实现的是里程计，一般要求实时在线完成。另外，在前端还要进行回环检测，为后端的回环优化提供约束。

优化框架的后端主要完成机器人位姿以及地图的维护与优化，一般采取图优化实现。具体来说，以关键帧（在局部范围或一定时间内选出的具有代表性的一帧）对应的机器人位姿和地图中的路标参数作为节点，路标到各个关键帧的重投影误差作为边（约束关系）构建图，然后进行图优化，即通过调整节点的状态，使之满足边的约束，从而校正机器人位姿和地图，这一优化过程一般称为光束平差法（Bundle Adjustment, BA）。后端通常采用非线性优化技术来实现，如高斯牛顿法等，常用的优化库包括 `ceres`、`g2o` 等。一般来说，后端优化的计算量较大，往往不能实时运行。

2) SLAM 中的典型优化策略

对于优化框架的 SLAM 而言，采取哪种优化策略，即如何组织优化变量，是需要重点考虑的问题，下面将介绍一些 SLAM 中的典型优化策略。

（1）单帧优化


对于里程计而言，一般采取单帧优化的优化策略。具体而言，系统每获取一帧数据（图像或点云等），在完成特征提取后，与上一帧数据（或局部地图）的特征进行匹配，基于建立的匹配关系，优化当前帧相对于上一帧（或地图）的位姿变换。

著名的 2D 激光 SLAM 算法 Karto 和 3D 激光 SLAM 算法 LOAM 采用了单帧优化的优化策略。例如，在 LOAM 中，前端将当前帧与上一帧的点云进行特征匹配，用于求解位姿，一般能达到 10Hz 左右的频率，满足实时运行的要求；而后端将当前帧与地图进行特征匹配，用于优化位姿，频率一般在 1Hz 左右。另外，许多视觉 SLAM 方案在前端也都选择了单帧优化的优化策略。

（2）滑动窗口优化

单帧优化并不涉及到历史位姿的优化，容易导致误差的累积，影响定位与建图的效果。反之，如果每获得一帧新的传感数据就优化当前和所有的历史位姿，以及整个地图，则会产生巨大的计算代价。为了平衡所用信息量与计算时间，研究人员提出了滑动窗口优化的优化策略，即通过滑动窗口组织固定长度的关键帧序列，对它们的位姿进行优化。一般情况下，滑动窗口内的关键帧具备时间上的相邻关系，例如 DSO；也有通过局部回环在滑动窗口内引入回环关键帧的处理方式，例如 VINS。

如图 10-16 所示，在 VINS 中，滑动窗口内的关键帧有时间上与当前帧比较靠近的关键帧 $(x_0, x_1, \dots, x_4)$ ，也有通过局部回环检测引入的能够形成共视关系的关键帧 (x_{v0}, x_{v1}, x_{v2}) ， f_0, f_1, f_2, f_3 表示地图中的特征点的位置。通过将地图中的特征向滑动窗口内的各个关键帧进行投影，并最小化重投影误差，即可实现对滑动窗口内的关键帧的位姿和地图中特征点的位置的优化。采用滑动窗口的代表性 SLAM 方法除了 VINS、DSO 之外，还包括视觉-激光-惯导紧耦合 SLAM 方法 R3LIVE^[20]。

图 10-16 滑动窗口^[12]

(3) 图结构优化

滑动窗口的优化策略主要用于 SLAM 前端，而在后端，常采用图结构优化策略，其中比较经典的是位姿图优化。

图 10-17 为位姿图的基本结构。当 SLAM 系统检测到回环时，将当前帧与回环涉及到的关键帧共同组成位姿图。利用位姿之间的约束关系，通过最小化当前帧和形成回环的关键帧之间的投影误差，即可实现对回环涉及到的所有关键帧以及当前帧的位姿的优化。





图 10-17 位姿图结构

除了传统的位姿图优化，近年来因子图优化也被 SLAM 领域广泛使用。LIO-SAM 的后端采用了典型的因子图优化的方法，其因子图结构如图 10-18 所示。其中， m_i 表示 IMU 的测量值， x_i 表示系统的状态， F_i 表示激光对应的关键帧。系统包含 IMU 预积分、激光里程计、GPS 以及回环四种因子，每个因子表示一种代价函数。对每一个关键帧，通过最小化上述不同因子的组合，得到关键帧的位姿估计结果。

图 10-18 因子图结构^[11]

3) 基于优化框架的 SLAM 代表性方法

近年来的 SLAM 以优化框架为主导，出现了许多有代表性的算法。为了进一步说明上述优化思想与优化策略的具体实现，在这里以 ORB-SLAM 为例，介绍基于优化框架的 SLAM 算法。




图 10-19 ORB-SLAM 系统框图

ORB-SLAM 的系统框架如图 10-19 所示。包含三个线程：跟踪线程、局部建图线程和回环线程。跟踪线程负责对每帧图像的相机位姿进行初始定位，并决定是否在局部地图中插入新的关键帧；局部建图线程负责处理关键帧，找到形成共视关系的关键帧，对这些关键帧的相机位姿和局部地图进行局部 BA 优化，并生成新的地图点；回环线程负责判断局部地图中的关键帧是否形成了回环，当检测到回环时，进行全局 BA 优化，进一步优化全局的地图和关键帧位姿。

在跟踪线程中，优化策略为单帧优化，优化变量为当前帧的相机位姿，代价函数为关联上的地图点到当前帧的重投影误差。假设一共有 N 个关联成功的地图点，则代价函数可写为：

$$\mathbf{T}_{cw} = \arg \min_{\mathbf{T}_{cw}} \sum_{i=1}^N [\mathbf{x}_i - \pi(\mathbf{T}_{cw}, \mathbf{X}_i)] \quad (10.11)$$

其中， $\mathbf{X}_i \in \mathbb{R}^3$ 为第 i 个关联上的地图点的三维坐标， $\mathbf{x}_i \in \mathbb{R}^2$ 对应的特征点的像素坐标， $\mathbf{T}_{cw}$ 为当前帧的相机位姿，即由世界坐标系到当前帧相机坐标系的位姿变换矩阵：

$$\mathbf{T}_{cw} = \begin{bmatrix} \mathbf{R}_{cw} & \mathbf{t}_{cw} \\ 0 & 1 \end{bmatrix} \quad (10.12)$$

其中， $\mathbf{R}_{cw}$ 为由世界坐标系到当前帧相机坐标系的旋转矩阵， $\mathbf{t}_{cw} \in \mathbb{R}^3$ 为两坐标系间的平移向量。式(10.11)

中的 $\pi(\cdot)$ 表示投影函数：

$$\pi(\mathbf{T}_{cw}, \mathbf{X}_i) = \begin{bmatrix} f_u \frac{x_i}{z_i} + c_u \\ f_v + c_v \end{bmatrix} \quad (10.13)$$

$$[x_i, y_i, z_i]^T = \mathbf{R}_{cw} \mathbf{X}_i + \mathbf{t}_{cw}$$

在局部 BA 优化和全局 BA 优化中，优化策略为图结构优化。这里的图结构是由若干个关键帧以及它们共同观测到的地图点组成的共视图，优化变量为形成共视关系的关键帧的相机位姿和观测到的地图点的

坐标，代价函数为地图点到各个关键帧的重投影误差。假设一共有 N_F 个关键帧和 N_p 个地图点，则代价函数可写为：

$$\{\mathbf{T}_{iw}, \mathbf{X}_j\} = \arg \min_{\mathbf{T}_{iw}, \mathbf{X}_j} \sum_{i=1}^{N_F} \sum_{j=1}^{N_p} [\mathbf{x}_{i,j} - \pi(\mathbf{T}_{iw}, \mathbf{X}_j)] \quad (10.14)$$

其中, $\mathbf{X}_j \in \mathbb{R}^3$ 为观测到的第 j 个地图点的三维坐标, $\mathbf{x}_{i,j} \in \mathbb{R}^2$ 为第 i 个关键帧上对应的特征点的像素坐标, $\mathbf{T}_{iw}$ 为第 i 个关键帧的相机位姿。通过局部 BA 和全局 BA, 对多帧的相机位姿和地图点坐标进行优化, 得到更准确的定位和建图结果。

10.4.2 基于深度学习的端到端 SLAM

随着深度学习技术的迅猛发展与机器人计算能力的提升, 深度学习技术已被越来越多地应用到 SLAM 领域。

1. 基本思路

端到端的 SLAM 属于完全数据驱动的 SLAM 方案, 它直接从大量的数据中学习从输入的传感器数据 (例如视觉、激光或其他传感器) 到输出 (例如位姿、地图或语义) 的映射关系, 如图 10-20 所示。端到端的 SLAM 利用深度网络作为通用的求解器, 通过在数据集上训练深度网络实现 SLAM 的所有过程, 一般由特征网络或深度预测网络和位姿网络组成, 类似于传统 SLAM 中的前端与后端, 但不同的是, 每个环节都由深度网络构成, 所有过程都是“黑箱”。由于 SLAM 问题的复杂性和环境依赖性, 端到端的 SLAM 方法通常需要海量的训练数据和极高的算力, 才能保证方法的通用性。




图 10-20 端到端的 SLAM 示意图

2. 代表性方法

LO-NET^[14]是面向无人驾驶提出的激光雷达定位建图系统, 通过三个深度学习网络实现, 系统输入为连续的激光点云序列, 输出为位姿和地图。该方法在许多数据集上定位精度优于 LOAM 算法, 建图结果如图 10-21 所示, 即使没有回环检测模块, 系统在城市街区环绕一周回到起点时, 轨迹的漂移仍较小。

图 10-21 LO-NET 的建图结果^[14]

SimVODIS^[21]是针对无人驾驶提出的单目视觉定位建图系统。该系统利用 MASK-RCNN 提取图像特征，并用同一套特征实现了五种功能，包括位姿估计、环境建图、目标（行人和车辆）识别、目标定位和目标的实例分割。该方法运行过程中，目标识别与实例分割的结果如图 10-22 所示。

图 10-22 SimVODIS 系统的运行结果图^[21]


10.4.3 深度学习与传统方法的结合

1. 基本思路

传统的 SLAM 是一个很复杂的过程，从前端到后端都是透明的，通常需要对特定的环节进行针对性的改进，以适配不同的环境和任务。而深度学习虽然可解释性不强，但可以基于大量先验数据学习到复杂的映射关系，在特定场景和任务下表现良好。因此，基于传统 SLAM 方法的基本框架，使用深度学习改进或替换其中的某些模块，能够绕开许多建模和实现上的棘手问题。例如，将基于深度学习的特征提取、深度估计、语义理解、回环检测等模块与传统 SLAM 系统相结合，能够取得较好的效果。

2. 代表性方法

TANDEM^[22]无缝融合了传统的视觉 SLAM 前端和 MVSNet 环境重建方法，有效地利用关键帧和预测的深度图，实现了单目视觉的实时三维稠密建图。如图 10-23 所示，该方法达到了较好的定位和建图效果。

图 10-23 室内场景的 TANDEM 定位和建图结果^[22]

SRVIO^[23]是适用于自主移动机器人的视觉惯导定位建图系统。该系统在 VINS 的基础上，利用深度神经网络分别实现动态区域的特征点去除、IMU 数据去噪和回环检测，在动态环境、光照变化等场景下均有较好的表现。如图 10-24 所示，在同一个场景的白天和夜晚，SRVIO 依然能够进行准确的特征匹配，完成回环检测。但该方法的性能依赖于动态区域检测与分割的效果，且在系统运行前，需要预先采集 IMU 数据训练 IMU 去噪网络。




图 10-24 SRVIO 系统在相同场景下白天和夜晚的特征匹配结果^[23]

虽然目前基于深度学习的 SLAM 在某些方面展现出了巨大的优越性，但考虑到实现成本和机器人应用场景的复杂性，基于深度学习的 SLAM 发展仍然任重而道远。首先，深度学习对计算能力的要求远远超过传统算法，不利于在机器人上直接部署。其次，深度学习的训练需要海量的数据样本，而许多 SLAM 的应用场景缺少先验数据，无法满足深度学习的训练要求。最后，深度学习的训练效果和性能较依赖于数据集的质量，并且要求应用场景与训练场景相似，因此泛化能力不强。

10.5 SLAM 的发展脉络与未来展望

10.5.1 SLAM 的发展脉络

SLAM 算法 1986 年展开研究并延续至今，按照研究热点趋势，可分为三个时期：经典时期（1986-2004）、算法分析时期（2004-2015）和鲁棒感知时期（2015 至今）^[24]，如图 10-25 所示。




图 10-25 SLAM 发展脉络

经典时期提出 SLAM 概念，主要关注 SLAM 技术的概率解释，包括扩展卡尔曼滤波、Rao-Blackwellized 粒子滤波和最大似然估计的方法；算法分析时期研究 SLAM 的基本性质，包括可观测性、收敛性和一致性，并开发了主要的开源 SLAM 库；鲁棒感知时期主要研究 SLAM 系统的鲁棒性能、高层感知理解能力、根

据可用算力资源调整负载的能力以及任务驱动的感知能力,并逐渐发展为多传感器融合 SLAM、语义 SLAM 等等。

1. 激光 SLAM

EKF-SLAM 1991: 使用最大似然估计进行数据关联,将扩展卡尔曼滤波应用于在线 SLAM 中。

Fast-SLAM 2002: 将 SLAM 问题分解为机器人定位问题和基于已知机器人位姿的建图问题,利用粒子滤波来模拟机器人位姿的估计,每个粒子维护 k 个 EKF 用于 k 个路标点位置的估计。

Fast-SLAM 2.0 2003: 对 Fast-SLAM 进行改进,在更新粒子位姿时加入观测信息,定义一个新的权重系数,并加入了对路标点真实性的判断。

Gmapping 2007: 在 Fast-SLAM 的基础上进行优化的一种 SLAM,使用了改进的 RBPF 粒子滤波算法,将粒子数量控制在一定范围内,减少重采样次数,缓解粒子耗散的问题。

Karto-SLAM 2010: 基于图优化的思想,将机器人运动姿态及约束关系采用稀疏有向图表示,使用了高度优化和非迭代 Cholesky 矩阵对系统进行解耦并求解。

Hector-SLAM 2011: 利用高斯牛顿法解决前端扫描匹配问题,将每一帧采集到的激光雷达数据和地图进行匹配。

LOAM 2014: 提取激光扫描数据中的角点和平面点,进行匹配和优化,实现实时定位与三维建图,分为高频、低精度的里程计与低频、高精度的地图构建两个部分进行解决。

Cartographer 2016: 基于图优化的激光 SLAM 算法,同时支持 2D 和 3D 激光 SLAM,分为前端局部建图和后端全局优化两个部分。

LeGO-LOAM 2018: 在 LOAM 的基础上,为应对可变地面进行了地面优化,并加入回环检测,同时保证轻量化,可在嵌入式系统上实现实时定位与建图。

BALM 2021: 提出了适用于激光 SLAM 的光束平差法 (BA),特征点位置可以通过解析方法求解,不参与 BA 过程,BA 只考虑关键帧位姿。

VoxelMap 2022: 为激光里程计提出一种高效的概率自适应体素建图方法,每个体素包含一个平面特征,实现环境的概率表示和激光帧的精确配准。

2. 视觉 SLAM

Mono-SLAM 2007: 首个单目 SLAM 算法,基于扩展卡尔曼滤波,使用单个线程逐帧更新相机位姿和地图。

PTAM 2007: 首个将跟踪和建图分离到两个不同线程的 SLAM 算法,并且也是第一个利用非线性优化,将光束平差法 (BA) 与视觉 SLAM 相结合的方法。

DTAM 2011: 使用单个 RGB 相机进行实时稠密定位和跟踪的方法,是首个使用直接法的视觉 SLAM,分为稠密建图和稠密跟踪两个线程。

LSD-SLAM 2014: 是一种基于半稠密建图的直接法视觉 SLAM,包含跟踪、深度图估计和地图优化线程。

SVO 2014: 一种半直接法视觉里程计,通过结合直接法和特征点法的优点,实现了快速准确的特征跟踪和地图构建,并利用基于均匀-高斯混合分布的深度滤波器保证系统在低纹理和重复纹理场景中的鲁棒

性。

ORB-SLAM 2015: 在 PTAM 的基础上, 提出基于 ORB 特征点的单目 SLAM 算法, 主要分为三个并行线程, 包括跟踪、建图以及回环线程。

ORB-SLAM2 2017: 在 ORB-SLAM 的基础上, 从单目相机扩展到双目和 RGB-D 相机, 能够实现地图重用、回环检测和重定位的功能。

DSO 2017: 一种稀疏直接法里程计, 将相机曝光时间加入到光度误差模型中, 通过最小化光度误差估计相机位姿、内参和特征的逆深度, 进一步提高了直接法的准确性。

3. 多传感器融合 SLAM

MSCKF 2007: 一种基于滤波的视觉惯性融合算法, 系统状态变量只包含相机位姿, 而不包含特征点位置, 利用多个相机状态之间形成的几何约束构建观测模型, 用于更新 EKF, 解决了传统基于 EKF 的 SLAM 的维度爆炸问题。

OKVIS 2015: 针对双目+IMU 的基于优化的紧耦合方法, 将 IMU 误差项和视觉重投影误差组合成一个目标函数, 共同优化。

VINS-Mono 2018: 一种基于滑动窗口优化的视觉惯导系统, 使用一个鲁棒的初始化方法对系统状态进行初始估计, 并在滑动窗口中对视觉特征点、IMU 预积分和先验信息进行紧耦合优化, 实现实时且鲁棒的相机位姿估计。

VINS-Fusion 2019: 在 VINS-Mono 的基础上, 增加对双目相机、双目相机+IMU 以及 GPS 的支持。

LIC-Fusion 2019: 基于 MSCKF 框架, 利用从激光雷达检测和跟踪到的稀疏边缘或平面特征、稀疏的视觉特征以及 IMU 数据, 进行多模态传感器融合, 并具有在线标定功能。

LIC-Fusion 2.0 2020: 在 LIC-Fusion 的基础上, 将激光平面特征的跟踪从相邻两帧扩展到滑动窗口中的多帧, 并将其加入到状态变量中进行优化。

LIO-SAM 2020: 在 LeGO-LOAM 的基础上, 增加了对 IMU 和 GPS 的紧耦合, 采用因子图优化位姿, 包括 IMU 预积分因子、激光里程计因子、GPS 因子、回环因子。

ORB-SLAM3 2021: 在 ORB-SLAM2 的基础上, 增加了对 IMU 融合的支持, 兼容鱼眼相机模型, 且增加了多地图的支持, 跟踪丢失时可以重建地图, 并将该地图和原来构建的地图进行对齐, 以实现自动重定位。

FAST-LIO 2021: 采用迭代误差状态卡尔曼滤波来实现激光雷达与 IMU 的紧耦合, 提出反向传播过程补偿运动畸变, 并提出一个新的卡尔曼增益计算公式, 使计算量依赖于状态维度而非观测维度, 从而降低了计算量。

LVI-SAM 2021: 基于因子图优化的紧耦合激光雷达视觉惯导 SLAM 系统, 由视觉-惯导和激光-惯导两个子系统组成, 视觉-惯导系统利用激光-惯导系统的估计值进行初始化, 并利用激光雷达的测量为视觉特征提供深度, 提升精度, 同时激光-惯导系统利用视觉-惯导的估计值作为初值进行匹配。

R2LIVE 2021: 一种鲁棒、实时紧耦合的多传感器融合框架, 融合激光雷达、视觉相机、IMU 的测量结果, 实现鲁棒准确的状态估计, 包含基于滤波的里程计和因子图优化两部分, 里程计部分通过迭代误差状态卡尔曼滤波进行状态估计, 并通过因子图优化局部滑动窗口内的视觉路标点, 进一步提高整体精度。

GVINS 2022: 一种基于非线性优化的紧耦合方法，在概率框架下融合视觉、IMU 信息与 GNSS 原始数据，实现了复杂场景下无漂移的实时位姿估计。此外，还提出了一种由粗到精的在线初始化方法，用于系统的初始状态估计。

FAST-LIO2 2022: 在 FAST-LIO 的基础上，使用增量式 ikd-tree 数据结构维护局部地图，有效降低激光点最近邻搜索的耗时，提升效率。

R3LIVE 2022: 一种多传感器融合框架，利用激光雷达、IMU 和 RGB-D 相机的测量，实现准确的状态估计，并实时地重建精确、稠密、带有 RGB 着色的地图，包含激光-惯导和视觉-惯导两个子系统，激光-惯导系统构建全局地图的几何结构，视觉-惯导系统通过最小化帧与地图的光度误差，直接有效地融合视觉数据，渲染地图的纹理（即 3D 点的颜色）。

FAST-LIVO 2022: 一种快速的激光雷达-惯性-视觉里程计，包含激光-惯导和视觉-惯导两个紧耦合的里程计子系统，激光-惯导子系统将激光原始点云配准到增量式点云地图中，地图中的点带有颜色、纹理信息，将其投影到新图像上，用于视觉-惯导子系统通过最小化光度误差估计新图像的位姿，复用了激光点，避免了视觉特征的提取。

Point-LIO 2023: 提出逐点 LIO 框架，消除点云的运动畸变，并允许系统以接近激光点采样的频率进行位姿估计和地图更新。同时，使用随机过程模型对 IMU 测量进行建模，进而提出随机过程增强的运动学模型，并将 IMU 测量值作为系统输出，进一步提高系统带宽。

4. 语义 SLAM

SLAM++ 2013: 一个基于先验物体模型的纯面向物体的语义 SLAM 系统。首先，为场景中可能出现的每一个物体构建高质量的物体模型，并构造物体数据库。随后，在追踪过程中，基于先验物体模型数据库检测场景中的物体及其位姿。最后，将检测到的物体模型添加到图优化中，实现面向物体的地图构建。

SemanticFusion 2017: 一种利用 SLAM 输出信息改善语义分割性能的方法。首先利用 SLAM 估计像素点的运动，得到相邻帧像素点的关联结果。随后，基于像素点关联信息和分类概率，利用贝叶斯方式更新当前像素点的分类概率，实现连续多帧分类概率的整合，从而增强语义分割的结果。

Fusion++ 2018: 一种基于体素的物体级语义 SLAM 系统。使用 Mask-RCNN 检测场景中的物体，获得 2D 实例掩膜。随后，利用 TSDF 对同一物体在连续多帧图像中的 2D 掩膜进行融合，得到物体模型的 3D “体素掩膜”。最后，Fusion++ 将物体的体素模型引入到 SLAM 中，设计完整的物体级 SLAM 系统。

DynaSLAM 2018: 一种面向动态环境的基于点特征的语义 SLAM 系统。首先，利用语义分割结果标记出图像中的疑似动态区域。随后，利用多视图几何对疑似动态区域进行验证，从而确保 SLAM 的稳定性和准确性。

QuadricSLAM 2018: 一种基于对偶二次曲面的物体级语义 SLAM 系统。首次将基于对偶二次曲面的物体表示形式引入到 SLAM 中，提出对偶二次曲面的投影观测模型和边界框约束模型，并将其与 SLAM 的追踪和建图相融合，实现了基于对偶二次曲面表示的物体模型与相机位姿的联合优化。

CubeSLAM 2019: 一种基于长方体模型的物体级语义 SLAM 系统，首次提出了基于消失点的单目 3D 物体检测方法，在假定物体支撑平面已知的前提下，通过采样物体偏航角和顶点位置，得到完整的物体模型。最后，将单目 3D 物体检测结果引入 SLAM 中，构建优化目标实现了物体模型和相机位姿的联合优化。

EA0-SLAM 2020: 一种基于参数化和非参数化检验的数据关联方法，首先提出一种基于独立森林的物体点云外点剔除方法，并利用点云估计物体模型。随后，通过假设检验实现物体模型之间的关联，提升了关联的准确度和鲁棒性。

SO-SLAM 2022: 一种考虑物体对称性的单目语义 SLAM 系统。采用 Quadric 模型表示物体，并引入三种空间约束增强物体模型，包括比例约束、对称纹理约束和平面支撑约束。SO-SLAM 首次将物体对称性引入到物体模型估计和 SLAM 优化中，降低了物体 SLAM 系统对观测数量的依赖。

SGS-SLAM 2024: 首个能够同时实现定位、重建和分割的基于 3D 高斯的稠密语义视觉 SLAM。采用多通道优化进行建图，将外观、几何和语义约束与关键帧优化相结合，在提供精确的 3D 语义分割的同时，产生高质量的重建结果。

SemGauss-SLAM 2024: 一种基于 3D 高斯的语义 SLAM 系统。将语义特征嵌入与 3D 高斯表示相结合，有效编码环境空间的语义信息，实现精确的语义场景表示，同时引入基于语义感知的光束平差法减少累积漂移，提高重建精度。

10.5.2 SLAM 的未来展望

SLAM 技术已经取得了显著进展，但在实际应用中仍面临诸多挑战。为了进一步提升 SLAM 技术的实用性和可靠性，在表 10-5 中总结了几个关键技术难点和未来的发展方向。

表 10-5 SLAM 的技术难点与未来展望

技术难点	描述	未来展望
大规模动态环境中的 SLAM	动态干扰：传统 SLAM 假设环境静止，实际应用中动态物体干扰大。 误差累积：长时间运行时，误差累积影响定位精度。	动态物体识别与跟踪：结合深度学习和传统 SLAM，提升动态物体识别与跟踪能力。 自适应算法：开发自适应 SLAM 算法，根据环境动态变化自动调整参数和模型。
提高 SLAM 系统的鲁棒性	复杂环境适应性：光照变化、遮挡、低纹理等环境下鲁棒性差。 非线性和非高斯噪声：现实环境非线性和非高斯噪声影响大。	多传感器融合：结合多种传感器数据，提升环境感知精度和鲁棒性。 鲁棒优化方法：研究基于非线性和非高斯噪声的鲁棒优化方法。
实时性与高效计算	高计算量：处理大量传感器数据，难以实时运行。 数据存储与传输：高效的数据存储和传输机制是关键。	专用硬件加速：开发 SLAM 专用计算芯片，提高处理效率，降低功耗。 高效数据结构和算法：研究更高效的数据结构和算法。
环境语义理解	高层语义信息缺乏：传统 SLAM 关注几何信息，对环境的高层语义信息理解较少。 语义信息集成：将语义信息与几何信息有效融合，实现语义级别的环境理解。	深度学习与 SLAM 结合：利用深度学习进行物体识别、语义分割等，将语义信息集成到 SLAM 系统中。 语义地图构建：构建包含语义信息的环境地图。
SLAM 与深度学习的结合	数据驱动与机理驱动结合：深度学习需要大量标注数据，SLAM 依赖精确的物理建模。 泛化能力：大模型在不同环境中的泛化能力有限。	混合模型：结合传统 SLAM 物理模型和深度学习，构建混合模型。 自监督学习：利用自监督学习，减少标注数据依赖，提升深度网络/大模型的泛化能力。

10.6 思考

【思考 10.1】探究最新的 SLAM 研究进展, 探讨其未来的发展方向和挑战。

【思考 10.2】现阶段 SLAM 的技术难点在于什么? SLAM 技术还有哪些可能的应用?

【思考 10.3】如果你是一个 SLAM 工程师, 想要实现一个 SLAM 系统, 你会选择哪种传感器? 为什么?

【思考 10.4】思考 SLAM 在自动驾驶中的应用, 探讨现阶段自动驾驶最可能的落地方向以及对交通安全的影响。

【思考 10.5】分析一个现有 SLAM 系统, 如何协助机器人完成在陌生环境中收集数据的任务, 描述各个步骤以及它们之间的依赖关系。

10.7 习题

【作业 10.1】请解释 SLAM 系统前后端的差异, 简要说明前端和后端在 SLAM 中的作用是什么、分别处理哪些任务, 以及为什么要同时包括前后端?

【作业 10.2】SLAM 的基本方法可以分为三类: 传统的 SLAM 方法、端到端的深度学习方法 and 前两类的结合, 分析三者的优劣。

【作业 10.3】请阐释 SLAM 技术在目前的智能家居中是如何应用的, 未来会有哪些新的突破?

【作业 10.4】除 SLAM 技术外, 还有哪些机器人定位方法? SLAM 和这些方法的差异性以及 SLAM 方法的特异性体现在哪里? SLAM 在机器人领域和其它无人系统中的重要性体现在哪里?

参考文献

- [1] SMITH R C, CHEESEMANN P. On the representation and estimation of spatial uncertainty[J]. The International Journal of Robotics Research, 1986, 5(4): 56-68.
- [2] GÁLVEZ-LÓPEZ D, TARDOS J D. Bags of binary words for fast place recognition in image sequences[J]. IEEE Transactions on Robotics, 2012, 28(5): 1188-1197.
- [3] GRISETTI G, STACHNISS C, BURGARD W. Improved techniques for grid mapping with Rao-Blackwellized particle filters[J]. IEEE Transactions on Robotics, 2007, 23(1): 34-46.
- [4] KONOLIGE K, GRISETTI G, KÜMMERLE R, BURGARD W, LIMKETKAI B, VINCENT R. Efficient sparse pose adjustment for 2D mapping: Proceedings of IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS): 22-29., 2010[C]. IEEE, 2010.
- [5] ZHANG J, SINGH S. LOAM: Lidar odometry and mapping in real-time[J]. Robotics: Science and Systems, 2014, 2(9): 1-9.
- [6] MUR-ARTAL R, TARDOS J D. ORB-SLAM2: An open-source slam system for monocular, stereo, and RGB-D cameras[J]. IEEE Transactions on Robotics, 2017, 33(5): 1255-1262.
- [7] CAMPOS C, ELVIRA R, RODRÍGUEZ J J G, MONTIEL J M M, TARDOS J D. ORB-SLAM3: An accurate open-source library for visual, visual-inertial, and multimap SLAM[J]. IEEE Transactions on Robotics, 2021, 37(6): 1874-1890.

- [8] ENGEL J, KOLTUN V, CREMERS D. Direct sparse odometry[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(3): 611-625.
- [9] XU W, CAI Y, HE D, LIN J, ZHANG F. FAST-LIO2: Fast direct LiDAR-inertial odometry[J]. IEEE Transactions on Robotics, 2022, 38(4): 2053-2073.
- [10] BLOESCH M, BURRI M, OMARI S, HUTTER M, SIEGWART R. Iterated extended Kalman filter based visual-inertial odometry using direct photometric feedback[J]. The International Journal of Robotics Research, 2017, 36(10): 1053-1072.
- [11] SHAN T, ENGLT B, MEYERS D, WANG W, RATTI C, RUS D. LIO-SAM: Tightly-coupled lidar inertial odometry via smoothing and mapping: Proceedings of IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS): 5135-5142., 2020[C]. IEEE, 2020.
- [12] QIN T, LI P, SHEN S. VINS-Mono: A robust and versatile monocular visual-inertial state estimator[J]. IEEE Transactions on Robotics, 2018, 34(4): 1004-1020.
- [13] WANG S, CLARK R, WEN H, TRIGONI N. DeepVO: Towards end-to-end visual odometry with deep recurrent convolutional neural networks: Proceedings of IEEE International Conference on Robotics and Automation (ICRA): 2043-2050., 2017[C]. IEEE, 2017.
- [14] LI Q, CHEN S, WANG C, LI X, WEN C, CHENG M, LI J. LO-NET: Deep real-time lidar odometry: Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR): 8473-8482., 2019[C]. IEEE, 2019.
- [15] GEIGER A, LENZ P, URTASUN R. Are we ready for autonomous driving? the KITTI vision benchmark suite: Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR): 3354-3361., 2012[C]. IEEE, 2012.
- [16] Bulch C, Klein A, Watson R, Kitts C. Characterization of delay-induced piloting instability for the Triton undersea robot: 2004 IEEE Aerospace Conference Proceedings: 409-423., 2004[C]. IEEE, 2004.
- [17] Wisht D, Camurri M, Fallon M. VILENS: Visual, inertial, lidar, and leg odometry for all-terrain legged robots[J]. IEEE Transactions on Robotics, 2022, 39(1): 309-326.
- [18] Koide K, Miura J, Menegatti E. A portable three-dimensional LIDAR-based system for long-term and wide-area people behavior measurement[J]. International Journal of Advanced Robotic Systems, 2019, 16(2): 1-16.
- [19] FOX D, BURGARD W, DELLAERT F, THRUN S. Monte Carlo localization: efficient position estimation for mobile robots: AAAI-99: Proceedings of the Sixteenth National Conference on Artificial Intelligence and The Eleventh Annual Conference on Innovative Applications of Artificial Intelligence: 343-349., 1999[C]. Computational Intelligence, 1999.
- [20] LIN J, ZHANG F. R3LIVE: A robust, real-time, RGB-colored, LiDAR-inertial-visual tightly-coupled state estimation and mapping package: Proceedings of IEEE International Conference on Robotics and Automation (ICRA): 10672-10678., 2022[C]. IEEE, 2022.
- [21] KIM U H, KIM S H, KIM J H. SimVODIS: Simultaneous visual odometry, object detection, and instance segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(1): 428-441.
- [22] KOESTLER L, YANG N, ZELLER N, CREMERS D. TANDEM: Tracking and dense mapping in real-time using deep multi-view stereo: Proceedings of Conference on Robot Learning: 34-45., 2022[C]. Proceedings of Machine Learning Research, 2022.

- [23] SAMADZADEH A, NICKABADI A. SRVIO: Super robust visual inertial odometry for dynamic environments and challenging loop-closure conditions[J]. IEEE Transactions on Robotics, 2023, 39(4): 2878-2891.
- [24] CADENAC, CARLONE L, CARRILLO H, LATIF Y, SCARAMUZZA D, NEIRA J, REID I, LEONARD J J. Past, present, and future of simultaneous localization and mapping: toward the robust-perception age[J]. IEEE Transactions on Robotics, 2016, 32(6): 1309-1332.

《自动化与智能科学概论》教材初稿